从理解具身智能
到选择研究方向

算法图解 · 仓库入门 · 五篇核心论文 · 四篇补充综述

偏算法主线：数据与表征 → BC / ACT / 扩散 / 流匹配 → VLA / RL → 世界模型与规划 → 长任务与研究实验。

19 张原创教学图，结合输入输出、损失、训练与部署、常见疑问和自测。覆盖核对明确各分支的讲解深度；研究工具地图另补数据、算力、基础设施和榜单。

学习导读由 Codex 根据指定仓库与论文编写。例子、公式简化和伪代码为教学补充。全文中文译稿另存为机器翻译初稿；完整公式、实验结果与正式引用以原文为准。

初版 2026-10-22 · 图解扩写 2026-10-24 · 建议从阅读路线开始

目录与学习目标

具身智能：从理解全景到选择研究方向

从 Embodied-AI-Guide 理解具身智能

P1：从动作策略到 Agentic Robots

P2：怎样判断真正的递归自我改进

P3：长时程 Agent 为什么难

P4：世界模型怎样帮助机器人

P5：把整个 Agent 系统作为改进对象

四篇补充综述：拓宽具身研究视野

具身智能与 Agent：术语速查

新手研究工具地图：数据、算力、榜单与世界模型

算法图解详解：从数据到策略与世界模型

仓库覆盖核对与算法阅读地图

PDF 提供章节书签；单篇 Markdown 文件可用于修改和记笔记。页码指引均按随包原始论文的 PDF 物理页码。

具身智能：从理解全景到选择研究方向

个人学习包 · 初版 2026-10-22 · 学习文档更新 2026-10-24

1. 这套材料怎么用

你的当前目标是建立原理层面的理解，能解释系统怎么工作、为什么失败、各种研究方向在解决什么问题。第一阶段不要求读完实现、不要求训练大模型，也不需要按页通读所有综述。

学习包分为原始论文、中文翻译、学习文档三部分。先看本文件和仓库导读，随后按照下面的顺序读学习文档；遇到重要定义时回到原文核对。中文全文是机器翻译初稿，保留英文术语，用来降低阅读门槛。每篇还附有单独校订的核心摘要，优先阅读这一页以准确把握主旨。PDF 中每个原文页后面紧跟该页中文译文，因此原图、公式、表格始终可查。机器提取无法完整重建复杂公式与表格，请以原文为准。

学习文档中的例子、计算、伪代码、实验建议由导读编写者补充，均为教学材料，不是论文原文、不代表作者开展过对应实验。五篇核心综述的分类体系是作者提出的分析框架，不能当成领域已经统一采用的标准。

2. 最推荐的阅读顺序

偏算法的阅读主线已调整：01 速览后，以 10 算法图解详解为主教材，先读第 1 至 7 节的数据 / 表征 / 动作学习，再读第 8 至 12 节的 VLA / RL / 世界模型。随后回到下面的综述导读。09 查询工具，11 说明仓库覆盖深度；不必先读两篇递归改进。

顺序	材料	先解决的问题	第一遍可以停在哪里
1	01 仓库入门导读	机器人从看见到行动，中间发生什么？	能画出感知、策略、控制、反馈闭环
2	09 新手研究工具地图	数据、算力、基础设施、榜单和世界模型模块怎么连接？	能区分六类工具，解释一条数据与一次预测
3	S1 基础模型综述导读，见 07	大模型分别能放在系统什么位置？	能区分感知模块、规划器、动作策略
4	P4 世界模型导读	机器人为什么需要预测行动后果？	能解释三条分类轴和预测误差
5	P1 Agentic Robots 导读	一个可靠机器人系统比单个策略多什么？	能解释 Model、Data、Environment、Harness
6	P3 长时程 Agent 导读	多步骤任务为什么远比单步难？	能解释依赖、记忆、验证、恢复
7	P5 Path to RSI 导读	如何把反馈变成持久改进？	能解释五组件状态与四阶段改进循环

顺序	材料	先解决的问题	第一遍可以停在哪里
8	P2 Last AI / RSI 导读	如何判断系统是否真正改进了改进机制？	能区分结构递归与有效递归
9	S2 VLA、S3 数据评测、S4 SLAM 导读，见 07	哪个具体方向值得继续研究？	每篇写出一个感兴趣的问题

将世界模型安排在 Agentic Robots 前，是为了先理解“策略负责行动、世界模型负责预测”的区别；如果更喜欢系统设计，可以交换这两篇。两篇 RSI 放在后面，是因为它们大量讨论通用 Agent、软件、科研和企业系统。机器人是其应用之一，不能将软件里的成功率、自动化能力直接视作机器人能力。

3. 一个可调整的六周方案

默认每周投入约 5 至 7 小时。这是建议安排，不是完成任务的时限，也没有要求你六周内掌握所有内容。

第一周：读仓库速览和 10 算法详解第 1 至 6 节，用图与样本理解数据和动作学习；按需查 09 工具地图，理解观测、动作、策略、数据轨迹、BC 与 RL。只看 RoboTwin 任务视频或数据示例也可以。产出一张“收拾杯子”的系统图和十个术语解释。

第二周：读基础模型和 VLA 导读。弄清视觉编码器、语言条件、动作头和动作分块。产出一个输入输出表：每个模块吃什么数据、输出什么数据。

第三周：读世界模型和 Agentic Robots 导读。每篇只精读摘要、总图、定义、挑战，并选一个分类分支。产出一页比较：直接策略、世界模型规划、Agent 编排分别在哪些失败上有帮助。

第四周：读长时程和两篇 RSI 导读。产出一个失败恢复流程，以及一个“改进了任务策略”和“改进了改进规则”的对比例子。不要急着钻进递归修改代码。

第五周：横向读数据与评测、SLAM 的导读，补足非模型方向。选两个候选方向，各写一个问题卡片：问题、已有方法、缺口、能做的最小实验、需要的资源。

第六周：只保留一个方向。阅读一篇代表性方法论文的核心方法，再阅读对应代码中的数据读取、模型输入输出、评测入口。目标是解释一条样本怎样穿过系统，而不是一次理解整个仓库。

4. 选方向时看什么

方向	你可能喜欢的事情	可以从什么小问题开始	主要资源门槛
模仿学习 / VLA	网络、训练、动作生成	同一策略换数据配方后，哪些失败减少？	小策略可仿真入门；大 VLA 训练门槛较高
世界模型	预测、表征、规划	更好的预测是否真的提高任务成功率？	潜空间小模型可入门；大视频模型昂贵
Agent Harness / 记忆	系统搭建、任务分解、调试	失败证据如何支持正确恢复而非盲目重试？	可冻结策略、在仿真中研究
数据与评测	实验设计、统计、可靠性	成功率是否被训练测试重叠或任务重置污染？	算力要求可较低，设计要求高
几何感知 / SLAM	空间推理、坐标、地图	换视角或遮挡时，系统为何丢失物体？	数据与标定知识很重要
运动控制 / RL	动力学、奖励、稳定性	仿真策略为何到真实地面会失稳？	并行仿真与控制基础更重要

如果暂时没有偏好，先做操作任务中的小策略加失败分析。它能连接视觉、数据、学习、控制和评测，之后转向其他分支也有用。选题不能只看方向热门程度；优先选择你能获取数据、运行基线、独立验证结论的问题。

5. 每篇论文只做一张理解卡片

写六句话：它解决什么问题；输入和输出是什么；核心机制是什么；作者通过什么证据支持它；在哪些条件下可能失败；它与我现在的研究兴趣有什么关系。接着画一张数据流图，最后再决定是否读代码。

遇到大量方法名时，先归类，再记代表作。例如 ACT 与 Diffusion Policy 都生成动作序列，但生成机制不同；Dreamer 与视频生成世界模型都预测未来，但目标、表示与控制接口不同。先建立比较维度，背模型名的收益很低。

6. 怎样判断真的理解了

你应当能不看材料回答：如果机器人抓空了，可能是看错、坐标错、策略错、控制误差还是评估错？如何设计一个最小检查区分它们？如果系统添加了记忆，怎样证明提升来自有效记忆而非更多计算？如果模型预测的视频更漂亮，为什么机器人仍可能更容易撞到杯子？

能解释这些问题，已经达到第一阶段目标。下一阶段才需要把解释落到具体数据、代码、训练与评测细节。

遇到数据、显存、仿真器和榜单术语时，查 09 新手研究工具地图；遇到模型与控制缩写时，查 08 术语速查。建议先理解英文全称表达的功能，再记缩写。

7. 来源与版本

仓库快照：Embodied-AI-Guide，提交 3e3abf3e687737c84113f0fe8a78587582c54eb6，读取于 2026-10-22。动态榜单、安装命令、显存需求和模型名称可能继续改变，实施时重新查看官方文档。

核心论文以本次桌面 PDF 为准：P1 79 页、P2 79 页、P3 149 页、P4 23 页、P5 70 页。页码均指 PDF 物理页码。公开记录见各篇导读；补充四篇原文与版本信息见 07。发表状态只按已核对的原文或公开记录标注，不把预印本等同于同行评审论文。

从 Embodied-AI-Guide 理解具身智能

本篇保留为全景速览。偏算法学习请在读完本篇后，以 10 算法图解详解作为主教材；那里展开训练目标、动作表示、推理机制、公式、伪代码与常见疑问。仓库各节的覆盖位置见 11 覆盖核对。

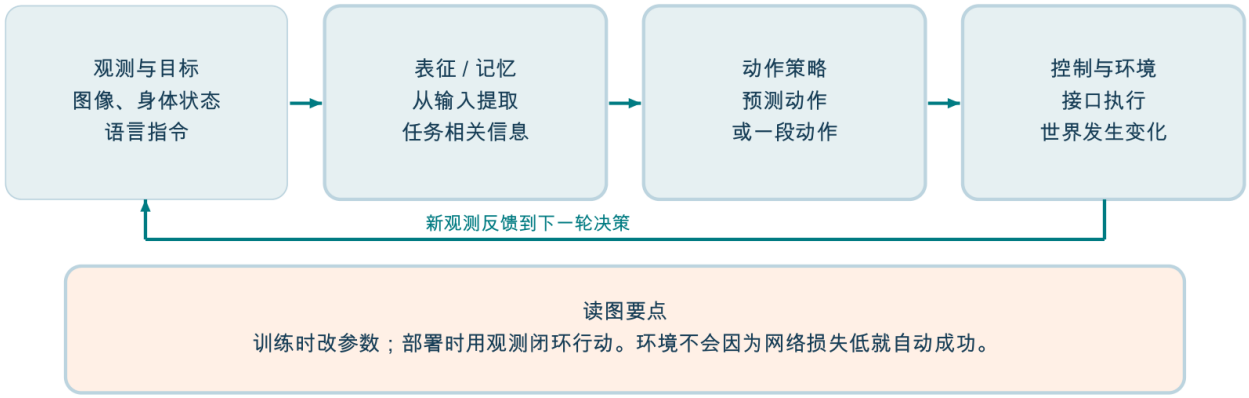
目标：理解原理、数据流与必要伪代码。依据仓库 README 与 algorithm、infrastructure、control、hardware 四篇内容重新组织。下面的教学例子和伪代码由导读补充。

1. 用一个杯子理解整个领域

任务："把桌上的红杯子放进水槽。"语言模型可以描述步骤，但机器人还要知道杯子在哪里、怎样抓住它、手臂如何运动、杯子是否滑落，以及执行失败后怎么办。它改变真实世界，而真实世界不会因为文字上写着"已抓住"就真的完成抓取。

具身智能的核心是交互闭环：传感器获得观测，系统根据目标选择动作，执行器施加动作，世界产生变化，再重新观测。身体决定它能观察什么、能执行什么，以及错误有什么代价。轮式机器人不能直接使用双臂机器人的动作空间，柔软物体也不能完全按照刚体假设处理。

图 1 | 一个算法究竟控制了哪个箭头？



教学示意：按功能解释，不代表所有方法具有相同网络结构。

读图：观测经过表征与策略产生动作，执行后的世界成为下一次输入。训练损失只评价局部拟合，完整闭环还需要任务评测。

一个简化系统可以写成：

```
目标 g：把红杯子放到水槽
观测 o：相机图像 + 关节角 + 夹爪状态
策略 π：根据观测和目标提出动作
控制器：将动作转换为可执行的关节运动
环境：机器人和物体实际发生变化
反馈：检查杯子是否被抓住、是否到达目标
```

这里的观测 observation 不等于真实状态 state。杯子背面的把手可能被遮住，杯子是否装水可能无法从一张图片确定，传感器也有噪声。论文如果使用机器人看不到的仿真真值训练或评估，要注意这些信息在部署时是否仍然可用。

2. 仓库的四张地图

算法篇回答如何理解世界、学习动作和做决策。基础设施篇回答如何产生数据、搭建环境、比较方法。控制篇回答怎样把目标变成稳定、受约束的实际运动。硬件篇回答机器人能感受到什么、能施加什么，以及数据怎么采集。

这四部分互相制约。相机标定错了，换一个更大的动作模型可能仍然抓偏；数据只有成功演示，机器人可能不知道滑落后的恢复动作；仿真中的物体摩擦过于理想，模型在真机上会失败。具身系统的性能不能只用网络架构解释。

3. 机器人到底看到了什么

RGB 图像提供颜色、纹理、类别信息；深度图或点云提供空间结构；关节角、速度、夹爪开合等本体感知 proprioception 告诉系统身体状态；力觉和触觉帮助判断接触、滑动和抓握是否稳定。不同传感器解决不同不确定性。

仓库列出的视觉模型可以按功能理解：CLIP / SigLIP 提供图文语义关联；DINO 提供可迁移视觉表征；Grounding DINO 根据文字定位物体；SAM 系列根据相应提示做分割；FoundationPose 用于物体位姿估计。它们的输出可能是特征、框、掩码或位姿，不会自动变成可执行抓取动作。

比如先用“red cup”找到框，再分割杯子，结合深度得到空间点，最后设计抓取位姿。每一步都可能错：找到了红碗、深度缺失、杯子掩码包含桌面、抓取位姿撞到把手。因此检查每个中间输出很有价值。

仓库对单目深度的提醒可以理解为尺度问题：相对深度不能直接当成米使用。具体模型可能有 metric depth 版本或尺度恢复能力，应核对实际权重与输出约定；不能把所有单目深度模型一概视为没有绝对尺度。

4. 坐标系、FK 和 IK：策略输出怎样落到机器人上

相机说“杯子在右侧”，机械臂需要的是基座坐标系中的目标。手眼标定得到二者的坐标变换。一个点可以示意为：p_base = T_base_camera × p_camera。T 包含旋转与平移；实际计算使用齐次坐标，并必须明确单位、轴方向和变换方向。

FK（Forward Kinematics，正运动学）根据关节角求末端位姿。IK（Inverse Kinematics，逆运动学）根据希望的末端位姿求关节角。IK 可能没有解，也可能有多个解；有解不等于运动路径没有碰撞。

位姿 pose 包含位置与朝向。把杯子移到同一个三维位置，夹爪朝向不同，结果可能完全不同。自由度 DoF 表示独立运动变量的数量，不能简单理解为“自由度越多越好”，因为控制与数据复杂度也随之增加。

第一阶段不要求推导完整动力学，只需理解：感知提供目标、运动学处理几何、规划考虑路径、控制器跟踪轨迹。它们与学习策略可以组合。

5. 一条机器人数据是什么

一条 demonstration / trajectory 是一次任务的时间序列，例如：

```
episode：抓红杯子
t=0：图像、关节角、夹爪状态、专家动作
t=1：执行后图像、身体状态、下一动作
...
t=T：终止标志、成功标签、必要元数据
```

语言指令、机器人本体、相机位置、时间戳、动作单位、控制模式都可能是重要元数据。只保存视频，通常无法知道每一帧对应的机器人指令；只保存关节指令，也可能缺少环境反馈。

常见动作有三类：关节位置 / 增量、末端位姿 / 增量、速度或力矩。比如同一个六维数字可能表示末端 xyz 加旋转，也可能根本属于关节空间，必须看定义。绝对坐标与相对增量混用会使动作失效。

时间同步尤其重要。图像是抓取前的一帧，而标签动作已经是抬起后的指令，模型就会学到错配关系。训练之前理解数据语义，比直接改模型更有收益。

6. 模仿学习：从演示学会动作

BC（Behavior Cloning，行为克隆）把专家动作作为监督标签，学习观测到动作的映射。它与分类或回归训练的思路类似，只是输出变成机器人动作。

```
for batch in 演示数据:
    观测, 目标, 专家动作 = batch
    预测动作 = 策略(观测, 目标)
    损失 = 预测动作与专家动作的差异
    更新策略参数，降低损失
```

示意目标为 L_BC = E[distance(π(o,g), a_expert)]。distance 取什么形式，取决于动作表示与策略类型；生成式策略不一定使用简单均方误差。

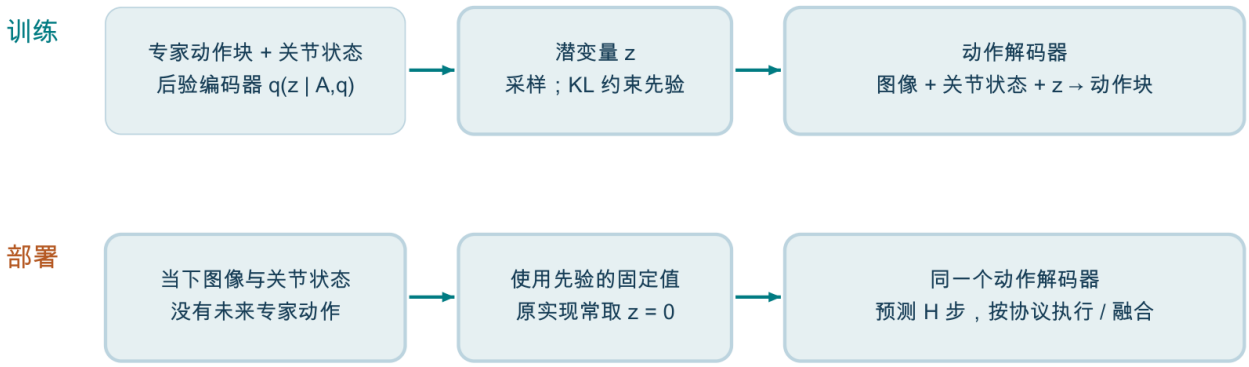
它的主要问题是 distribution shift：模型稍微抓偏，进入专家演示中很少出现的状态；这时又更容易预测错。演示全是“已经抓住后抬起”，模型可能不知道抓空后应该重新对齐。

如果同一场景允许从左抓或从右抓，直接把两种专家动作取平均可能得到一个碰撞路径。这解释了为什么动作分布的多模态表达很重要，而不仅是网络更大。

7. ACT：为什么一次预测一段动作

图 4 | ACT 的训练与部署不是同一个输入图

ACT = Action Chunking with Transformers；CVAE = Conditional Variational Autoencoder



z 表示示范的未观测变化；训练有后验，部署无法读取专家未来。

教学示意：按功能解释，不代表所有方法具有相同网络结构。

读图：训练中的后验编码器可以读取专家未来动作，但部署没有这些标签。原始实现常用先验中心 z=0；它是潜变量设定，不是关节置零。完整损失与融合机制见 10 第 5 节。

ACT（Action Chunking with Transformers）预测未来一段动作，借助条件变分自编码器（CVAE）建模演示行为的变化，并用 Transformer 将观测映射为动作序列。动作分块有助于表达连贯操作，也减轻逐步决策的部分问题。

想象“伸手、合爪、抬起”是连贯短动作。每步独立预测，可能一会儿向左、一会儿向右。一次生成一段动作能利用序列结构。但预测十步并不意味着无反馈地执行十步一定更好；执行多少步后重观测，是部署设计的一部分。

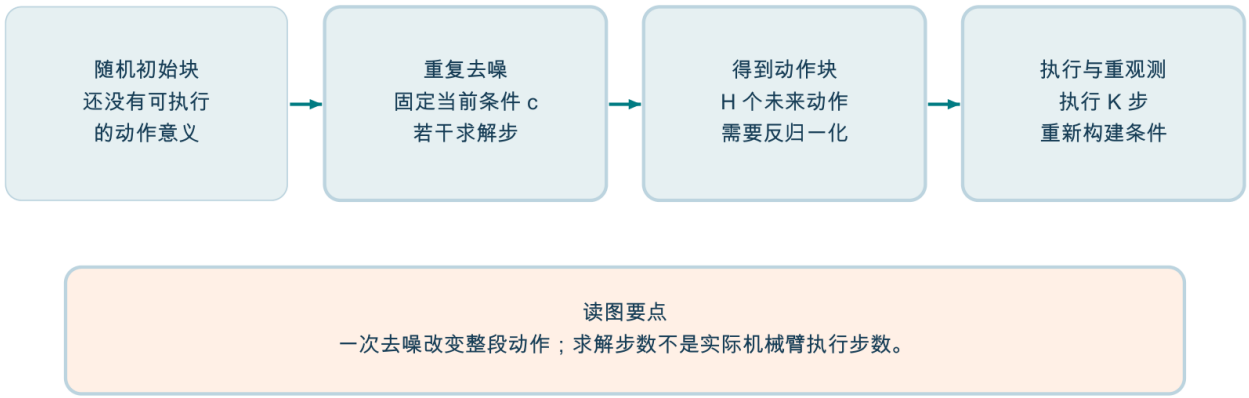
ACT 还可对不同时间预测的、对应同一执行时刻的动作进行 temporal ensembling，以平滑执行。论文实现还包含潜变量、KL 正则等细节，完整输入、动作块、潜变量、损失和部署区别见 10 第 5 节。

```
循环直到结束:
  读取最新图像和关节状态
  动作块 = ACT(当前观测)
  根据部署策略，执行部分动作或融合重叠预测
  重新观测，更新后续预测
```

这是教学伪代码，不是官方可直接运行的 ACT 实现。

8. Diffusion Policy：从噪声形成合理动作序列

图 7 | 扩散部署从随机动作噪声开始



教学示意：按功能解释，不代表所有方法具有相同网络结构。

读图：生成器内部的多次去噪共同产生一个动作块，机械臂随后执行其中一部分。去噪步与交互时刻不同，训练的随机噪声监督见 10 第 6 节。

扩散策略学习给定观测时动作序列的分布。训练时给专家动作加噪声，网络学习去噪；推理时从噪声开始，逐步得到符合观测与任务的动作序列。

训练：专家动作块 → 加噪 → 预测噪声 / 去噪方向 → 更新模型
推理：随机动作噪声 → 条件去噪多步 → 动作块 → 执行前几步

它能更自然地保留多个可行行为模式。代价是迭代生成带来计算延迟，且动作的合理性仍受数据和观测约束。DP3 加入点云表示，强调空间信息对动作学习的作用。不要把“扩散生成的视频”和“扩散生成的动作”混在一起：生成对象不同，训练目标也不同。

9. RL：根据交互结果改进策略

RL（Reinforcement Learning，强化学习）让策略通过交互获得奖励，并优化长期回报。示意目标是 $J(\pi) = E[\Sigma \gamma^t r_t]$。r 是反馈，γ 控制未来奖励的权重，不需要现在推导求导过程。

重复:
- 策略在环境中执行，收集状态、动作、奖励与终止信息
- 根据轨迹评估哪些行为产生更高长期回报
- 更新策略 / 价值函数
- 在独立评测环境检查实际任务表现

操作任务的奖励可能难设计：距离杯子更近，不等于成功抓取；抬起夹爪，不等于杯子被拿起来。奖励写错，模型可能学到“看起来高分”的行为。仿真中的并行试错有助于训练，但现实交互成本、任务重置和安全约束不能忽略。

仓库将 IL 更常用于操作、RL 更常用于运动控制作为入门经验。这是常见模式，不是严格边界；操作同样使用 RL，运动同样使用演示和动作先验。IL 预训练后进行 RL 后训练，是值得认识的组合路线。

10. VLA、大模型规划和快慢系统

VLA（Vision-Language-Action）把视觉、语言和动作连接起来。常见输入是图像、语言任务和机器人状态，输出是动作或动作块。语言提供任务条件，视觉提供环境信息，动作头必须输出机器人能够解释的控制表示。

两种典型设计可以放在一起比较：一种由高层 LLM 分解任务，调用抓取、移动等技能；另一种由 VLA 直接根据观测和语言生成低层动作。实际系统可以分层组合：慢速语义规划决定子任务，快速策略与控制器负责执行。

“慢 / 快”是频率和职责的区别，不代表固定网络名称。具体控制频率取决于机器人、接口和算法。不能把大模型的一次文本响应直接等价为高频闭环控制。

语言知识能帮助认出“杯子”和理解“放进水槽”，但不能自动提供精确摩擦系数、接触力或可靠碰撞约束。语义理解与物理执行之间仍有距离。

11. 世界模型：预测我这样做会发生什么

策略回答“做什么动作”，世界模型回答“做了之后世界可能怎样变化”。一个示意关系为 下一状态 ≈ world_model(当前状态, 动作)。它可帮助规划、生成训练经验或评估候选动作。

```
当前状态 = 编码(最新观测)
候选动作序列 = 产生若干方案
for 方案 in 候选动作序列:
    预测未来 = 世界模型展开(当前状态, 方案)
    分数 = 目标达成程度 - 风险 - 成本
执行最高分方案的第一步
重新观测，再次规划
```

这是基于模型的滚动规划示意。它不能保证安全：预测模型可能误判接触、漏掉障碍或低估不确定性。一般视频生成器如果没有可靠动作条件，不能仅凭画面逼真就视为可控物理模拟器。详细比较见 P4 导读。

12. 仿真、数据集与基准各自是什么

Simulator 是可以交互的环境，负责执行动作并产生新状态与观测；Dataset 是已经记录下来的经验；Benchmark 是任务、评分、数据划分、重置方式和预算等评测协议。三者经常配套，但作用不同。

Sim2Real Gap 包括视觉、动力学、摩擦、接触、延迟和噪声的差异。Domain Randomization 在训练时变化这些条件，帮助策略避免只适应一个狭窄环境。但随机化范围不合理，可能增加训练难度，或仍覆盖不到真实问题。Real2Sim 则从真实物体和场景构建仿真表示。

训练时随机杯子颜色，测试时换杯子形状，二者检验的泛化不同。评测需要说清未见的是对象、位置、场景、任务组合还是机器人本体。

13. 用 RoboTwin 理解完整生命周期

仓库以 RoboTwin 2.0 和 ACT 为实践主线。你现在可以先理解五步：认识任务与仿真；理解轨迹内容；把数据转换成策略输入；训练；在独立环境执行并分析失败。

仓库快照的策略工程通过 XPolicyLab 管理，安装与调用路径可能随版本更新。它提醒使用对应的图像解码工具、对齐 bench / checkpoint / action_type 等配置，这说明“同样叫 ACT”并不保证数据语义和部署接口一致。

你可以暂时不安装环境，先读一条轨迹的字段说明，画出：原始记录 → 图像解码与动作归一化 → 模型输入 → 预测动作 → 反归一化 → 控制接口。知道每一个箭头做什么，就已经实现当前的理解目标。

如果以后开始实践，第一轮只选一个任务和一个基线。先确认数据能显示、动作单位正确、评测能记录失败，再考虑换成大型 VLA。仓库中的显存、成功率与榜单信息是特定快照下的指引，实际执行时核对官方版本。

14. 怎样看成功率而不被数字误导

成功率 80% 至少还需要任务集合、试验次数、训练测试划分、重试预算和成功判断方式。模型 A 在简单位置测试、模型 B 在随机遮挡测试，数字不能直接比较。

可以把失败标为：感知错误、坐标 / 标定错误、动作生成错误、轨迹碰撞、抓握滑落、任务进度丢失、终止判断错误。先分类再选改进方法，避免所有问题都归结为“模型不够强”。

长任务还要统计完成子任务数量、恢复成功率、总耗时、干预次数与代价。只报告最终成功会隐藏改进来自什么模块。

15. 入门自测与参考答案

1. 图像中杯子位置正确，机械臂却总固定偏 2 厘米，应先查什么？先检查坐标变换、标定、单位和时间同步，再判断模型问题。

2. BC 训练误差很低，执行却经常失败，为什么？离线误差只衡量演示分布；闭环执行可能进入陌生状态，并累积误差。

3. 预测未来画面很漂亮，为什么抓取不一定更好？图像质量可能没有反映接触、碰撞、动作因果和精确几何。

4. 控制器与 VLA 有什么区别？VLA 生成任务条件下的动作意图 / 指令；控制器将其在机器人动力学和约束下跟踪执行，具体边界取决于接口。

5. 新人应该先背所有模型名吗？先建立输入输出与问题分类，再记少量代表作；理解比名称覆盖更重要。

来源

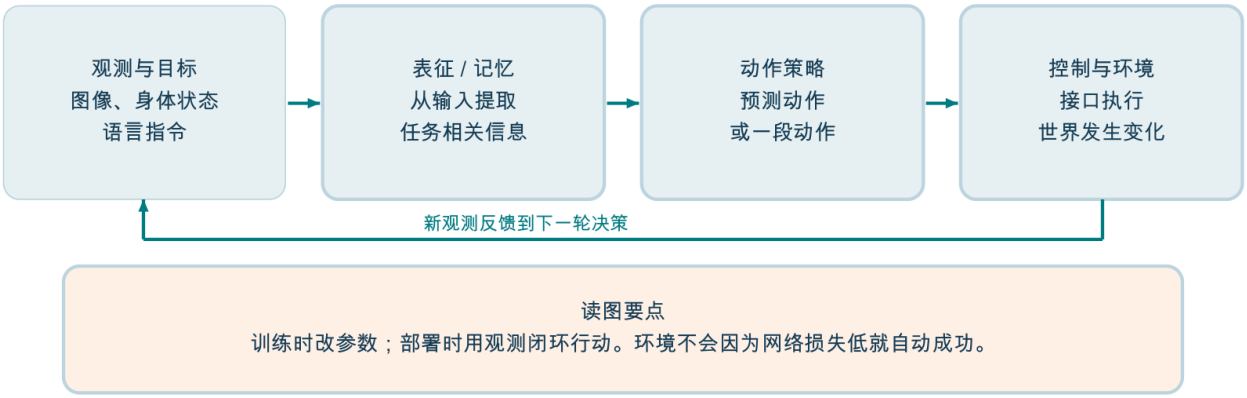
仓库 README、算法篇、基础设施篇、控制篇、硬件篇。经典策略链接：ACT、Diffusion Policy、RoboTwin。

P1：从动作策略到 Agentic Robots

原文：Towards Agentic Robots: Model, Data, Environment, and Harness。Chonghan Qin 等，arXiv:2610.20442v1，2026-10-14，79 页。此版本为预印本。公开记录。

1. 先抓住主张

图 1 | 一个算法究竟控制了哪个箭头？



教学示意：按功能解释，不代表所有方法具有相同网络结构。

读图：动作策略只是中间一环。P1 的 Model、Data、Environment、Harness 分别涉及可学习能力、经验来源、交互条件与运行组织。较强动作模型仍需要进度、反馈和失败处理；训练目标与执行闭环的区别见算法详解第 1、13 节。

一个动作预测模型再强，也不自动具备长期任务管理、失败恢复、数据采集和能力改进。本文用 Agentic Robots 讨论这些功能如何共同构成机器人系统，并以 Model、Data、Environment、Harness 四个领域组织研究。

这里的 agentic 强调系统能够围绕目标作决策、使用反馈调整操作和组织能力。不能简单理解为“把 LLM 接在机器人上”，也不能仅凭模型名字判断系统是否有这些能力。

2. 四种范式如何连接

范式	主要回答	杯子例子	单独使用时的典型缺口
任务策略 Policy	根据观测做什么动作？	当前画面对应怎样的抓取动作？	陌生任务、持续进度管理
VLA	如何将视觉与语言知识连接到动作？	理解“红杯子”并执行操作	语义理解不等于长期可靠执行
WM / WAM	哪些未来值得预测，预测怎样帮助动作？	抬起后是否会碰到旁边物体？	预测误差与控制接口问题
Agentic Robot	如何组织执行、反馈与改进？	抓空后诊断、换方案、记录经验	系统成本、归因、真实部署可靠性

作者明确把它们视作可共存的研究传统与能力。不要把这张图理解为新范式出现后，旧策略或控制器就失去价值。

3. 四领域、十七类：记问题而不是背名单

Model 有五类：Training、Perception、Planning、Robot Control、Adaptation。它研究应该学什么、理解什么、决定什么和控制什么。比如抓取失败是策略缺少演示，还是高层计划选择了错误对象？

Data 有三类：Collection、Annotation、Refinement。它研究采什么数据、如何标注、如何筛选和改善数据。比如对失败场景补采演示，或识别动作与视频错位的轨迹。

Environment 有三类：Reconstruction、Task Generation、Benchmarking。它研究构造什么世界、任务和测试。比如生成带遮挡的杯子场景，检验策略能否处理困难位置。

Harness 有六类：Orchestration、Memory、Monitoring and Recovery、Skills、Infrastructure、Layered Systems。它研究如何组织可执行能力、记住状态、检测问题、恢复执行与支持长期使用。

四领域是组织研究的视角，并不是四个互不相交的软件包。生成任务会改变数据分布，数据改变策略，策略失败又指导下一轮任务生成。

4. Harness 为什么值得单独研究

Harness 可译为运行支撑框架。它决定模型什么时候被调用、获得哪些观测、能用哪些工具、结果怎样验证、失败怎样处理、哪些状态保留到下一步。

假设机器人抓空了。基础策略可能继续执行抬起动作。加入监测后，系统发现“夹爪闭合但杯子仍在桌面”；加入恢复机制后，它重新定位杯子、调整抓取位置。真正的改善来自闭环证据，而非多写一句“请认真完成任务”。

监测也不能只依赖模型自述。应优先用适当的视觉、触觉、夹爪或环境状态证据。例如仿真中可直接读取物体位姿，真机中则需传感器推断；这两种成功判断的可靠性不同。

5. 教学伪代码：可靠执行一个多步骤任务

```
任务 = 解析用户目标
计划 = 根据观测与可用技能生成子任务
记忆 = 保存目标、已完成步骤、已知约束

while 尚未达到最终目标:
    观测 = 读取环境与机器人状态
    下一技能 = 根据计划、记忆和观测选择
    检查技能的前置条件
    执行下一技能
    结果 = 根据新观测检查实际后果
    if 成功:
        更新完成状态与证据
    else:
        诊断失败原因
        在预算与执行约束内恢复 / 重新规划
    达到预算或无法恢复时，明确记录未完成状态

最终用环境证据验证目标
```

这是导读补充的抽象循环。具体系统可能使用状态机、行为树、LLM 工具调用、VLA 或混合实现。论文中的 Monitoring and Recovery 与 Orchestration 是查找对应方法的入口。

6. 和另外四篇论文的关系

世界模型论文展开 Model 中预测与表征的分支。长时程综述解释 Harness 如何维持跨步骤与跨上下文的一致性。两篇 RSI 论文解释执行反馈怎样变成长期能力更新，以及改进规则自身是否发生变化。

Agentic 执行与 self-improvement 不等价。系统可以在一次任务内不断重新规划，但任务结束后不留下任何能力变化。反过来，一个固定训练流程可能持续更新策略，却没有自主规划与恢复能力。

7. 作者主张、证据与尚未解决的问题

本文的直接贡献是分类、比较与研究议程，不能当作一个已经解决通用机器人问题的实验系统。它讨论的重点包括公平评测、真机部署效率和跨本体泛化。

阅读具体系统案例时，至少记录基础模型、底层执行器、观测权限、重试次数、推理延迟和任务集合。成功率变化可能来自这些因素中的任何一个。即使原文给出模型或榜单比较，也不能脱离其协议外推到其他机器人。

8. 第一遍怎么读

建议先读第 1-10 页的摘要、发展脉络与定义，重点看图 1、图 2、分类总图；随后读 Harness 的第 31-45 页，再看第 46-48 页的展望。只对某个分支感兴趣时，按目录跳读。第 49 页以后的长引用列表可以用于后续选题，不要求通读。

所有页码都是原始 PDF 物理页码。第二遍可以在四领域中任选一类，把两篇代表工作按“输入、改动、验证、成本”做比较。

9. 一个适合初学者的小实验

冻结相同动作策略，在相同任务和种子上比较：固定步骤执行、加成功检查、加成功检查与恢复。报告最终成功率、检测误报 / 漏报、恢复成功率、平均耗时和调用次数。

必须固定策略与观测条件，否则无法知道改善来自 Harness 还是更强的底层模型。该实验是学习建议，不是本文作者的实验或成熟选题结论。

10. 自测

为什么抓取策略很强，收拾整张桌子仍然可能失败？因为任务组织、已完成状态、异常恢复与终止判断也会影响最终结果。

系统多重试了三次，成功率提升，能否说明架构更好？需要计入重试与计算预算，并比较同等预算下的结果。

你应能画出：任务 → Harness → 策略 / 技能 → 控制器 → 环境 → 反馈 → Harness 的闭环。

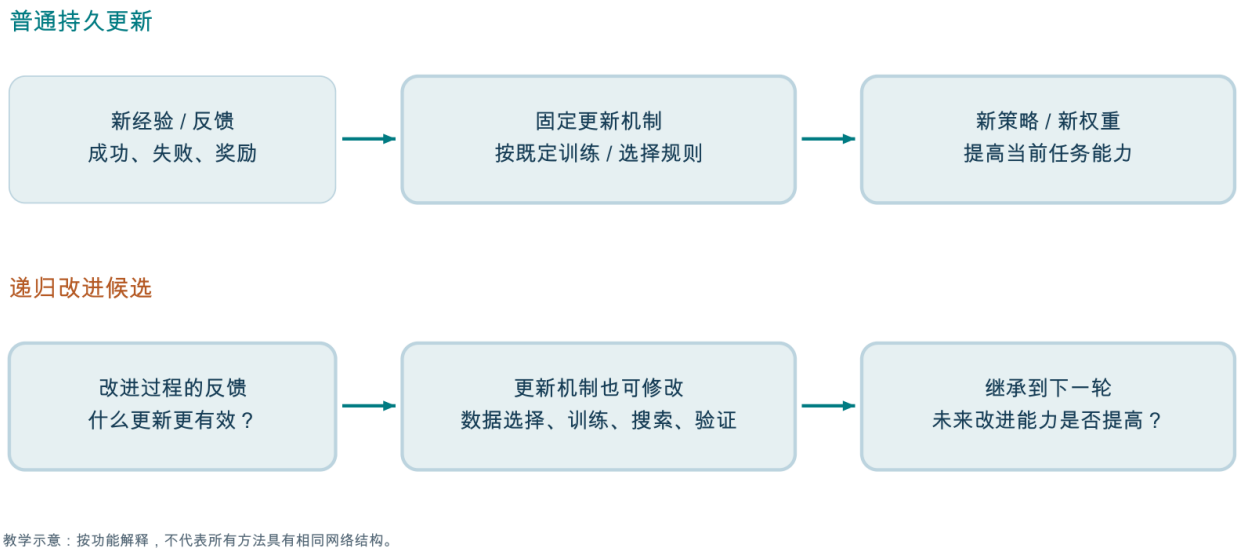
P2：怎样判断真正的递归自我改进

原文：The Last AI Built by Humans: Toward Genuine Recursive Self-Improvement。Yi Duan 等，arXiv:2609.11873v3，2026-09-22，79 页。此版本为预印本。公开记录。

1. 标题是一种研究愿景

图 19 | 策略更新与递归改进：修改的对象不同

教学对照：判断递归还需后续收益、继承与独立验证。



教学示意：按功能解释，不代表所有方法具有相同网络结构。

读图：上排修改策略权重，下排还修改用于改进的规则。下排是递归改进候选；是否真的提高以后改进能力，需要独立证据。训练一次更好模型与递归自我改进不能直接画等号。

“人类构建的最后一个 AI”并不是本文已经证明的事实。它的核心问题是：AI 能否把经验变成持久能力，并且进一步改善未来获得、选择和验证改进的方法？

普通优化使当前系统更好。Recursive Self-Improvement（RSI）要求进一步关注“怎样改进”本身能否被系统修改、继承和再次使用。一次正确回答、一次自我反思、一次性能提升，都不足以单独证明 RSI。

2. 三种变化必须区分

任务内改进：机器人第一次抓空后换一个姿态，最终成功，任务结束后没有留下能力变化。

持久自我改进：系统把“杯子把手会妨碍当前抓取”保存成经验证的技能，后续任务也会使用；或者从真实交互更新策略参数。

递归自我改进：系统发现原有技能更新规则常常把偶发失败当成通用规律，于是修改诊断与验证机制；这个新机制被后续改进轮次实际使用，并使下一批改进更可靠或更有效率。

最后一种变化的对象包含改进机制。它不要求一定修改模型权重，也可能修改验证规则、数据选择、搜索策略或改进流程。是否称为 RSI，还需说明允许自主修改的边界与证据。

3. 本文 B0 与 L1-L5 的自主性路线

层级	自主性的重点	杯子教学例子
B0	In-Task Improvement，任务内改进	当前抓空后重试，能力没有跨任务保留
L1	Improvement Execution，改进执行	按既定配方收集、训练、验证更新
L2	Improvement Strategies，改进策略	根据失败选择补数据、改提示或调训练方法
L3	Future Learning Experience，未来学习经验	自主选择下一批训练任务、探索和课程
L4	Deployment / Environment Adaptation，部署与环境适应	在变化场景中持续诊断、更新并管理持久状态
L5	Meta-Improvement，元改进	修改并继承指导以后改进的机制

这是该论文的分类，不是 P5 的分级。P5 的 L1 是人工改进，L4 才明确表示受限领域内的 RSI，两篇层级编号不能互换。

自主性指哪些决策由系统承担，不是模型参数数量、是否多人协作、自动执行多久，也不代表每项决策完全脱离人类边界。

4. 最有用的阅读工具：追踪一个完整改进循环

每读一个案例，都询问：什么事件触发改进？谁诊断？谁提出修改？谁验证？什么内容持久保存？后继系统如何使用？下一轮的改进机制是否真的改变？

```
版本 x_t = 当前策略、记忆、工具与改进机制
证据 = 执行轨迹 + 失败结果 + 独立检查
候选修改 = 改进机制(版本 x_t, 证据)
在可比条件下验证候选修改
通过后保留新版本 x_(t+1)
下一轮实际使用保留的能力 / 机制
```

这是教学抽象。拒绝的候选、退化和回滚同样需要记录，不能只保留成功故事。

5. 结构递归与有效递归

Structural Recursion 表示改进机制被修改、继承并用于下一轮。Effective Recursion 进一步要求它帮助后续系统产生更好的改进，且比较条件和预算合理。

比如自动修改训练数据选择代码，下一轮确实运行了这份代码，说明结构发生了变化；但如果同样预算下结果没有改善，不能说已经实现有效递归。

尤其需要区分“当前模型得分更高”和“当前系统更擅长创造更好的后继系统”。前者是任务性能，后者是改进能力，评价对象不同。

6. HCI 应该怎样理解

本文用 Headroom-Closed Index（HCI）描述基准剩余提升空间被填补的比例。在稳定协议与可比评分下，简化形式为：HCI = 100 × (当前分数 - 起始基线) / (100 - 起始基线)。

教学例子：起始分数 60，当前 80，满分 100，HCI 为 50，表示相对于起始基线填补了一半可提升空间。这不是“智力达到人类的 50%”，也不是不同任务可以无条件统一比较的证明。

论文还处理来源权重、基准协议家庭与跨年份汇总等问题。图中的后续 RSI 延伸具有示意性质，不能把预测区域当成已经观察到的性能。HCI 本身也不能建立“RSI 导致了性能增长”的因果结论。

第一遍掌握含义和比较条件即可，不必逐项复算全部跨基准数据。

7. 为什么机器人中的 RSI 更难

软件常可重复运行测试、还原版本；机器人碰倒杯子后，恢复代码版本不能把杯子重新放回去。现实交互还有任务重置、人力、硬件磨损和安全约束。

经验是内生的：当前策略决定能到达哪些状态，从而决定下一轮看到的数据。一个只会在容易位置抓取的机器人，可能一直缺少困难状态的学习证据。

失败归因也更复杂。抓空可能来自相机、标定、感知、动作生成、控制或物体性质。若把所有失败都写成“需要重新训练”，更新可能没有触及真正瓶颈。

所以持续学习、世界模型、数据课程、技能库都与 RSI 有关，但它们不自动构成最高层级的递归改进。

8. 读案例时怎样衡量证据强弱

公开演示说明系统可能完成某些任务；可复现实验能说明特定条件下的收益；跨任务、跨多轮、独立验证与预算匹配的结果，才能更有力支持持久改进和递归效果。产业案例与初步实证具有参考价值，但证据强度不应混为一谈。

本文明确讨论自主性归因、持久状态可靠复用和长时程评估。不要只从文章标题推断已经出现无限加速或通用自我进化。

9. 第一遍阅读建议

先读第 3-7 页的动机，第 9-12 页的概念边界，第 12-35 页各层级的开头与总结；再读第 46-49 页的挑战与结论。具身相关可重点看第 74-76 页附近的 Appendix C.2，那里把环境、技能、策略、世界模型与评估器放进同一个改进循环。

第一遍产业案例可以选一两个理解机制，其余作为后续索引。不要花大量时间记公司名。

10. 小实验与自测

学习实验可比较固定改进规则与自适应规则：两者使用相同初始策略、任务划分和总预算，分别统计每轮增益、旧任务退化、人工介入、拒绝更新和最终成本。若要宣称元改进，还应在新任务上冻结并检验学得的改进机制是否有帮助。

你应能回答：变化是否跨任务保留？后继系统是否真正调用？改进机制有没有变？收益能否由更多计算或更强底座解释？独立评价是否避免了反复针对同一测试集优化？

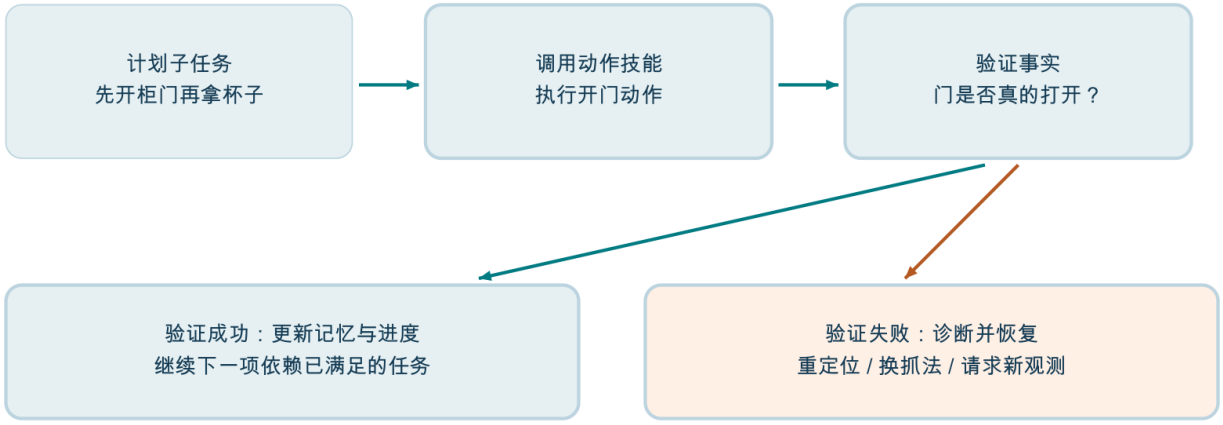
这些问题比“系统是否会反思”更能帮助你判断前沿工作。

P3：长时程 Agent 为什么难

原文：Towards Long-Horizon Agents: A Survey，副标题 Foundation, Evolution, Harness, Optimization, Application, and Frontier。Guanting Dong 等，本次桌面 PDF 共 149 页。作者资源仓库。版本识别以随包原文为准，此处不额外推断未核对的发表状态或 arXiv 编号。

1. Long-Horizon 不只是运行很久

图 17 | 长时程 Agent：记录证据才能正确恢复



教学示意：按功能解释，不代表所有方法具有相同网络结构。

读图：计划中的下一项依赖环境事实被验证。命令已发送不能当作任务已完成；恢复需要知道哪里失败，记忆要记录证据与进度。动作块预测未来，历史记忆总结过去，二者作用不同。

一次搜索等待五分钟，可能没有复杂依赖；两分钟内完成多个互相制约的机器人操作，却可能是困难的长时程任务。本文强调大量耦合的逻辑依赖、持续交互和反馈修正。

它将能力看作 Externalized Harness Engineering 与 Internalized Model Optimization 的共同结果。前者把记忆、工具、工作流和验证放在系统外部；后者通过数据、训练和经验将相应能力内化到策略中。

更多上下文有帮助，但上下文容量不是长期任务能力的充分条件。模型仍可能忽略关键约束、错误总结、目标漂移或在中途提前宣布完成。

2. 从“收拾一个杯子”到“收拾一间厨房”

厨房任务需要先识别物体、腾出空间、处理杯子、清理台面、确认没有遗漏。杯子还可能装水，垃圾桶可能已经满了。一开始的计划并不包含所有情况，系统必须依据新观测更新决定。

已完成子任务不能反复重做，未完成步骤不能在总结中消失，失败也可能破坏后续前置条件。长期任务要求维护状态与依赖，而不仅是一次生成更长的步骤列表。

3. 模型与 Harness 的耦合

作者示意 Agent = π_θ ⊕ H。π 是基础策略，H 是运行支撑框架，⊕ 表示运行时耦合，而不是数字相加。

Harness 汇总：任务 + 历史 + 当前观测 + 检索记忆 + 工具结果
模型根据汇总内容提出下一动作
Harness 检查并执行动作
环境产生变化与反馈
Harness 更新持久状态和工作上下文
继续调用模型

模型看到的上下文通常只是历史的有损摘要，环境观测本身也不完整。因此作者借助 POMDP（Partially Observable Markov Decision Process）描述部分可观测的决策条件。第一遍只需懂“世界真状态和系统知道的状态不同”。

4. 三层任务与能力

H1 / C1 对应单个工作上下文内的多步推理与执行。比如在一次连续会话内完成几个互相依赖的操作。

H2 / C2 对应跨上下文的连续任务与记忆。比如任务执行很久，需要换工作窗口或跨会话继续，却要保留当前阶段、未完成事项和约束。

H3 / C3 对应跨任务经验积累与使用。比如多次收拾厨房后，系统在新的相关任务中调用过去经验证的经验。

这是作者用上下文边界刻画依赖负担的分类。不是按分钟数划分，也不能直接映射成两篇 RSI 的 L1-L5。

5. 三类典型失败

Goal Drift 与 Compounding Error：目标逐渐偏移，局部错误改变后续轨迹。机器人原本要把杯子收进水槽，中途却把“移走杯子”当成完成。

Context Rot 与 Context-Limit Pressure：信息变多后模型检索和使用关键事实的能力下降；摘要又可能删掉尚未解决的限制。某些系统会因感知到上下文压力而过早停止。

Sparse / Delayed Rewards 与 Irreversibility：最后才知道任务失败，难确定哪一步导致；现实动作还可能无法撤销。软件回滚与物理恢复的意义不同。

6. 为什么单步准确率高仍不够

教学计算：如果每步成功概率都是 0.98，且各步独立、任何失败都会导致全任务失败，那么 50 步全成功概率为 0.98^50 ≈ 0.364。这只是说明性模型；真实步骤并不独立，也可能恢复、重试或共享误差。

它提醒我们优化最终轨迹，而非仅看下一动作准确率。检测错误、修复前置条件、检查目标是否真正完成，都可能改变全任务成功率。

7. 外部 Harness 的六类能力

Loops and Workflows 让系统按照执行结构推进任务；Context and Memory 决定当前该看什么、什么跨阶段保留；Tools、MCP and Skills 提供可执行接口和复用能力；Orchestration 组织角色与协作；Hooks and Middleware 在执行前后插入检查；Verification 评估动作、阶段或最终结果。

工作流可以线性、分支、计划执行交替。结构越复杂不一定越好，额外协调会增加成本与新的失败路径。对一个简单任务，明确的状态机可能比复杂多 Agent 编排更可靠。

技能不是“一个名字”。它需要输入、适用条件、前置条件、执行过程和结果检查。pick(cup) 若没有明确坐标约定和成功判断，复用会产生歧义。

8. 记忆应该保留什么

短期工作上下文用于当前决策；持久记忆用于跨窗口或跨任务保留可用信息。二者不能只靠把所有历史塞进去实现。

```
阶段检查点：
  原目标与约束
  已完成步骤及其证据
  尚未完成步骤
  物体 / 工具当前状态
  失败尝试和原因
  接下来需要验证的事实
```

这份模板由导读补充。关键是区分事实、推测和过期信息。昨天记录“杯子在右边”，今天桌子已被重新布置，检索到这段记忆可能反而有害。

评价记忆至少看写入是否正确、检索是否相关、执行时是否使用、最终是否有收益。更多记忆条目不等于更多可靠能力。

9. 内部优化怎样配合外部系统

本文组织的内部优化涵盖架构、数据与环境生成、预训练 / 中期训练、微调、Agent RL、On-Policy Distillation 和 Self-Evolution。第一遍只需理解训练改变策略能力，Harness 改变运行条件，两者需要匹配。

在一种工具接口上训练的策略，换了工具返回格式可能失败；训练时有完整历史，部署只给短摘要，也会产生分布变化。外部机制能够先提供支撑，之后再通过训练内化部分行为，但这不是自动发生的过程。

Credit Assignment 指长轨迹中如何判断哪些决策对最终结果有贡献。中间验证能提供更密反馈，但不可靠的验证器也会引导错误学习。

10. METR 时间趋势要谨慎读

文中引用前沿 Agent 的任务时间跨度趋势。相关时间跨度常用人类完成任务所需时间和某个成功概率阈值定义，且主要来自特定软件或类似任务分布。

它不等于模型能以同样成功率无人干预控制真实机器人多久，也不等于任务平均运行时间。读取曲线时看任务集合、成功阈值、模型与 Harness 设置，以及不确定性。

11. 第一遍阅读建议

先读第 4-14 页的动机、定义、H1-H3 和邻近概念；第 20-36 页重点读记忆、工作流和验证；第 37-55 页先看优化分类，暂跳过大量方法名；第 55-66 页按兴趣看应用与评测；再看第 67-74 页的前沿与结论。第 75 页以后的大量文献主要供后续检索。

本文五类应用包含软件工程、信息搜索、计算机使用、多模态和通用 Agent。具身机器人是需要结合物理反馈重新验证的迁移方向，不能直接从其中的软件成功率得出真机能力结论。

12. 小实验与自测

用固定底层策略完成一个多步骤仿真任务，比较无检查点、结构化检查点、检查点加恢复三种条件。控制任务种子、计算预算与观测权限，记录最终成功、遗漏步骤、重复执行、恢复成本和记忆错误。

你应能解释：为什么长上下文仍可能丢目标？为什么总结会产生新的错误？怎样判断终止是真正完成而非预算耗尽？怎样证明记忆产生了收益而非只是增加模型调用？

P4：世界模型怎样帮助机器人

原文：A Comprehensive Survey on World Models for Embodied AI。Xinqing Li 等，arXiv:2510.16732v3，2026-06-25，23 页。公开记录。这里使用桌面 v3 版本，不把作者的 IEEE 会员称号或稿件格式当作已发表的证据。

1. 先懂一个问题

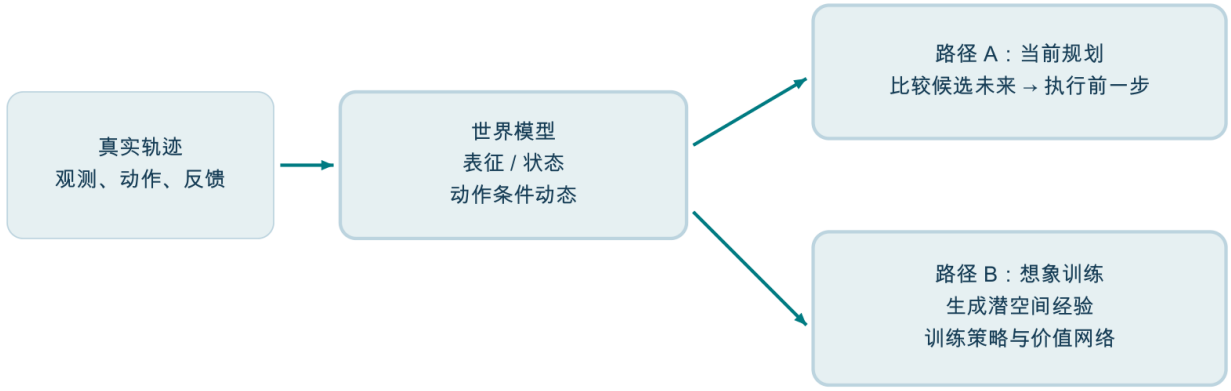
机器人看到杯子，知道可以抓，却未必知道从哪边抓不会碰倒旁边的瓶子。世界模型学习环境怎样随动作改变，让系统能够推演“如果这样做，会发生什么”。本文将其视作支持前向和反事实展开的内部模拟器。

前向预测是“执行这个动作后会怎样”；反事实预测是“若改成另一个动作，后果会不会不同”。要用于机器人控制，预测应与可执行动作有可靠关系，不能只评价生成画面是否像真实视频。

2. 最小数据流

图 12 | 世界模型：两条使用路径

学习动态与利用动态是两件事；图中模块按用途添加。



A 的部署成本来自搜索；B 的成本主要在训练，部署可直接用策略。

教学示意：按功能解释，不代表所有方法具有相同网络结构。

读图：学习动态与使用动态是两件事。当前规划比较候选动作；想象训练更新部署策略。编码器、先验 / 后验、损失与搜索过程在算法详解第 11、12 节展开。

观测 o_t → 编码器 → 潜状态 z_t
潜状态 z_t + 动作 a_t → 动态模型 → 预测潜状态 z_(t+1)
预测潜状态 → 观测 / 奖励 / 价值 / 状态预测
这些预测 → 规划器或策略学习 → 下一动作

这里 z 是压缩表示，可以不是人能够直接解释的物理状态。具体模型可在像素、特征、对象、几何或其他状态上预测，并非都必须使用相同结构。

状态通常部分可观测：杯子被手遮挡后仍然存在，因此模型可能需要历史记忆或 belief state 来表示不确定性。单帧视觉特征不一定足以支持动态预测。

3. 本文三条分类轴

第一轴是 Functionality：Decision-Coupled 与 General-Purpose。前者学习与特定决策目标紧密关联的动态，强调控制与任务效果；后者希望覆盖更广环境和现象，强调可迁移的模拟能力。通用预训练目标与下游控制目标可能不一致。

第二轴是 Temporal Modeling：Sequential Simulation and Inference 与 Global Difference Prediction。前者按序展开未来，便于逐步动作控制，但长时程误差会累积；后者直接 / 并行估计未来状态，能降低长预测的时延，但频繁反馈与细粒度闭环控制可能更难。这里保留作者的原英文分类名，不将其简单改称为“扩散模型”。不同具体方法仍有各自的预测机制。

第三轴是 Spatial Representation：四种表示各有取舍。

表示	可以怎样理解	优势	代价与风险
Global Latent Vector	把环境压成紧凑向量	推演效率高	细致空间信息可能不足
Token Feature Sequence	用多个特征 token 表示场景	多模态、局部结构与注意力交互	计算和数据成本较高
Spatial Latent Grid	用 BEV、体素等有空间位置的网格	几何邻接、多视角融合与地图式规划	内存、分辨率及适应性取舍
Decomposed Rendering Representation	用 NeRF、3DGS 等可渲染结构表示	几何一致性和可控渲染	动态、接触、拓扑变化仍具挑战

三条轴可以组合。不要把“全局预测”误认为“一定使用全局向量”；一个描述时间建模，一个描述空间表示。

4. 为什么不一定需要预测每一个像素

对抓杯子来说，杯子位置、姿态、是否接触夹爪，可能比桌面纹理更重要。潜空间模型希望把计算集中在有用信息上；像素生成模型则提供直观且丰富的未来观测，但也可能在与任务无关的细节上花费算力。

Dreamer 系列是理解基于模型学习的代表入口：学习潜空间动态，在模型想象的轨迹中优化行为。RSSM（Recurrent State-Space Model）结合确定性记忆与随机状态，用来表达时间信息和不确定性。第一遍不要求推导所有损失，只需明白世界模型和策略承担不同功能。

JEPA 类方法强调预测表征而非逐像素重建。3D / 几何方法强调空间一致性。视频生成方法强调丰富的未来外观。这些目标相互联系，但不能互相替代。

5. 教学例子：预测得像，不等于抓得好

假设两套模型预测杯子抬起后的画面。A 的纹理漂亮，但误判夹爪没闭合时杯子也会上升；B 的纹理模糊，却正确预测抓空、滑落与碰撞。A 可能在视觉指标上占优，B 却更有利于动作选择。

因此要分层评价：像素预测质量、状态 / 几何理解、动作条件与物理一致性、最终任务效果。PSNR、SSIM、FVD 等指标有各自适用范围，不能单独证明模型具有可靠的物理理解。

本文正是将数据与指标跨机器人、自动驾驶和一般视频任务组织起来，并指出应更加重视物理一致性、实时效率和长预测可靠性。

6. 滚动规划与想象训练

世界模型的两种使用方式要区分。规划是在当前时刻比较候选动作，然后执行第一步再观测。想象训练是在模型生成的经验上改进策略，随后让策略直接执行。二者可组合，也具有不同误差路径。

```
滚动规划示意:
  z = 根据真实观测更新当前状态
  对候选动作序列 A:
    预测未来状态 = rollout(world_model, z, A)
    score = 目标价值 - 风险 - 动作成本
  执行最高分序列的第一步
  用新观测纠正预测，再规划
```

这是导读补充的 MPC 风格示意。模型预测准确并不足以保证控制安全，尤其涉及分布外动作、接触和未知障碍时。

7. 长预测误差为什么会累积

一步预测偏一点，下一步把偏差当作输入，后续误差可能扩大。一个说明性的关系为 $e_{t+1} \le L\, e_t + \varepsilon$：$\varepsilon$ 是新引入的预测误差，L 表示动态对误差的放大敏感度。它是教学示意，不是本文证明的普适误差界。

杯子接触桌沿时，小位置误差可能改变“稳放”与“跌落”的结果。相较平滑运动，接触、不连续事件和遮挡更难。重新观测可减轻累积，却受到感知质量和推理延迟限制。

8. 和 Agentic / RSI 的连接

Agent 可调用世界模型比较方案，或利用预测发现危险。但世界模型通常不负责完整任务管理。持续改进系统还能用真实失败更新世界模型，再利用改善的模型生成训练经验。

这也产生反馈风险：错误模型生成错误数据，策略学到错误规律，再产生偏置经验。因此需要真实或独立证据检验合成经验的有效性。模型与策略共同更新不自动构成递归自我改进，要看改进机制自身是否更新并帮助以后改进。

9. 第一遍阅读位置

先读第 1-3 页的动机、背景与三轴分类，尤其第 3 页图 1；用第 4 页表 I 找三种感兴趣的代表工作。随后按正文标题跳读 Data and Metrics、Performance、Challenges and Trends。不要第一遍逐行通读大型模型清单。

第二遍选择一个对照：潜空间与像素预测、序列与全局预测、2D token 与空间网格。比较时控制动作条件、数据规模和部署频率。

10. 小实验与自测

冻结同一策略 / 规划器，比较不用世界模型、使用模型筛选动作、使用更长预测时域三种条件。记录任务成功、碰撞、预测误差、总推理耗时。该建议用于学习，不代表已验证能形成论文贡献。

你应能回答：世界模型的输入是否包含动作？预测的是像素还是表征？预测目标与控制目标是否一致？推演时会不会走到训练未覆盖的状态？最终收益是否超过额外计算成本？

如果能回答这些问题，你已经可以开始阅读代表方法，而无需先理解所有模型代码。

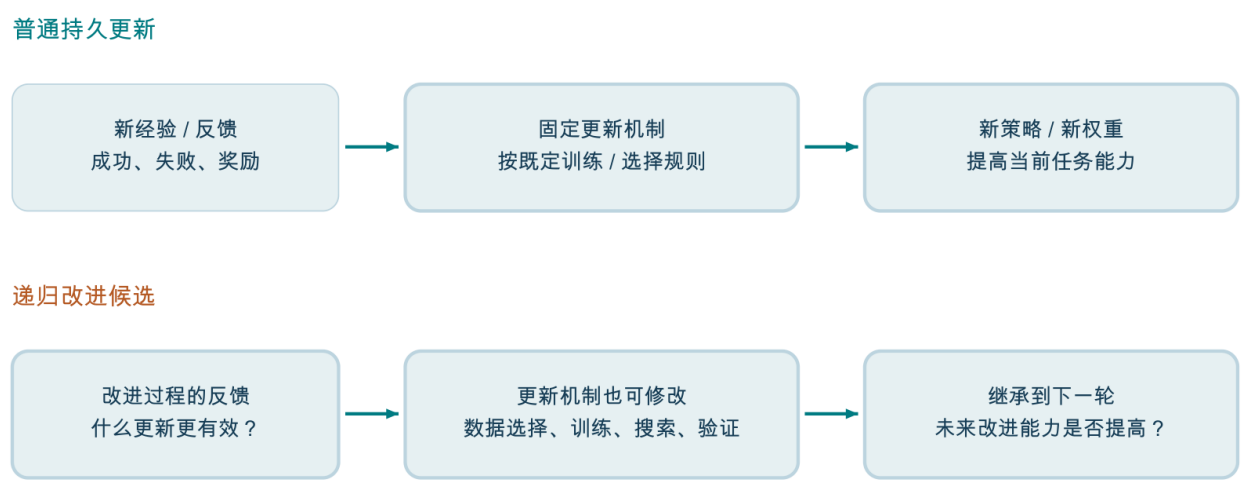
P5：把整个 Agent 系统作为改进对象

原文：The Path to Recursive Self-Improving Agents: Foundation, Framework, and Future Directions。Shuaiqi Liu 等，桌面文件共 70 页。公开记录为 Preprints.org，2026-08-03，DOI: 10.20944/preprints202608.0051.v1。论文记录。此记录是预印本，页面上的 Review 是文章类型，不等于已完成同行评审。

1. 先掌握五个组件

图 19 | 策略更新与递归改进：修改的对象不同

教学对照：判断递归还需后续收益、继承与独立验证。



教学示意：按功能解释，不代表所有方法具有相同网络结构。

读图：新数据更新策略只是持久学习；如果负责采样、优化或验证的机制也被修改并继承，才需要进一步讨论递归。不能只看到循环箭头就判断系统已达到有效递归。

本文把系统状态写为 x_t = (M_t, H_t, D_t, T_t, Imp_t)。与只盯着模型权重相比，它把数据、运行框架、训练器和改进机制一起放入分析。

组件	作用	机器人教学例子
M：Foundation Model	提供参数化的理解、决策或动作能力	基础模型或动作策略
H：Agent Harness	组织上下文、工具、技能和执行	调用抓取技能、记录进度、检查结果
D：Agent Data System	将轨迹和反馈变成训练 / 评价资料	收集失败、筛选轨迹、生成课程
T：Agent Trainer	将数据与学习信号变成持久参数更新	BC、RL 或其他优化流程

组件	作用	机器人教学例子
Imp：Improvement Mechanism	决定诊断、提出、验证和整合什么修改	判定瓶颈并选择数据、框架或训练改动

Imp 是“改进过程的决策与规则”，不能简单等同于优化器。T 中某个训练算法可能被 Imp 修改，但两者的职责不同。

2. 为什么组件必须一起看

假设图像归一化改变了，模型仍按旧分布解释视觉输入；或 Harness 改了动作单位，控制接口没有更新。局部组件看起来更好，整个系统却可能更差。

另一个例子：补充了更多抓取演示，机器人仍抓偏，真正问题是相机到基座的变换错误。若改进机制只允许训练模型，无法解决这个瓶颈。

因此本文不仅关心更新哪个组件，也关心组件的依赖、接口一致性和系统层面的结果。

3. 四阶段循环

Diagnose：根据端到端表现、模块状态、接口和反馈定位瓶颈。

Propose：提出一个或多个候选修改，明确目标组件与具体变化。

Evaluate：检查性能、成本、兼容性和适用条件，筛选候选。

Integrate：将通过验证的修改整合为新版本，并保证后续仍可使用。

```
证据 = 当前系统的轨迹、结果、接口检查与预算记录
瓶颈 = Diagnose(x_t, 证据)
候选 = Propose(x_t, 瓶颈)
对候选进行隔离评估、回归检查和独立检验
接受的修改 → Integrate → x_(t+1)
保留修改依据、版本与使用条件
```

这段代码是教学示意。真实系统并不保证每轮都提升；回归、拒绝和无效更新都是改进研究需要报告的结果。

4. 本文 L1-L5 的标准

层级	本文名称	必须理解的区别
L1	Manual Improvement	系统修改来自外部人工开发与部署
L2	Assisted Improvement	系统提供建议 / 诊断，人负责实质验证与应用
L3	Programmatic Self-Improvement	系统自主提出、应用、验证组件修改，Imp 固定或外部维护
L4	Bounded Recursive Self-Improvement	连 Imp 也能作功能性修改，并在受限领域长期使用
L5	General Recursive Self-Improvement	改进机制的能力可跨广泛且变化的领域有效迁移

“功能性修改”意味着影响后续改进过程，不能仅仅改注释或文件名。L5 的 generality 指递归改进能力的跨领域通用性，不只是当前策略能完成很多任务。

5. 与 P2 分级为什么不能混用

P2 围绕自主权范围展开：执行、策略、经验、环境适应、元改进。P5 围绕人工介入、组件自主更新、Imp 是否可改及跨领域迁移划分。两者回答的问题相近，但坐标不同。

例如 P2 的 L1 强调自主执行既定更新；P5 的 L1 却是人工改进。P2 的 L5 强调元改进；P5 的 L4 已要求受限领域内修改 Imp，L5 更进一步要求跨领域的递归改进泛化。

所以记录文献时应写“P2-L3”或“P5-L3”，并附定义。无法仅靠编号给一个实际系统自动定级。

6. Harness 可以在不改权重时进化

本文把记忆、技能 / 工具、提示 / 上下文、编排 / 架构和自引用代码修改放入 Harness 自我改进研究。改变这些组件也可能改变能力，不必每次重新训练基础模型。

例如机器人把经验证的恢复策略写入技能库，后续遇到相同失败便能调用。若技能写错、检索错或使用条件变化，它又可能导致退化。持久记录必须有来源、适用条件和结果证据。

“保存更多经验”与“形成更可靠的可复用知识”是两件事。阅读记忆方法时，不只看条目数量，也看写入、检索、调用和任务收益。

7. 数据与训练器也能成为改进对象

D 连接运行中的轨迹与后续学习。它可以包含环境生成、任务生成、课程、轨迹筛选与评价证据。数据产生和数据利用需要共同设计：收集大量相似简单轨迹，可能不能弥补困难状态的缺口。

T 将数据与反馈转换成更新。修改监督信号、奖励、优化策略、训练基础设施会改变训练结果，但仍需看谁作决定，以及 Imp 是否固定。

传统固定配方下的持续训练可归为程序化自我改进的一种情况。它具有价值，但没有因此自动获得“改进改进机制”的能力。

8. 真正的递归在哪里

普通循环：Imp_fixed 每轮根据相同规则更新 M 或 H。递归循环：Imp 自己也是状态的一部分，系统可以提出 Imp_new，通过验证后让后续轮次使用新的改进方式。

杯子教学例子：旧 Imp 见一次失败就增加一条技能。新 Imp 先判断失败是否可重复、是不是标定问题，再决定改技能还是修接口，并要求在未参与生成的任务上验证。改变的是以后更新的决策规则。

然而把这个过程写进代码不等于已经证明它有效。必须检验新规则在新任务、多个轮次和相同总预算下是否改进可靠性或效率。

9. 怎样评价“持续进化”

至少分开观察当前任务得分、旧任务保留、更新被实际复用的比例、后继系统质量、总资源消耗，以及改进机制的迁移效果。

如果系统反复用同一测试集选择修改，测试集会逐渐变成优化目标。更好的分数可能来自适应测试集，而非一般改进能力。因此需区分开发评价与独立测试，并报告预算、失败、版本轨迹和停止条件。

复杂的多组件协同也需要归因：固定其他组件，只修改一个模块；再比较联合改动。否则不能说清收益来自哪里。

10. 第一遍阅读建议

先读第 1-3 页与图 1；第 5-9 页精读五组件、L1-L5 和四阶段过程，尤其第 7 页表 1。随后从第 3、4、5 节分别选 Harness、Data、Trainer 的一个分支，看第 6 节如何协同改进，最后读第 7 节开放问题。

第 4 页的大分类图和后面大量方法表适合检索，不需要第一遍记完。按“改什么、证据是什么、规则是否固定”整理三篇代表作即可。

11. 与具身选题的连接

较容易切入的方向是失败驱动的数据选择、技能与记忆更新、恢复机制、评估器一致性，而不是立即让机器人自主修改所有代码和训练方法。

选择一个固定策略和仿真任务，先搭建可记录、可比较的改进循环。明确任务分布、可修改组件和证据边界后，才讨论更高层递归。这样的研究起点更容易解释结果。

12. 自测

固定程序每晚自动训练一次新模型，属于真正 RSI 吗？仅凭这件事不能，需看 Imp 是否自主作功能性改变并被继承。

模型能做十类任务，说明 P5-L5 吗？不能，L5 需要改进能力在广泛变化领域中的有效迁移。

怎样判断更新有意义？看它是否触及真实瓶颈，在独立可比条件下产生收益，并被后续系统可靠使用。

四篇补充综述：拓宽具身研究视野

你已经有五篇系统、世界模型、长时程与 RSI 综述。补充阅读的价值是补齐基础模型、动作学习、数据评测、几何感知，而不是继续增加高度重叠的 Agent 清单。

四篇原始 PDF 和逐页中文翻译均随包提供。选择依据是问题覆盖、分类与机制解释、公开原文可核对，以及与现有材料的互补性。两篇可从原文核对正式发表信息；另外两篇按本次获取的预印本版本使用。发表平台不是质量的唯一标准，也不能把“新”自动等同于“更可靠”。

1. 选择与阅读优先级

标识	论文	年份 / 版本信息	为什么选	建议顺序
S1	Foundation Models in Robotics: Applications, Challenges, and the Future	arXiv:2312.07843v1，2023，33 页	从感知、规划、学习到具身系统的完整地图	先读，帮助建立宽度
S2	A Survey on Vision-Language-Action Models for Embodied AI	首次提交 2024；本次下载 54 页作者版本，原文注明 TNNLS 发表与 DOI	将 VLA 拆为组件、低层策略与高层规划	理解策略后阅读
S3	Vision-Language-Action in Robotics: A Survey of Datasets, Benchmarks, and Data Engines	arXiv:2604.23001，2026，17 页	直接补足数据来源、合成与评价协议	与任何模型研究配合
S4	Past, Present, and Future of Simultaneous Localization And Mapping: Towards the Robust-Perception Age	TRO 2016；arXiv:1606.05830v4，25 页含封面	补足空间估计、地图、鲁棒性与长期自主	拓宽到导航 / 几何时阅读

S1 与 S4 是建立机制与脉络的材料，不用于判断 2026 年最新排行榜。最新动态应结合 P1、P4、S3 的本次版本与具体方法论文核对。

2. S1：基础模型可以放在机器人哪里

公开记录：arXiv:2312.07843。Roya Firoozi 等，本包保存 v1。

核心问题

Foundation Model（基础模型）并不是某一种机器人控制器，而是经过广泛数据训练、能够支持多种下游任务的模型。它可以提供视觉特征、语言理解、规划、奖励、场景表示和行为先验。

这篇综述将基础模型背景、机器人学习与决策、感知、具身 AI 和挑战串起来。它的价值是帮助你画出系统中各类模型的位置，避免把“机器人使用大模型”只理解为端到端 VLA。

杯子例子

图文模型帮助找到“杯子”；几何 / 场景表示帮助确定位置；语言模型分解“清理桌面”；动作策略控制抓取；学习型评价器辅助识别完成。它们输入输出不同，可以模块化，也可以在某些结构中联合训练。

关键区别是 semantic knowledge 与 physical grounding。知道“杯子通常可以拿起”，不等于知道当前杯子是否粘在桌上、装了多少液体或能否被这个夹爪稳定抓住。

数据流伪代码

```
目标对象 = 语言与视觉模型识别(任务, 图像)
空间状态 = 感知与几何模块估计(图像, 深度, 身体状态)
子任务 = 规划器(目标, 空间状态, 可用技能)
动作 = 策略(子任务, 最新观测)
执行并用环境证据验证
```

这不是某一个作者系统的实现，而是将综述分支连接起来的教学图。

主要取舍

预训练知识能减少每个新任务从零学习的成本，但机器人数据与互联网数据在动作、反馈、精度和物理后果上不同。冻结模型省算力，可能限制适应；微调改善特定任务，又需要合适数据且可能损失泛化。

模型的“知道”与“能做”之间仍需要执行接口、训练经验和评价。开放词表感知的成功，不直接意味着开放世界操作的成功。

第一遍读哪里

第 3 页看动机；第 4-8 页按需了解术语；第 8-16 页看机器人策略、规划和开放词表任务；第 16-21 页看感知与可供性；第 23-27 页看挑战。第一遍可跳过细致架构背景与大量引用。

读完写下三个不同位置的基础模型，分别说明它们的输入、输出、失败方式。自测：为什么识别出杯子仍不能完成抓取？答案应包含空间、动作、接触与执行约束。

3. S2：VLA 不只是一张大网络图

公开记录：arXiv:2405.14093。Yueen Ma 等。原文注明正式发表在 IEEE Transactions on Neural Networks and Learning Systems，DOI：10.1109/TNNLS.2025.3650584。随包的是作者版本，不能代替最终期刊排版。

核心问题

本文分三条研究线：VLA 的组成组件、预测低层动作的控制策略、分解长任务的高层规划器。它适合回答“视觉、语言、动作分别怎么进入模型，以及低层执行与高层组织如何连接”。

有些文章将 VLA 用作较宽的概念，包含高层规划分支；较窄用法则强调从视觉语言到机器人动作。阅读时先看作者定义，不要求所有文章使用同一边界。

动作表示决定什么

动作可以离散为 token，也可以通过扩散或 Flow Matching（流匹配）等机制生成连续动作。离散化涉及精度、序列长度和自回归时延；连续生成涉及生成成本、分布表达与执行频率。

例如要把夹爪移动 3 毫米，动作表示的量化或单位会影响精度；生成十步动作块，执行时是否频繁重观测会影响反应能力。不同动作头不只是换一个输出层，它会影响训练目标与部署方式。

语言为什么有用

同一张桌子图像，“拿红杯子”与“把所有杯子收起来”要求不同动作。语言条件帮助任务选择和语义泛化。模型仍需要实际动作经验，才能把指令与机器人可执行行为连接。

相同句子在不同机器人上也需要不同动作：夹爪、灵巧手、单臂、双臂之间存在本体差异。跨本体泛化涉及观察接口、动作空间和行为语义，不能只靠共享语言输入完成。

教学伪代码

```
训练样本 = 图像历史 + 语言目标 + 身体状态 + 专家动作块
视觉语言表示 = 编码器(图像历史, 语言目标)
动作分布 = 动作头(视觉语言表示, 身体状态)
按照所选生成机制计算学习目标并更新
部署时将生成动作转换到实际控制接口
```

这只是通用接口示意。具体模型是否使用历史、怎样编码身体状态、是否冻结主干，都需看方法。

如何判断泛化

分别检验未见对象、未见指令表达、未见场景、未见任务组合和未见本体。某一个维度提高不说明所有维度都解决。避免把“可以换一句提示”当成“可以执行任意新任务”。

第一遍读哪里

第 1-3 页看背景与分类；第 3-11 页选两种低层动作策略；第 12-14 页看 Task Planners；第 15-17 页看资源、挑战与结论。其后长参考文献用于查找方法，不需要通读。

读完比较 ACT、Diffusion Policy 和一个 VLA 的任务条件、动作表示、训练数据及执行接口。自测：大模型为什么仍需要机器人数据？答案应说明网络知识缺少与具体执行器关联的动作反馈。

4. S3：数据与评价可能决定模型上限

公开记录：arXiv:2604.23001。Ziyao Wang 等，2026-04-24，17 页预印本。作者资源仓库。

核心问题

本文围绕 Datasets、Benchmarks、Data Engines 三个支柱，主张把高质量数据引擎和结构化评测共同作为研究对象。这是作者的研究判断，不是已经证明模型架构不再重要。

Dataset 是已有经验，Data Engine 是持续产生 / 筛选 / 标注经验的过程，Benchmark 是检验能力的协议。三者相互影响：数据覆盖影响策略，失败评测指导数据引擎，数据引擎又改变下一轮训练分布。

数据从哪里来

真机演示有真实接触与执行信息，但成本高；仿真便于规模化、自动标注和重置，却有 Sim2Real Gap；人类视频覆盖广，但通常缺少机器人动作与精确接触信息；视频重建与合成可以桥接部分缺口，物理一致性仍需验证。

不是轨迹数量越多越好。相同位置的一万条成功演示，可能不如覆盖遮挡、抓空恢复、不同形状的一千条有用。质量、覆盖、多样性、失败信息、跨本体对齐都值得考虑。

杯子例子：训练测试重叠

若训练和测试都来自同一桌面布局、相同物体位置或重复轨迹，成功率可能高估泛化。应说明划分单位：按轨迹随机分，按对象分，按场景分，还是按任务组合分？

一次“整理杯子”的成功也可能来自测试重置时夹爪已经靠近目标。重置方式、可见真值、人工干预和重试预算都属于协议，不能只报告模型结构。

数据闭环伪代码

```
在独立条件中评估当前策略
将失败按感知、动作、恢复和任务组织分类
选择最需要补充的状态 / 任务
采集或生成候选轨迹
验证时间同步、动作语义、物理有效性与覆盖
用于训练；在未参与选择的测试集上重新评价
```

这里最容易混淆的是“用测试集指导训练”与“独立测量泛化”。开发集可用于选数据，最终测试集应保留独立用途。

本文的四类开放问题

Representation Alignment、Multimodal Supervision、Reasoning Assessment、Scalable Data Generation。分别关心不同数据 / 本体怎样对齐，怎样利用多种监督，怎样评估推理和组合能力，以及怎样可扩展地产生有效经验。

这些问题与 P1 的 Data、Environment，以及 P5 的 D 高度关联。但 S3 从具身数据与评价切入，能帮助你把抽象自我改进落到具体资料与协议。

第一遍读哪里

第 1-3 页建立定义，第 4-5 页看数据，第 6-7 页看基准，第 8-10 页看数据引擎，第 11-12 页看开放问题。全文正文相对短，适合完整读一遍。

一个低门槛实验是固定 ACT，比较等量数据下的简单采样与覆盖困难状态采样。先控制轨迹数量、训练预算和测试划分，再讨论数据配方的作用。

5. S4：SLAM 为什么仍然值得读

公开记录：arXiv:1606.05830。Cesar Cadena 等，IEEE Transactions on Robotics 32(6):1309-1332，2016，DOI：10.1109/TRO.2016.2624754。本包为 v4，第一物理页是引用封面，因此 PDF 物理页码比正文印刷页码多 1。

核心问题

SLAM（Simultaneous Localization and Mapping）同时估计“我在哪里”和“世界地图是什么”。机器人移动时，如果自己的位置估计错了，即使任务语义正确，也可能走错门或把目标投影到错误坐标。

这篇经典综述覆盖系统结构、长期鲁棒性、规模、几何与语义表示、主动 SLAM 和新传感器 / 学习。它是空间估计与长期自主的机制教材，不是当前视觉语言导航的最新榜单。

前端与后端

前端从传感器提取并匹配信息，建立运动或位置约束；后端结合约束优化轨迹与地图。Loop Closure（回环检测）判断机器人是否回到旧地点，用旧新观测约束减轻累计漂移。

```
新图像 / 点云 → 提取与关联特征 → 产生运动约束
约束 + 历史地图 → 后端优化 → 更新位姿与地图
若识别到曾经到过的位置 → 加入回环约束 → 全局调整
```

回环可能误识别：两个相似走廊不一定是同一个地方。错误回环会使地图变形，说明“有更多约束”不总是更好。

地图需要表示什么

Metric Map 关注几何位置、结构和可运动区域。Semantic Map 进一步表示房间、物体类别和关系。目标导航需要语义，精确避障和定位需要几何，两者可以结合。

语言模型说“厨房在客厅旁边”，不能替代当前环境中的几何定位；世界模型预测未来图像，也不一定提供可靠地图。不同能力可互相补充，但训练目标与误差性质不同。

长期自主为何困难

动态物体、光照、季节、地图规模、重复结构、传感器故障与不同观测视角都会带来问题。机器人持续运行，需要判断什么时候旧地图仍适用，什么时候应更新或重新定位。

Active SLAM 进一步考虑主动选动作以改善定位和地图，例如为了消除遮挡而换一个视角。动作不只服务任务，也可服务信息获取，这与具身交互的核心思想相通。

第一遍读哪里

PDF 第 2-5 页看引言与系统结构，第 6-9 页看鲁棒性与规模，第 10-13 页看几何 / 语义地图，第 15 页看 Active SLAM，第 18 页看结论。其他理论部分可在决定深入几何后阅读。

自测：地图和世界模型有什么区别？地图强调当前 / 已知空间结构与定位，世界模型强调状态随动作的变化；二者在某些方法里会融合，但不能根据名字就认为功能相同。

6. 从综述到一个可深入的方向

兴趣	先继续读的代表入口	第一轮只追踪什么
动作学习	ACT、Diffusion Policy	一条样本的动作块、归一化、训练目标、执行频率
大型 VLA	OpenVLA、openpi	输入接口、动作表示、微调数据与部署反归一化
潜空间世界模型	DreamerV3	编码、动态预测、想象轨迹与策略更新
数据 / 评测	RoboTwin、robomimic	轨迹字段、划分、任务重置与成功判断
几何与定位	ORB-SLAM3	数据关联、位姿约束、回环与评价轨迹
Agent 恢复 / 记忆	从 P1 的 Monitoring and Recovery 或 P3 的 Context and Memory 选一个方法	失败检测、状态写入、检索、调用和独立验证

这里只是后续方法 / 代码入口，未要求当前安装或运行，也没有将链接对应方法额外当作已翻译综述。

第一轮深入可以只回答：一条数据怎样被读取，模型究竟输出什么，输出怎样执行，最后怎么判定成功。第二轮再读损失、优化和关键实现。确定具体方向前，不需要把所有仓库逐行看完。

7. 怎样理解前沿发展脉络

一个有用的研究脉络是：传统几何与控制提供可执行基础；模仿学习与 RL 学习行为；基础模型提供广泛语义与表征；VLA 把知识连接到动作；世界模型帮助预测与规划；Agent 系统组织长期执行；持续 / 递归改进研究跨任务和跨轮次的能力积累。

这不是整齐的线性替代史。它们在真实系统中长期共存，数据与评测贯穿每一层。当前值得追问的研究问题包括：预测能否带来实际控制收益、长任务如何可靠恢复、跨本体数据怎样对齐、独立评测能否解释真实泛化、持续更新怎样避免遗忘与错误继承。

把这些问题与你能获得的实验条件结合，比单纯追逐最新模型名字更容易找到可以深入的方向。

具身智能与 Agent：术语速查

以下是阅读本包时建议保持一致的译法。相同术语在不同论文中可能有不同边界，最终以作者定义为准。中文全文初稿已对常见短语施加固定译法约束；本表还补充缩写解释。2026-10-23 更新：常用缩写附英文全称；数据、算力和研究工具的更多全称见 09 补充工具地图。

1. 系统与任务

英文 / 缩写	中文	理解要点
Embodied Artificial Intelligence（Embodied AI）	具身智能	通过身体感知与行动，与环境交互
Embodiment	本体 / 具身载体	身体结构、传感器和动作接口影响能力
Agent	智能体	依据观测和目标进行交互决策的系统
Agentic Robots	智能体式机器人	组织目标执行、反馈、恢复和能力使用
Policy / π	策略	从可用信息到动作或动作分布的映射
Observation / o	观测	传感器或接口提供的信息，不等于真实状态
State / s	状态	建模世界与身体的相关变量
Proprioception	本体感知	关节、速度、执行器等身体信息
Trajectory / Episode	轨迹 / 一次任务记录	时间序列，可能包含观测、动作、奖励、终止
Manipulation	操作	用机械臂、手等改变物体与环境
Locomotion	运动 / 行走	移动机器人身体，维持稳定与跟踪目标
Long-Horizon	长时程	大量相互依赖的决策与交互，不能只按时长定义

2. 学习与模型

英文 / 缩写	中文	理解要点
IL：Imitation Learning	模仿学习	从示范行为学习
BC：Behavior Cloning	行为克隆	用专家动作作为监督标签
RL：Reinforcement Learning	强化学习	通过交互奖励优化长期行为
SFT：Supervised Fine-Tuning	监督微调	使用监督数据进一步调整模型
PPO：Proximal Policy Optimization	近端策略优化	一类策略梯度优化方法
VLM：Vision-Language Model	视觉语言模型	处理图像与语言，不自动提供机器人动作
VLA：Vision-Language-Action	视觉语言动作模型	连接视觉、语言与动作，具体边界依作者定义
ACT：Action Chunking with Transformers	Transformer 动作分块	用条件序列模型预测动作块
CVAE：Conditional Variational Autoencoder	条件变分自编码器	用潜变量建模条件数据分布
Diffusion Policy	扩散策略	通过条件去噪生成动作序列
Flow Matching	流匹配	学习使样本沿连续流变化的向量场
Action Chunking	动作分块	一次预测多个未来动作，执行方式需另行定义
Foundation Model	基础模型	广泛预训练、支持多种下游任务的模型
World Model / WM	世界模型	捕捉环境动态，支持未来和反事实预测
World-Action Model / WAM	世界动作模型	将世界预测与动作生成结合，定义不完全统一
Latent State / z	潜状态	压缩后的状态表征，未必直接可解释
RSSM：Recurrent State-Space Model	循环状态空间模型	结合时间记忆与随机状态的动态模型
JEPA：Joint Embedding Predictive Architecture	联合嵌入预测架构	预测表征，通常不以逐像素重建为唯一目标
Rollout	轨迹展开	在真实环境或模型中执行 / 推演多步
Counterfactual	反事实	询问换成另一个动作会产生什么后果
Credit Assignment	贡献归因	判断长轨迹中哪些决定影响最终结果

3. 控制、几何与感知

英文 / 缩写	中文	理解要点
FK：Forward Kinematics / IK：Inverse Kinematics	正 / 逆运动学	关节到末端位姿 / 末端目标到关节解
Pose	位姿	位置与朝向
DoF：Degrees of Freedom	自由度	独立运动变量的数量
End-effector	末端执行器	夹爪、手、吸盘等执行部件
PID：Proportional-Integral-Derivative	比例积分微分控制	利用误差与其历史变化控制
MPC：Model Predictive Control	模型预测控制	反复优化未来序列，执行部分后重规划
WBC：Whole-Body Control	全身控制	协调身体多个部位的运动和约束
SLAM：Simultaneous Localization and Mapping	同时定位与建图	同时估计自身位置与地图
Loop Closure	回环检测	识别重访地点并添加约束
Affordance	可供性 / 可操作性	环境与身体条件下可实现的交互方式
Grounding	落地关联	将语言 / 表征与具体环境、动作或事实关联
BEV：Bird’s-Eye View	鸟瞰表示	用俯视空间网格表达场景
NeRF：Neural Radiance Fields	神经辐射场	可渲染的连续场景表示
3DGS：3D Gaussian Splatting	三维高斯泼溅	用三维高斯元表示并渲染场景

4. 数据、评价与持续改进

英文 / 缩写	中文	理解要点
Teleoperation	遥操作	人通过接口控制机器人并记录经验
Simulator	仿真器	执行动作并产生新状态与观测
Dataset	数据集	已记录下来的经验
Benchmark	基准 / 评测协议	任务、划分、评分、预算与执行条件
Data Engine	数据引擎	持续产生、处理和筛选经验的过程
Sim2Real / Sim-to-Real	仿真到现实	策略或方法从模拟环境迁移到真实环境
Domain Randomization	域随机化	训练时变化视觉与物理等条件
Harness	运行支撑框架	上下文、工具、记忆、工作流、检查等运行机制
Orchestration	编排	组织工具、技能、角色与执行依赖
Skill	技能	可复用能力及其接口、条件和执行过程
Verification	验证	用适当证据检查行为或结果
Continual Learning	持续学习	学习新经验同时保留旧能力
Catastrophic Forgetting	灾难性遗忘	更新新任务后丢失旧能力
RSI：Recursive Self-Improvement	递归自我改进	改进机制自身成为可修改、继承的对象
Meta-Improvement	元改进	改善以后寻找、选择或验证改进的方法
HCI：Headroom-Closed Index	剩余提升空间闭合指数	相对起始基准的可提升空间被填补的比例

5. 最容易混淆的五组

策略与世界模型：策略选择动作，世界模型预测动态；有些联合模型将两者结合。

VLM 与 VLA：前者处理视觉语言，后者与动作关联；是否直接生成低层指令需要核对定义。

长上下文与长时程：一个描述容量，一个描述复杂依赖与持续执行。容量增加不保证记忆、恢复或正确终止。

持久改进与递归改进：前者留下能力变化，后者还要求改进机制本身的功能性变化与继承。有效递归需要进一步证明以后改进能力提高。

P2-L1-L5 与 P5-L1-L5：P2 以自主权范围组织，P5 以人工介入、程序化更新、Imp 修改与泛化组织。务必附论文名和定义，不能只写编号。

6. 学习笔记推荐记法

首次出现写“世界模型（World Model，WM）”，后续使用 WM 或世界模型。保留论文、模型、数据集和基准的英文名称，方便检索。遇到翻译不顺或数学表达不清，立即根据译页标注回到原文，并在笔记里记录原词而不是继续猜测。

新手研究工具地图：数据、算力、榜单与世界模型

补充于 2026-10-23。目标是读懂论文与项目介绍，知道实现一个功能需要哪些内容。本文的工程配置、计算和杯子例子是教学说明，不是已经运行的实验。项目接口、榜单规则和硬件支持会变化，实际使用时核对链接中的官方文档。

推荐把这一章插在仓库入门导读之后，再读五篇论文。第一次先看第 1、2、4、7 节；需要选数据或做实验时查第 3、5、6、8 节。不要一次记住全部名字。

1. 先分清研究中六种不同的“东西”

名称	提供什么	收拾杯子的例子
Dataset，数据集	已记录的图像、动作、状态等资料	人演示如何抓杯子的轨迹
Simulator，仿真器	根据动作计算世界变化，产生观测	夹爪合拢后，模拟杯子受力与移动
Environment / Task Suite，环境 / 任务套件	在仿真器上定义机器人、场景、目标、重置和接口	不同位置、形状和遮挡的抓杯子任务
Benchmark，评测基准	任务、数据划分、成功标准、预算等比较规则	在未见杯子与固定试验次数下比较成功率
Leaderboard，榜单	在特定规则下展示提交成绩	某个模型在该任务集合中的分数
Model / Checkpoint，模型 / 权重检查点	网络结构及训练得到的参数	根据图像生成抓取动作的已训练策略

一个项目可以同时提供多种东西：RoboTwin 提供任务、数据生成与评测；LIBERO 提供终身机器人学习任务和演示；LeRobot 提供数据格式、训练和硬件接入工具。看到一个名称，先查它属于哪些层，而不是一概叫“数据集”。

Dataset 是静态经验，Environment 能继续交互。训练算法是学习方法，Checkpoint 是某次训练的结果。训练完成不等于有了可部署系统，还需要相机、动作接口、归一化和控制器。

本文会用到 AI（Artificial Intelligence，人工智能）、IL（Imitation Learning，模仿学习）、RL（Reinforcement Learning，强化学习）、VLA（Vision-Language-Action，视觉语言动作模型）与 ACT（Action Chunking with Transformers，用 Transformer 进行动作分块）。IL / RL 是学习方法，VLA 描述连接的模态与能力，ACT 是一种具体策略方法；它们不属于同一层。其余缩写在相关段落给出全称，原学习包的 08 术语表也可随时查阅。

2. 一条数据怎样变成模型输入

2.1 新手会频繁看到的字段

字段	含义	需要核对什么
Episode / Trajectory	一次完整任务 / 时间轨迹	起止边界、成功或失败、是否可恢复
Step / Timestep	一个记录时刻	时间戳、采样频率、是否有丢帧
Observation	模型可获得的观测	哪些相机、身体状态和历史信息
Action	发给机器人的指令	关节或末端、绝对或增量、位置或速度、单位
State	任务相关状态变量	实际传感器能获得，还是仿真特权信息？
Reward	强化学习的反馈分数	与真正完成任务是否一致？
Done / Termination / Truncation	结束 / 任务终止 / 截断	成功、失败、超时和预算结束应区分
Language Instruction	语言任务说明	对应整段轨迹还是某个子任务？
Metadata	来源、本体、相机、标定与版本等信息	能否解释不同样本的接口和采集条件？

RGB（Red, Green, Blue，红绿蓝图像）提供外观；RGB-D（RGB plus Depth，彩色加深度）增加空间距离；点云是三维点集合；Proprioception（本体感知）描述身体的关节、速度等状态。它们提供互补信息。

教学形状例子：两路相机、三帧历史、每张 224×224 像素，可形成 [批量, 时间, 相机, 通道, 高, 宽] 的输入。实际顺序以代码为准。动作块可能是 [批量, 未来步数, 动作维数]。同样是 7 维，也可能分别代表不同机械臂关节，或末端位移、旋转和夹爪，不能只看数组长度猜含义。

2.2 常见数据格式与工具

RLDS（Reinforcement Learning Datasets）是存取与处理序列决策数据的格式和工具生态，强调 Episode / Step 结构。Open X-Embodiment 使用它组织不同来源经验。TFDS（TensorFlow Datasets）是数据加载与管理工具，不是一份机器人数据集。

HDF5（Hierarchical Data Format version 5）可以在一个文件中组织图像、动作与元数据。LeRobot Dataset 是 LeRobot 定义并随版本发展的机器人数据组织方式，结合结构化记录、视频和元数据。Parquet 是列式存储格式，MP4（MPEG-4 Part 14；MPEG 为 Moving Picture Experts Group，动态图像专家组）是常见视频容器；它们不是学习算法。

统一文件格式不意味着统一动作语义。两个数据集都能被同一个加载器读取，一个是米，一个是毫米，模型仍会学错。要检查图像解码、颜色顺序、时间同步、相机标定、动作单位与统计归一化。仓库对特定图像解码工具的提醒正是在解决这类问题。

2.3 数据划分比“下载多少”更重要

Train / Validation / Test（训练 / 验证 / 测试）承担不同用途。训练集用于更新参数，验证集用于选择超参数和版本，测试集用于最后的独立检验。如果持续按测试结果补数据，测试集就逐渐成为开发工具。

按帧随机划分，会把同一轨迹的相邻帧分到训练和测试；按轨迹划分，仍可能共享同一物体和背景；按对象、场景、任务或本体划分，考察的泛化更不同。论文中的 Unseen（未见）必须问“到底未见什么”。

3. 常见数据与环境：按用途识别

专有项目名不一定是缩写。下面给出官方名称或论文题目；没有可确认的字母展开时，保留名称并解释用途，不强行编造全称。数字规模不作为长期固定标准，下载前查当前版本。

3.1 真实机器人操作数据

名称与英文解释	大致提供什么	适合先理解什么
OXE：Open X-Embodiment	跨机构、任务和机器人本体的数据集合	多来源数据如何共同训练，动作怎样对齐
DROID：Distributed Robot Interaction Dataset	多地点采集的真实操作轨迹；原始发布约 7.6 万条演示	真实场景变化、相机与动作信息
BridgeData V2；论文 A Dataset for Robot Learning at Scale	多环境操作行为，包含语言说明和演示	语言条件策略、跨场景迁移
ALOHA：A Low-cost Open-source Hardware System for Bimanual Teleoperation	双臂遥操作硬件与配套任务 / 数据生态	双臂演示与动作分块；它首先也是硬件系统
UMI：Universal Manipulation Interface	手持设备采集示范并关联机器人部署的接口与方法	数据采集能否减少对固定机器人平台的依赖
LeRobot Hub 数据集	社区按 LeRobot 格式发布的多种轨迹	快速看样本与接口；质量和许可逐个数据集核对

OXE 是集合，不表示所有数据都来自同一种机械臂。DROID 是具体数据项目，不是每个机器人数据集的统称。ALOHA 和 UMI 同时涉及采集设备与方法，不能简单当作两个下载文件。

官方入口：OXE、DROID、BridgeData V2、ALOHA、UMI、LeRobot。

3.2 仿真操作任务与配套演示

项目	主要侧重	新手应注意
RoboTwin	双臂操作、自动数据生成与统一评测	Clean 与 Randomized 条件、相同任务的不同测试分布
LIBERO；Benchmarking Knowledge Transfer for Lifelong Robot Learning	知识迁移与终身机器人学习	Spatial、Object、Goal、100 等任务套件各检验什么
CALVIN；A Benchmark for Language-Conditioned Policy Learning for Long-Horizon Robot Manipulation Tasks	语言条件下的多步骤连续操作	常见指标是连续完成链长，不应与单步成功率混用
RLBench：Robot Learning Benchmark	视觉引导操作、任务变化与演示生成	依赖 CoppeliaSim；任务和相机设置会影响结果
ManiSkill	操作环境、机器人、演示与训练基线	依赖 SAPIEN；适合研究仿真采样和操作学习
Meta-World	多任务机器人操作基准	任务集合、状态或视觉输入与评价版本需对齐
BEHAVIOR-1K；Benchmark for Everyday Household Activities in Virtual, Interactive, and ecOlogical enviRonments	大量完整家庭活动与交互环境	家庭任务、物体状态与长期操作比简单抓取更复杂

LIBERO 名称保留原名，解释使用官方论文标题，不将名称字母强行展开。论文里经常出现 LIBERO-10，它通常对应从 LIBERO-100 划出的较长任务集合；下载与比较时查看具体 split（划分），不能用“10”猜所有任务难度。

CALVIN 的 LH-MTLC 全称是 Long-Horizon Multi-Task Language Control，意为长时程多任务语言控制。它要求按连续语言指令推进任务，前面失败会影响后面。不是简单把多个独立任务成功率平均。

官方入口：RoboTwin、LIBERO、CALVIN、RLBench、ManiSkill、Meta-World、BEHAVIOR。

3.3 导航、视频与驾驶数据：为什么也会出现在世界模型论文里

Habitat 是具身导航和交互的模拟平台；HM3D（Habitat-Matterport 3D）与 Matterport3D 提供室内三维场景，主要帮助构建环境，不自动带有与某种机械臂一致的抓取动作标签。ObjectNav（Object-Goal Navigation）找指定类别物体；PointNav（Point-Goal Navigation）走到指定目标位置；VLN（Vision-and-Language Navigation）根据视觉与语言指令导航。

DMC（DeepMind Control Suite）提供物理控制任务，是研究潜空间世界模型与基于模型的强化学习的常见入口。Atari 游戏环境也常见于这类研究，但游戏表现不直接说明真实机械臂操作能力。

SSv2（Something-Something V2）等人类视频数据可帮助学习物体变化与视觉表征，但通常缺少对目标机器人可直接执行的动作。Waymo Open Dataset 的驾驶数据包含不同子集与任务，适合研究动态场景、感知或轨迹预测；它不是机器人操作数据的直接替代品。

官方入口：Habitat、HM3D、DeepMind Control Suite、Waymo Open Dataset。

3.4 如何选第一份数据

先按功能选：学 BC（Behavior Cloning，行为克隆）需要观测和专家动作；学动作条件世界模型需要连续观测和对齐动作；做导航需要环境、移动动作与目标；做记忆 / 恢复需要含失败或多步骤状态的任务。

再核对本体、动作、相机、语言、是否含失败、下载量、许可和基线。当前理解阶段只需看少量样本与字段说明。不要为认识一个数据集而下载整个超大集合。

4. 算力到底是什么：不要只数显卡

4.1 六种资源瓶颈

CPU（Central Processing Unit，中央处理器）负责数据解码、调度、部分物理计算和环境逻辑。GPU（Graphics Processing Unit，图形处理器）适合神经网络并行计算、渲染和部分并行物理。RAM（Random Access Memory，系统内存）存放程序和主机数据；显存是加速器保存模型、激活和设备数据的内存，不能与普通内存直接互换。

VRAM（Video Random Access Memory）常被泛指显卡显存；HBM（High Bandwidth Memory，高带宽内存）是部分加速器使用的实际内存技术。Unified Memory（统一内存）让部分设备共享物理内存，但框架支持、带宽与可用量仍决定实际表现。

存储容量决定数据是否放得下；SSD（Solid-State Drive，固态硬盘）的读写速度影响加载。网络带宽影响下载和多机通信。Memory Bandwidth（内存带宽）决定设备传输数据速度，TFLOPS 再高也可能被数据访问拖慢。

FLOP（Floating-Point Operation，浮点运算）是运算量单位；FLOPS（Floating-Point Operations Per Second）是每秒速度；TFLOPS（Tera Floating-Point Operations Per Second）是每秒万亿次浮点运算。比较数字时要对齐 FP32、FP16、BF16 等精度与是否使用稀疏计算；厂商理论峰值不等于训练实测吞吐。

4.2 显存分给了谁

推理需要权重、输入、激活和缓存；自回归 Transformer 还常用 KV Cache（Key-Value Cache，键值缓存）。训练额外保存梯度、优化器状态与反向传播所需的中间结果。仿真环境和相机渲染也可能占同一张显卡。

教学计算：B 为 Billion，1B 表示约十亿参数。若每个参数用 16 位，即 2 字节，权重本身约 2 GB；7B 权重约 14 GB。GB（Gigabyte）等于十亿字节，GiB（Gibibyte）等于 2 的 30 次方字节。这只是参数存储，不是完整运行显存。

Adam（名称源自 Adaptive Moment Estimation，自适应矩估计）是一种常见优化器。一个混合精度 Adam 训练配置可能需要约 16 字节 / 参数，包括低精度权重、主权重副本、梯度和两个矩估计状态；因此 1B 参数仅相关状态就可能约 16 GB，还没算激活。不同实现的状态精度和分片方式不同，这个例子不能当作统一公式。

图像更多、分辨率更高、历史更长、动作块更长或 batch 更大，都可能增加成本。视频世界模型的时间和空间开销尤其明显。OOM（Out Of Memory，内存不足）不只可能是显存不足，也可能来自主机内存，先看错误位置。

4.3 精度与省显存方法

名称与全称	用途	不要误解成什么
FP32：32-bit Floating Point	常规单精度计算	不是所有模块都必须采用它
FP16：16-bit Floating Point	减少部分计算和存储成本	可能需要处理数值稳定性
BF16：Brain Floating Point 16	另一种 16 位浮点格式，指数范围较大	与 FP16 有不同数值特征，硬件支持需核对
AMP：Automatic Mixed Precision	自动组合不同精度	不会消除全部训练内存
LoRA：Low-Rank Adaptation	用低秩增量做参数高效微调	基础模型仍要加载，激活仍占内存
PEFT：Parameter-Efficient Fine-Tuning	参数高效微调方法总称	不等于只有 LoRA 一种方法
Quantization，量化	用较低位宽表示部分数值	推理适用不代表直接适合所有训练和控制模块
Gradient Accumulation，梯度累积	多个小批量累计后更新	能减少单次批量占用，通常增加运行时间
Gradient Checkpointing，梯度检查点	少存激活，在反向时重算	用更多计算换显存，不是断点权重文件

4.4 单卡、多卡与部署频率

DDP（Distributed Data Parallel，分布式数据并行）通常让各卡保存完整模型副本，各处理不同样本。因此两张 24 GB 卡不自动成为一张 48 GB 卡。FSDP（Fully Sharded Data Parallel，全分片数据并行）等方法可分片参数、梯度和状态，但需要额外通信与正确配置。

吞吐 Throughput 表示每秒样本、帧或 token 数；延迟 Latency 表示一次请求需要多久。机器人关心动作是否及时返回：批量推理吞吐很高，也可能单次动作延迟太大。Hz（Hertz，赫兹）表示每秒次数，30 FPS（Frames Per Second）图像与 100 Hz 控制不必一一对应，时间同步与延迟补偿需要专门设计。

4.5 当前学习阶段需要多少

阶段	合理起点	主要限制
阅读、看样本、理解数据字段	普通电脑即可，数据按需取样	大视频解码和数据下载仍可能慢
一个任务的小型 ACT / Diffusion Policy 基线	单张约 16-24 GB 显存的支持设备可作为规划起点	配置、图像、批量和仿真决定实际需求
冻结特征编码器、小世界模型实验	先降低图像大小、预测长度和批量	不能由参数数目单独估算成本
大 VLA 微调或高分辨率视频模型	按模型官方配方选 40-80 GB 级或多卡资源	PEFT 能降低部分需求，不能保证消费卡都可跑
从零训练大规模视频世界模型	通常是数据、集群和系统工程项目	不适合作为当前入门的第一步

这些是选择实验规模的粗略参考，不是保证配置。租服务器前先做最小批量试跑，测峰值显存、每轮耗时、存储占用和真实任务效果；不要仅凭论文用了哪张卡就照抄。

4.6 论文里的加速器型号与集群词汇

GeForce RTX 系列是常见消费级显卡产品，例如 RTX 3090 / 4090 的常见配置为 24 GB 显存。这里将 RTX 保留为产品品牌，不编造算法全称。A100、H100、H200 是 NVIDIA 数据中心加速器型号；同一型号也可能有不同显存与设备形态。不能只凭“用了 H100”就推断论文训练成本或你的复现配置。

TPU（Tensor Processing Unit，张量处理单元）是 Google 的专用加速器；NPU（Neural Processing Unit，神经网络处理单元）是更一般的专用加速器类别。AMD GPU、TPU、Apple 加速器都需要对应软件支持，不是所有 CUDA 项目都能直接迁移。当前阶段无需为了阅读论文购买设备。

Node（计算节点）通常指一台服务器，Cluster（集群）是多节点系统。GPU-Hour（GPU 小时）约等于设备数乘运行小时；8 张卡运行 10 小时是 80 GPU 小时，但不同型号、利用率与任务的这项数字不能直接比较。租用成本还包括存储、下载和空闲时间，应先看实际计费规则。

PCIe（Peripheral Component Interconnect Express）连接设备与主机；NVLink 是 NVIDIA 的高速设备互联技术；InfiniBand 是常见集群互联技术。它们影响多卡 / 多机通信，拥有更多卡不保证按卡数等比例加速。Slurm（原名源自 Simple Linux Utility for Resource Management）是常见集群作业调度系统：提交任务、申请卡和内存、排队与查看日志，也是实验室研究基础设施的一部分。

5. 基础设施：实现功能需要的工具层

5.1 从底层到项目接口

操作系统和驱动支撑硬件；CUDA（Compute Unified Device Architecture）是 NVIDIA 的并行计算平台；PyTorch / JAX 等框架实现模型和训练；数据管线读入轨迹；仿真器处理物理和渲染；任务套件定义目标；训练与评测程序将这些部分连接起来。

Python 虚拟环境用于隔离依赖；Docker 是容器工具，便于打包软件环境，但不能抹去 GPU 驱动、架构和渲染支持差异。Checkpoint、配置、代码版本和数据版本共同决定能否复现。

macOS 可以用于阅读、数据处理与部分小模型。MPS（Metal Performance Shaders）提供 Apple 平台上的部分加速能力，但支持它不等于支持依赖 CUDA 的机器人项目。机器人训练与仿真仓库常围绕 Linux 与 NVIDIA 测试，安装前查各项目支持矩阵。

5.2 常见平台怎么分工

名称	主要角色	应连接到哪个问题
MuJoCo：Multi-Joint dynamics with Contact	接触动力学仿真引擎	物理是否正确、如何执行控制量
SAPIEN	物理与视觉模拟平台	操作场景、相机与交互；不是策略模型
Isaac Sim / Isaac Lab	仿真系统 / 机器人学习与任务框架	场景传感器、并行训练与执行接口
CoppeliaSim	机器人仿真平台	RLBench 等任务的底层环境
PyBullet	Bullet 物理的 Python 接口与环境工具	CALVIN 等项目的仿真基础
Gymnasium	强化学习环境接口标准与工具	reset / step / observation / action 的调用约定
robomimic / LeRobot	数据、策略训练与评测工具	从演示到训练、部署与记录
ROS 2：Robot Operating System 2	机器人消息、中间件与工具生态	相机、机器人状态、控制模块之间如何通信
MoveIt 2	运动规划与机器人操作工具	目标位姿怎样转换为无碰撞路径

MuJoCo 原生引擎、其 GPU 后端与上层任务套件的能力不同，不能只看到项目用 MuJoCo 就判断是否所有物理都跑在 GPU。Isaac Sim 和 Isaac Lab 也不是同一个层：后者围绕机器人学习组织任务与训练。

URDF（Unified Robot Description Format）描述机器人关节、连杆等结构；MJCF（MuJoCo XML Format）是 MuJoCo 的模型描述格式，XML 为 Extensible Markup Language。这类文件告诉模拟器机器人是什么，不会自动训练出策略。

5.3 容易被模型图省略的内容

相机内外参、手眼标定、时钟同步、控制频率、动作限制、碰撞检测、任务重置、数据日志、成功检测、异常处理都属于系统。模型预测一个末端位姿，还需要 IK（Inverse Kinematics，逆运动学）、运动规划和控制器将其变成可执行运动。

云 GPU 或实验室服务器只提供部分计算资源，不一定提供机器人仿真可用的渲染环境。无显示器运行叫 Headless，不等于不渲染；如果策略吃图像，仍然需要生成相机图像，并核对渲染库和驱动。

工程实用工具还包括 Git 版本管理、实验配置、日志与指标记录、任务种子 Seed、断点续训和缓存。固定 Seed 有助于比较，却不保证不同硬件或软件版本结果完全相同。

官方文档：MuJoCo、Isaac Lab、ROS 2、RLDS、LeRobot。

6. 榜单、打榜网站与论文检索怎么用

6.1 推荐关注的官方入口

网站 / 项目	看什么	怎样使用
RoboTwin Leaderboard	双臂操作的任务结果与条件	先读 Setting 和提交规则，再看模型排名
RoboDojo	仿真与真机的操作评测、能力维度	区分 Sim / Real、本体、Score 和成功率
LIBERO	任务划分、演示、基线和评价代码	常在论文 / 仓库对照表比较，不必有统一在线提交榜
CALVIN	长时程语言操作协议与连续任务指标	查看链长和环境划分，不与普通成功率混排
Habitat Challenge	具身导航与相关挑战	按年份确认赛道、数据与提交入口
BEHAVIOR Challenge	家庭活动任务、基线、规则与榜单	关注完整任务和实际评测赛道
Waymo Open Dataset Challenges	感知、运动预测等不同驾驶赛道	只与相同赛道和版本的方法比较
Hugging Face	权重、数据、模型卡和演示	下载与复现入口；受欢迎程度不是任务能力排名

有的基准提供评测代码和论文结果，没有持续维护的公开榜单；有的榜单需要提交容器或权重，由服务器评测；也有作者自行报告的结果。先查证据来源，再解释排名。

arXiv 是预印本平台，GitHub 是代码托管与协作平台，OpenReview 用于部分会议投稿和评审，Google Scholar、Semantic Scholar 可帮助检索文献。这些都不是机器人能力统一榜。论文名、引用数和仓库星数适合发现资料，不能代替实验质量判断。

6.2 打榜之前必看的问题

问清任务、训练数据、测试划分、动作接口、观测权限、模型版本、随机种子与试验次数；还要看每次能重试几次、能用多少计算、是否允许测试时训练、是否有人干预。榜单日期也应记录。

Zero-Shot（零样本）通常表示没有针对目标设置作额外训练，但模型仍可能经过其他训练；Few-Shot（少样本）使用少量目标经验；Fine-Tuning（微调）更新已有模型。定义与预训练重叠情况必须看具体协议。

SR（Success Rate，成功率）不是所有榜单的 Score。Score 可能综合不同维度。导航还常使用 SPL（Success weighted by Path Length，按路径长度加权的成功指标），奖励成功且路径高效的行为。CALVIN 连续链长则考察多任务串联可靠性。

教学例子：模型 A 的 SR 为 80%，来自 20 次简单场景试验；模型 B 为 75%，来自 500 次带遮挡试验。不能据此说 A 更强。即使设置相同，试验次数、方差与置信区间也影响结论。

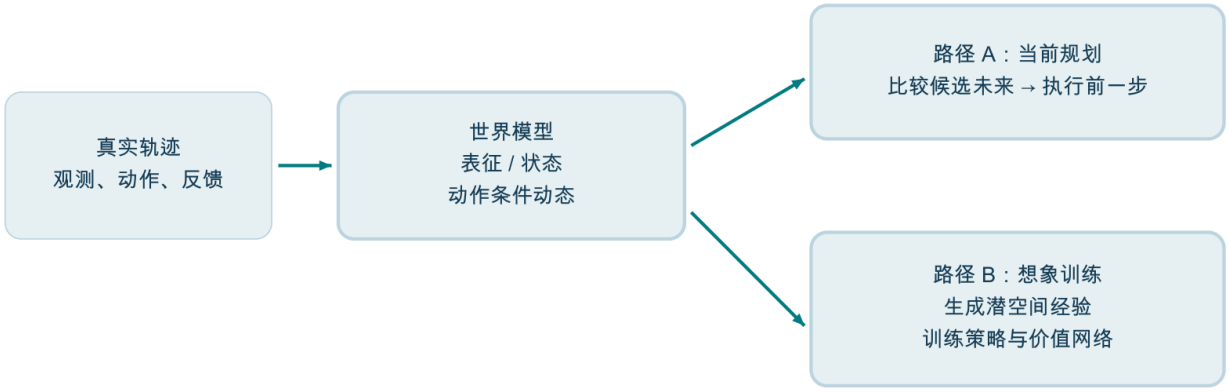
Ablation（消融）问“去掉这个模块会怎样”；Baseline（基线）是参照方法；SOTA（State of the Art）表示作者在指定设置中相对先进的结果，必须附具体基准与条件。OOD（Out Of Distribution，分布外）强调与训练分布不同，不能只用“没见过”三个字带过。

7. 世界模型：实现预测与规划需要哪些板块

7.1 一张完整的功能图

图 12 | 世界模型：两条使用路径

学习动态与利用动态是两件事；图中模块按用途添加。



A 的部署成本来自搜索；B 的成本主要在训练，部署可直接用策略。

教学示意：按功能解释，不代表所有方法具有相同网络结构。

读图：左侧学习世界如何变化，右侧选择如何使用预测。规划器可在线搜索；策略也可先在想象轨迹中训练。更详细的先验、后验与训练目标见 10 算法详解第 11 节。

真实 / 仿真交互轨迹
→ 数据整理、时间同步、动作定义与划分
→ 观测编码器：把图像、身体状态等变成表征
→ 状态 / 历史模块：整合当前与过去的信息
+ 候选动作、目标及其他条件
→ 动态预测器：预测状态如何演变
→ 按用途输出特征、图像、几何、奖励或终止信息
→ 规划 / 策略学习：利用预测选择动作
→ 控制与环境执行
→ 新观测校正、记录误差、继续预测与评测

这个图是功能清单，不要求每个框必须是独立网络。一个 Transformer 可以承担多个功能。世界模型本身可以只做预测；当目标是机器人规划或控制时，还要补上动作选择和执行闭环。

7.2 数据板块：模型得见过怎样的变化

预测下一帧需要连续观测；预测“执行动作后怎样”还需要时间对齐的动作。图像帧、指令时间与实际执行结果错位，模型就会学错因果关联。还要明确状态、相机、采样频率和动作单位。

仅有专家成功演示，可能缺少滑落、抓空与危险动作的后果。仅有人类视频，又缺少机器人可执行动作。不同来源能补充不同能力，不能把所有视频直接当成控制训练数据。

7.3 表征板块：预测什么东西

Encoder（编码器）把观测转换为有用表征。可以用紧凑潜向量、图像 patch token（局部图像词元）、空间网格、点云、对象表示或可渲染几何。选择依据是预测用途、空间精度和计算预算。

Latent Space（潜空间）是压缩表示的空间，不是另一份物理世界。预测潜特征可以省去生成纹理，但特征要保留接触、位置或其他任务需要的信息。全部特征预测得很准，也不一定保证遗漏的物理量正确。

7.4 状态与记忆板块：遮住杯子后它还在吗

单帧看不到遮挡后的杯子，历史能够帮助推断位置和存在性。模型可以使用循环结构、注意力历史、RSSM（Recurrent State-Space Model，循环状态空间模型）或其他状态估计方式。

Belief State（信念状态）表达在部分观测下对可能世界状态的估计，可以包含不确定性。它不同于“确定记住一个位置”：若杯子可能被人挪动，状态需要允许不确定并寻求新观测。

7.5 条件与动态板块：动作如何改变未来

Action-Conditioned Dynamics（动作条件动态）将当前表征和动作映射为未来表征。语言、目标、相机位姿、本体信息也可作为条件，但这些条件不能与物理动作混淆。

教学对照：不含动作的模型问“接下来通常会发生什么”；含候选动作的模型问“如果夹爪向左移动并闭合，会发生什么”。后者才直接支持比较不同动作后果。部分方法从视频学习隐式动作或潜在动作，再映射到机器人动作；该映射的有效性仍需检查。

动态模型可以逐步自回归预测，也可以分块 / 联合预测多个未来时刻；可用确定性回归、概率状态模型、扩散、流匹配等方法。时间预测方式与空间表示是不同维度，不能把“扩散”简单等同于全部世界模型。

7.6 输出板块：按用途添加，不必全部都有

Decoder（解码器）把预测表征还原为图像或其他可读量。若规划直接比较预测特征与目标特征，图像解码器可以是可选项。Reward Head（奖励头）、Value Head（价值头）或 Termination Head（终止预测头）帮助判断任务价值与结束，适合某些强化学习方法，并非所有世界模型的必备结构。

几何输出用于碰撞与空间关系；图像输出便于可视化或训练下游视觉策略；对象状态便于检查是否抓住杯子。Inverse Dynamics Model（逆动态模型）从状态变化推断动作，是部分从未来计划到动作的方法使用的组件，不能仅凭预测视频就默认存在。

7.7 学习目标板块：用什么信号让模型变好

可以比较下一观测、特征或状态预测与真实结果，也可结合奖励、终止、几何和多步一致性目标。MSE（Mean Squared Error，均方误差）衡量回归差异；NLL（Negative Log-Likelihood，负对数似然）用于概率预测；KL Divergence（Kullback-Leibler Divergence，KL 散度）可约束概率分布。这些不是每个模型都必须同时包含的损失。

JEPA（Joint Embedding Predictive Architecture，联合嵌入预测架构）强调表征预测。V-JEPA（Video Joint Embedding Predictive Architecture，视频联合嵌入预测架构）属于视频表征路线。DINO（Self-Distillation with No Labels，无标签自蒸馏）可提供视觉特征；DINO-WM 利用预训练特征学习动态与规划，不表示 DINO 本身已经是动作条件世界模型。

需要防止表示坍缩：若模型对所有图像都输出相同特征，特征预测损失可能很低，却没有有用信息。还要区分训练时每步看真实状态与推理时连续使用自己预测的状态；后者更容易累积误差。

7.8 规划与控制板块：预测如何产生动作

Planning（规划）可以比较候选动作序列的预测结果，或在潜空间中优化动作。MPC（Model Predictive Control，模型预测控制）每次规划未来一段，执行第一步或一小段，再用新观测重规划。

另一条路线是 Model-Based Reinforcement Learning（基于模型的强化学习）：在想象轨迹上训练 Actor（动作策略）和 Critic（价值评价器），部署时用策略行动。Dreamer 系列是这类路线的重要代表。规划与想象训练能组合，但成本和误差传播不同。

```
当前表征 = 编码(真实观测与必要历史)
产生若干候选动作序列
for 每个候选:
    用动作条件模型展开未来
    根据目标、风险与成本评分
执行最好序列的第一步
读取真实新观测，校正表征
再次规划
```

伪代码里的风险项不会自动获得安全保证。若世界模型对碰撞预测不准，规划器仍可能选出危险动作，需要另行检查实际约束和环境结果。

7.9 评测与不确定性板块：好看不等于可控

PSNR（Peak Signal-to-Noise Ratio，峰值信噪比）与 SSIM（Structural Similarity Index Measure，结构相似性指标）衡量部分图像差异；FVD（Fréchet Video Distance，弗雷歇视频距离）用于视频分布比较。它们不能独立证明接触、因果或控制能力。

同时看状态误差、动作敏感性、时间一致性、对象持续存在、物理约束、下游任务成功和推理延迟。换一个动作，预测是否产生合理不同结果，是很有用的检查。

Uncertainty（不确定性）可来自随机状态、多模型集合、概率输出或其他估计，但不等于有了可靠校准。Calibration（校准）要求预测信心与实际正确率有对应关系。误差大或分布外时，系统可以限制动作、获取新观测或使用其他可靠机制；具体需要验证。

8. 三种世界模型项目，需要的东西并不相同

目标	最小需要的内容	可以暂缓的内容
学会预测视频 / 特征	连续数据、编码 / 表征、预测器、学习目标与预测评测	机器人动作规划和真机部署
用模型规划抓杯子	对齐动作的轨迹、可用状态表征、动作条件动态、目标评分、规划器、执行反馈	大视频生成器；仅特征规划可不重建像素
在想象中学习动作策略	动态模型、奖励 / 价值等学习信号、想象轨迹、策略训练、环境验证	每一步都由大型规划器搜索

若当前要从理解走向最小实验，建议冻结一个现成视觉编码器，在一个仿真任务的小数据上学短期动作条件特征预测，再检验是否有利于选动作。先比较一步预测与多步展开、训练误差与独立任务成功，不要直接追求生成整段高分辨率世界。

没有动作对齐数据时，可以学习视频表征与预测，却不能因此宣称已学会可靠的机器人可控动态。没有执行接口和任务评分时，可以演示未来画面，却仍缺少完整的规划 / 控制系统。

方法入口：DreamerV3、DINO-WM、V-JEPA 2。这些链接用于下一阶段理解代码，未要求现在安装所有项目。

9. 其他很常见的研究词汇

词汇与全称	一句话解释	杯子例子
MDP：Markov Decision Process	用状态、动作、转移和奖励描述决策	假设当前状态足以预测下一步
POMDP：Partially Observable Markov Decision Process	决策时只能获得部分观测	杯子被遮挡，需记忆与估计
Open-Loop / Closed-Loop	无中途反馈执行 / 持续依据反馈调整	按整段轨迹走 / 抓空后重定位
Offline / Online Learning	用已有资料学习 / 随交互产生新资料并学习	学演示 / 练习后更新策略
On-Policy / Off-Policy	用当前策略 / 其他策略产生的经验作学习依据	最新练习 / 旧演示；具体定义依算法
Replay Buffer，经验回放池	保存交互供训练采样	成功和失败都可回放
Curriculum Learning，课程学习	组织逐渐适配能力的训练任务	从无遮挡到复杂遮挡
Test-Time Adaptation，测试时适应	测试执行阶段更新状态或模型以适应	必须在协议中说明允许更新什么
Teacher Forcing，教师强制	训练时用真实历史作为输入	与推理时依赖自身预测不同
Autoregressive，自回归	下一步依赖之前输出或状态	逐步生成未来表征
Receding Horizon，滚动时域	执行一小段后重新规划	每次只执行计划的前部分
Sim2Real / Real2Sim	仿真到现实 / 真实场景重建到仿真	摩擦迁移 / 把桌面重建进模拟器
Retargeting，动作重定向	把一种身体的运动映射到另一种本体	人手示范映射到机器人手
Affordance，可供性	在特定身体条件下可能的交互	这个夹爪能否抓住杯柄？

Transformer 中的 Token 是模型处理的单位，可能是词、图像块、动作或状态，而不总是一个汉字。Embedding（嵌入）是把单位变成向量。Backbone（主干）提取主要表示，Head（预测头）输出指定量。

Pretraining（预训练）、Fine-Tuning（微调）、Inference（推理）分别是广泛学习、针对性更新与使用模型，资源需求不同。

10. 一页研究系统检查表

看到新方法时先写：任务和本体；观测与动作；数据来源与划分；核心模块；训练目标；部署频率；成功判据；计算预算；失败模式；代码与权重是否能找到。

如果是世界模型，再问：预测对象是什么？有无真实动作条件？是否需要历史？误差怎样累积？规划依据什么评分？实际执行后是否重观测？预测收益是否超过时延与计算代价？

如果是榜单，再问：比较的是相同任务、观测、预算、数据和版本吗？有没有误用训练数据、只看成功演示或隐藏人工干预？有没有多个随机种子和误差报告？

如果要动手，先让一条样本从读取到执行完整通过。字段、单位、时间和接口都清楚之后，再决定换模型或扩大算力。

11. 自测：学会按问题选择内容

问题一：我想做动作条件世界模型，拿到很多人类视频就够了吗？不够。可先学视觉预测，但要支持机器人动作比较，还需合适动作表示、时间对齐和落地关联。

问题二：两张 24 GB 卡能直接运行需要 40 GB 单卡内存的模型吗？不能自动。数据并行通常每卡仍保留完整模型；分片需要明确的方案与支持。

问题三：LIBERO 的数字比另一个真机榜高，证明模型更强吗？不能。任务、本体、观测、预算和成功标准都可能不同。

问题四：世界模型必须生成视频、奖励和机器人动作吗？不必须。预测形式依用途选择；若目标是完整控制，需要另外提供动作选择、执行和反馈。

问题五：预测视频很清晰，为何仍会撞杯子？视觉相似性不一定衡量接触动态、动作因果、空间精度和实时反馈。

12. 来源与边界

本文基于指定 Embodied-AI-Guide 基础设施篇、随包世界模型综述与上述官方项目页面编写。主要项目说明与术语在 2026-10-23 核对；导航挑战入口等页面需进一步按实际年份和赛道确认。数据规模、赛道、工具版本和支持硬件以当前页面为准。原理解释与最小系统图是教学归纳，不代表所有论文都采用相同设计。

算法图解详解：从数据到策略与世界模型

为偏算法背景的初学者编写，更新于 2026-10-24。本章是对仓库导读的实质扩写：先把算法写成输入、输出、监督信号和执行流程，再解释为什么这样设计。公式、数字、示意图和伪代码均为教学材料；与某篇论文实现有关的细节会明确给出来源。

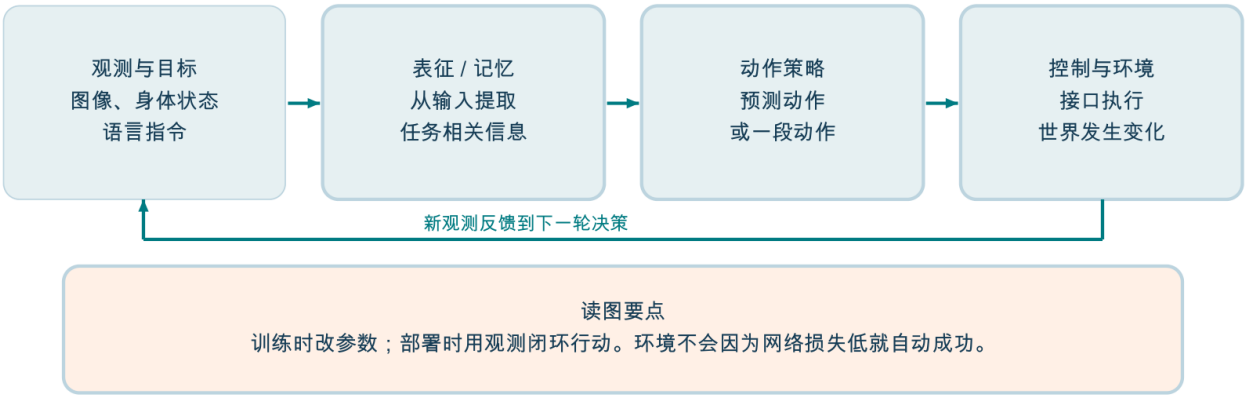
建议先读第 1 至 7 节建立动作学习基础，再读第 8 至 13 节理解强化学习、世界模型与长期决策。第 14 至 17 节补齐几何、导航、实验与选题。你不需要一次背下所有模型名；每节末尾的“读懂检查”用来判断是否需要回看。18 张图既嵌在本文中，也保存在图解目录中，附有矢量 PDF 原图。

1. 算法背景进入具身：先改变哪几个思维习惯

1.1 监督学习的输出现在会改变下一次输入

普通图像分类里，你把一张图片判错，不会因此改变下一张测试图片。机器人策略不同：它抓偏了，杯子被推到新位置，下一次看到的图像就变了。于是“输入 → 预测”变成“输入 → 动作 → 新输入”的闭环。算法必须在自己造成的状态变化中继续工作。

图 1 | 一个算法究竟控制了哪个箭头？



教学示意：按功能解释，不代表所有方法具有相同网络结构。

图中策略与环境之间的箭头是新手最容易漏掉的部分。模型可以在离线测试里准确模仿专家，却在真实执行里进入专家没经历过的状态。训练损失与任务成功率因此必须分开测量。

具身智能 AI（Artificial Intelligence，人工智能）不要求每个模块都用神经网络。一个完整系统可以用学习视觉编码器、传统运动规划器和经典控制器；也可以用端到端策略，但接口、时间同步和物理执行仍然存在。

1.2 先写一张符号表，读公式就不会一直停下来

符号	本章含义	抓杯子例子
t	机器人交互时刻	合爪前、合爪后、抬起后
o_t	当前可获得的观测	相机图像与关节传感器读数
s_t	描述环境的状态	杯子真实位姿、速度、接触等
q_t	机器人关节位置等身体变量	机械臂关节角；这里 q 不代表价值函数
g	目标 / 指令	把红杯子放进水槽
c_t	策略的条件信息	编码后的图像、状态、语言及必要历史
a_t	一个时刻的动作	关节目标或末端增量
A_t	从当前开始的动作块	[a_t, a_(t+1), …, a_(t+H-1)]
H	预测动作的步数	一次预测未来 20 步
K	本轮执行后重新观测的间隔	执行前 4 步就再次推理
θ	可学习模型参数	编码器和动作网络的权重

观测 o_t 不等于状态 s_t。杯子背后有没有把手、是否装水、是否稳定接触，未必从图像中完整可知。算法有时直接使用仿真状态，有时只看图像；比较方法时必须对齐观测权限。

E 表示在数据、轨迹或随机噪声上求期望，也就是对很多样本求平均；πθ 表示参数为 θ 的策略；p 表示概率分布。下标与括号的精确定义依论文而定，同一个字母在不同论文里可以承担不同角色。

1.3 看一篇算法论文，先回答四个接口问题

输入包含什么？输出是什么动作表示？训练时谁提供监督？部署时如何与环境交互？先回答这四项，再看网络层数。

例如“基于 Transformer 的机器人算法”仍然很模糊。Transformer 可以做视觉编码、动作解码、动态预测或语言规划。只有知道它预测的是动作、状态还是文本，你才能理解它在解决哪种问题。

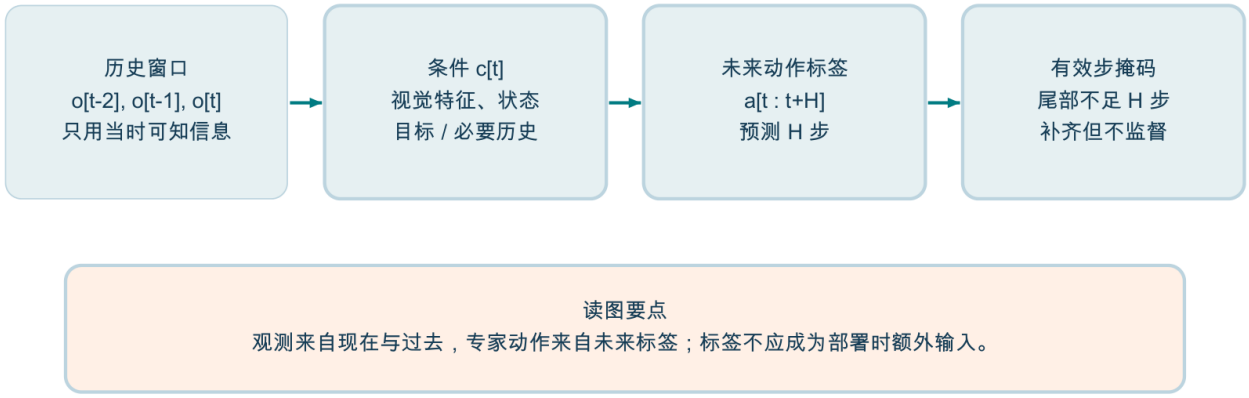
读懂检查：你能否解释“模型推理成功”“低层控制成功”“任务成功”分别意味着什么？前者只代表程序得到输出，中间一项代表运动被执行，最后一项才代表目标完成。

2. 数据到张量：动作学习真正的地基

2.1 训练样本是轨迹中的一个窗口

一条轨迹记录从开始到结束的交互。训练时通常不会每次读取整条轨迹，而是在时刻 t 截取条件窗口和未来动作标签。IL（Imitation Learning，模仿学习）使用专家行为作为监督；BC（Behavior Cloning，行为克隆）是其中直接监督拟合动作的常见方法。

图 2 | 从一条轨迹截取一次训练样本



教学示意：按功能解释，不代表所有方法具有相同网络结构。

图中“未来动作”只在训练时作为标签使用。预测它们是任务，不能在部署时偷偷把真实未来动作输入网络。某些条件生成方法训练时会编码未来动作形成潜变量，那是训练后验的一部分，推理必须换成可获得的先验；ACT 正好需要理解这个区别。

教学张量例子：批量 B=16，两路相机，三帧历史，每帧 RGB（Red, Green, Blue）图像 224×224，图像可以是 [16, 3, 2, 3, 224, 224]；未来动作 H=20，动作维数 d=7，则标签是 [16, 20, 7]。B 在这里是 Batch Size，不是十亿参数的 Billion。具体轴顺序由实现决定。

如果模型使用单帧，时间维可能省掉；如果先编码图像，每张图可能变成一串 patch token（图像块词元）；如果使用点云，则输入可能是 [B, N, 3] 加颜色或其他特征。形状只能告诉你数量，不能告诉你动作单位与语义。

2.2 七维动作为什么会有完全不同含义

一个模型输出七个数，可以是六个关节加夹爪，也可以是末端三维平移、三维旋转加夹爪。双臂动作维数更高，但拼接方式也依本体不同。旋转又可以用欧拉角、轴角或其他表示。抓杯子时的方向很关键，不能只监督 xyz。

绝对动作指定目标值，例如“关节转到 0.5 弧度”；增量动作指定相对变化，例如“再转 0.02 弧度”。位置动作、速度动作、力矩动作对应不同控制接口。相同数字进入不同接口，物理结果会完全不同。

算法实验必须固定动作表示。否则“加一个模型模块”的结果变化，可能实际来自改了动作单位、控制模式或反归一化。

2.3 归一化、补齐、掩码到底在做什么

归一化把不同量纲调整到易训练的尺度。标准化示意为 $a_{norm} = (a - \mu) / (\sigma + \varepsilon)$，μ、σ 是训练集统计量，ε 是防止除零的小常数。部署时用 $a = a_{norm} \times \sigma + \mu$ 还原。某些仓库使用分位数缩放或将夹爪维单独处理，不能只复制这个公式。

为什么重要？位置量可能是 0.1 米，角度可能是 1 弧度，夹爪可能是 0 或 1。如果所有维度直接求平方差，数值较大的维度可能主导梯度。归一化改善优化，但不会统一动作的物理意义。用错统计文件，动作可能系统性抓偏。

轨迹最后剩余步数不足 H 时，常补齐张量，并用 Padding Mask（补齐掩码）忽略无效标签。补齐的零不是“专家要求停在零位置”。不仅损失要忽略补齐，注意力网络也可能需要忽略补齐输入。

```
采样轨迹中的时刻 t
取允许使用的观测历史，构造条件 c
取未来 H 个专家动作，不足部分补齐
构造有效步 mask
用训练集统计量归一化动作
预测动作块，与有效标签比较
更新参数
```

2.4 增强与划分要保留控制语义

图像裁剪改变目标在像素中的位置；水平翻转可能改变左右语义；点云坐标变化可能需要同步变换动作。如果只翻图像、没有正确处理“向左移动”的标签，增强会制造错配。实际是否可用取决于任务、标定与模型输入。

训练、验证、测试应按轨迹、场景、对象或任务合理划分。按帧随机划分容易让相邻帧跨越训练和测试。用测试场景统计动作或选超参数，也会降低独立评测的可信度。

读懂检查：拿到一个数据集，你能否说清楚每个动作维、单位、时刻对应关系，以及补齐部分是否被监督？不能回答时，先不要改网络。

3. 表征与注意力：为什么不是把图片和文字简单拼起来

3.1 从像素到可供动作网络利用的条件

视觉编码器把图像变成特征。CNN（Convolutional Neural Network，卷积神经网络）擅长局部处理；ViT（Vision Transformer，视觉 Transformer）常把图片切成块，通过注意力建模关系。它们都可以产生全局或局部特征。

全局向量紧凑，但可能丢掉小杯柄的位置；稠密特征保留局部空间关系，但占更多算力。点云、深度和几何可以补空间信息，但还要处理传感器噪声和坐标对齐。“特征更强”需要落实到任务需要保留什么。

CLIP（Contrastive Language-Image Pre-training）与 SigLIP（Sigmoid Loss for Language-Image Pre-training）学习图文关联；DINO（Self-Distillation with No Labels）学习可迁移视觉特征。图文对齐帮助选择红杯子，稠密视觉特征帮助跟踪杯柄，但它们都不自动提供抓取动作。

冻结 Encoder（编码器）是固定其参数，只训练下游头。优点是省训练成本、减少小数据过拟合；缺点是任务所需信息可能没有充分编码。微调可适配任务，但可能破坏原有通用能力，并增加数据与优化需求。比较冻结与微调时要报告训练参数、预算与独立任务成功。

3.2 Attention 中 Q、K、V 的实际含义

Self-Attention（自注意力）常写为 Attention(Q,K,V) = softmax(QK^T / sqrt(d)) V。这里 Q、K、V 分别是 Query、Key、Value（查询、键、值），是特征的可学习线性投影。Q 问“我该关注谁”，K 用于计算相关程度，V 提供聚合内容；softmax 把分数变成归一化权重。

这套 Q / K / V 与强化学习的 Q 值不是同一个概念。本章动作长度 K 也与注意力键 K 不同。上下文决定符号含义。

如果动作查询需要预测“夹爪下一步怎么动”，它可能关注杯柄的图像 token、当前关节状态和语言目标。Cross-Attention（交叉注意力）允许一组 token 查询另一组 token；它是一种信息交互机制，不保证学到的关注位置符合人的直觉。

Position Encoding（位置编码）告诉网络 token 的空间或时间身份。否则模型看到一组特征，很难分清第几帧、哪路相机或哪个未来动作槽位。Causal Mask（因果掩码）限制访问未来信息，Padding Mask 屏蔽补齐位置；两者解决不同问题。

3.3 几种融合选择与它们的研究问题

早期融合将不同模态较早放在共同网络中；后期融合先分别提特征再组合；交叉注意力让一种模态按需要查询另一种。没有一种设计对所有任务最好。语言很少变化、视觉需要高频更新时，还可以缓存静态条件，但缓存必须与当前任务和观测一致。

读懂检查：一张架构图上的“视觉 backbone + language token + action head”不够。你还应追踪模态在哪里交互、哪个模块更新、动作查询能看见哪些信息，以及训练和部署是否使用同样条件。

4. BC：简单方法为什么仍是重要基线

4.1 最直接的监督目标

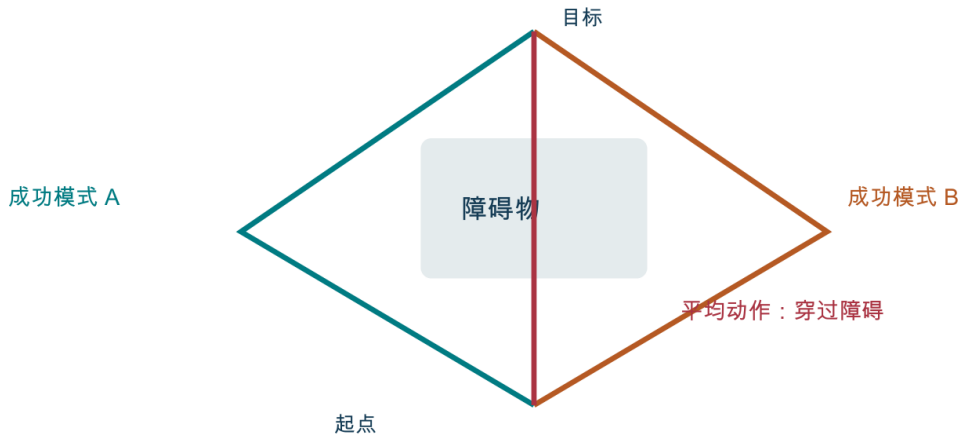
BC 学习 a_hat = πθ(c)，用专家动作 a 作标签。如果输出是确定性连续值，可以使用 L1（绝对误差）或 L2（平方误差）；如果输出概率分布，可以使用负对数似然；扩散和流匹配也能用于模仿学习，但使用不同监督构造。

平方误差例子：对一个动作维，专家为 0.3，预测为 0.1，误差平方是 0.04。多维动作要考虑尺度和重要性。闭环成功还取决于误差在哪些阶段出现：远离障碍时差一厘米，与插孔时差一厘米，后果不同。

4.2 多模态：一个条件可能允许多个正确动作

图 3 | 两种成功动作的平均值可能失败

示意：绕过中央障碍，左右都可行；图中路径不是实验结果。



教学示意：按功能解释，不代表所有方法具有相同网络结构。

图中左右绕行都是专家可行模式。确定性均方回归在理想化情况下倾向条件均值；当数据同时包含左右动作，这个均值可能穿过障碍。这里没有说所有回归策略都会失败，而是说明“用单点平均表达多种合理行为”可能不合适。

可以用多模态概率分布、潜变量、扩散或流匹配表达多个行为模式。生成动作分布有助于减少平均化问题，但仍需选择样本、保持时间连贯，并满足物理约束。随机性不是任务成功的保证。

4.3 协变量偏移：训练时跟着专家，部署时跟着自己

Covariate Shift（协变量偏移）在这里指策略访问的状态分布与演示不同。第一次抓偏一点，第二次更陌生，第三次可能完全偏离。增加演示可以补覆盖，但不一定覆盖所有失败后的状态。

DAgger（Dataset Aggregation，数据集聚合）是一类补救思路：让当前策略执行，请专家在它遇到的状态给出动作标签，再将数据加入训练。专家标签可以来自遥操作或可用控制器；现实中查询成本和干预风险要单独考虑。

```
先用初始演示训练策略
重复:
  让当前策略访问环境状态
  获取这些状态下专家应采取的动作
  聚合新标签与旧数据
  重新训练 / 更新策略
用独立任务检验恢复与泛化
```

这个过程补的是状态覆盖，不是简单把原演示复制更多遍。若没有可用专家，不能直接把它当成免费的训练改进。

4.4 Loss 低却抓不到，怎么逐层定位

先看相机图像和动作标签是否正确；再看反归一化动作是否落在合理范围；检查单步预测能否对齐专家；然后观察闭环何时偏离；最后按抓空、碰撞、滑落、进度丢失等模式分类。数据损坏、接口错配、模型表达不足和状态分布偏移需要不同改进。

读懂检查：为什么某个复杂模型必须与小 BC 基线比较？因为只有在相同数据和协议下超越简单拟合，才能判断复杂机制是否有实际收益。

5. ACT：把潜变量、动作分块与融合分开理解

5.1 三个设计分别解决什么

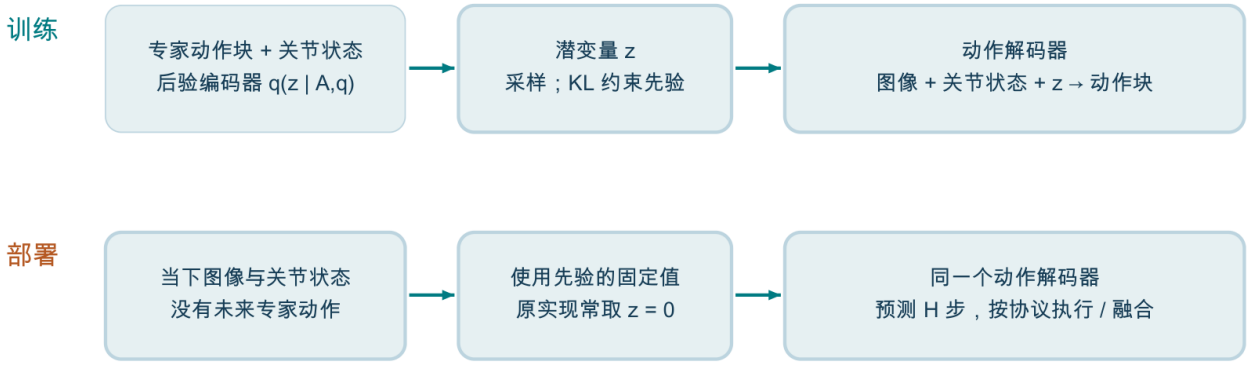
ACT（Action Chunking with Transformers）用 Transformer 一次预测一段动作。它还通过 CVAE（Conditional Variational Autoencoder，条件变分自编码器）建模演示中不完全由当前观测解释的变化；部署可进行 Temporal Ensembling（时间集成），融合不同推理时刻对同一执行时刻的预测。

动作分块表达局部连贯行为；潜变量帮助训练时解释不同演示风格；时间集成减少部分动作不连续。三个机制不能互相替代。动作分块本身不提供长期记忆，也不自动解决所有分布外状态。

5.2 训练图：为什么要把专家未来动作送进一个编码器

图 4 | ACT 的训练与部署不是同一个输入图

ACT = Action Chunking with Transformers；CVAE = Conditional Variational Autoencoder



z 表示示范的未观测变化；训练有后验，部署无法读取专家未来。

教学示意：按功能解释，不代表所有方法具有相同网络结构。

原始 ACT 参考实现的后验编码器读取专家动作块和当前关节状态，得到潜变量分布的均值 μ 和对数方差 log σ²。通过重参数化 z = μ + σ × ε 采样，其中 ε 来自标准正态分布。这样能将随机采样的梯度路径写成可学习变换。

动作解码器接收图像特征、关节状态和 z，预测未来动作块。z 可以解释同一观测下演示中的未观测差异；它不是杯子的完整物理状态，也不是长期任务数据库。

教学目标：L_ACT = L_reconstruction + β × KL(q(z | A,q) || N(0,I))。重建项比较预测与专家动作；KL（Kullback-Leibler Divergence，KL 散度）约束后验不要任意偏离标准正态先验；β 控制权重。

参考代码使用有效步上的 L1 动作差异与 KL 项。β 太弱时，后验可能过分依赖训练未来；太强时，潜变量可能被忽略。具体调参还要看数据、实现和任务成功，不能只根据一句原理给固定数值。

5.3 部署图：没有专家未来，潜变量从哪里来

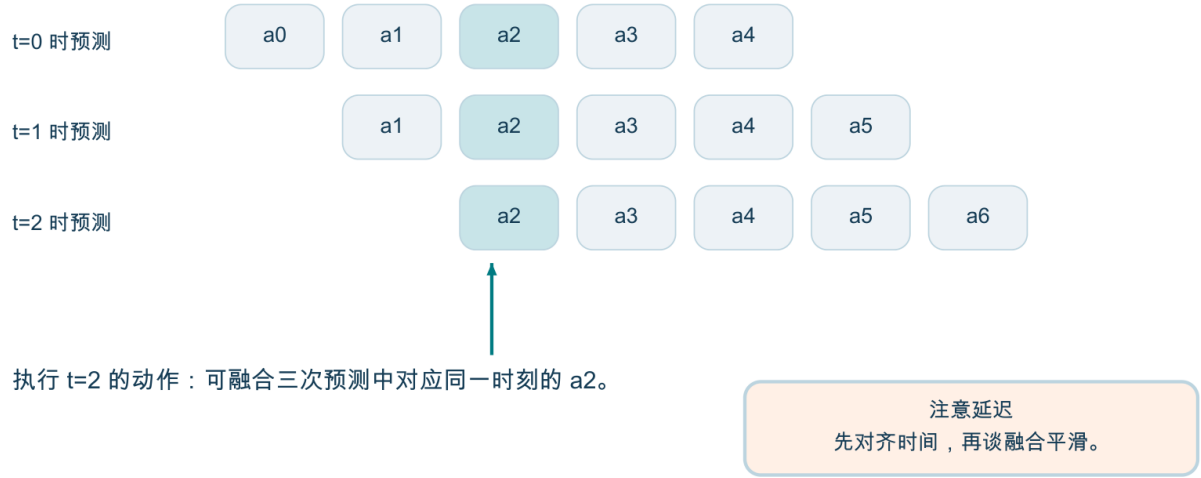
部署时专家未来动作不可用，因此不运行这个后验编码器。原始 ACT 常将 z 固定为零，通过同一个动作解码器输出动作块。零是先验的中心值，不能解释为“把机器人关节置零”。一些变体可能使用不同策略，应查实现。

ACT 被称为带潜变量的生成式模型，不意味着官方部署每次都随机采样很多动作并挑最优。训练结构和使用方式必须分别理解。

5.4 分块长度 H、执行间隔 K 与时间集成

图 5 | 动作分块与重叠融合：三种长度不要混淆

H：预测长度；K：执行后重观测间隔；n：生成器内部求解步数



教学示意：按功能解释，不代表所有方法具有相同网络结构。

t=0 预测未来多个动作，t=1 又预测一段；到 t=2 时，它们各有一个对应 t=2 的预测。时间集成融合的是“同一执行时刻”的这些预测，不能把 t=2 与 t=5 的动作随意平均。

可以示意为 a_t = sum_i w_i a_hat_t^(i) / sum_i w_i，i 表示不同推理时刻的预测。权重规则依实现而定；越新越可信或越旧越平滑都不是通用定律。

如果 H=20，K=4，代表一次预测 20 步，执行前 4 步后重新观测；不是每次无反馈执行整段。时间集成模式也可每步推理。H 越大，长期标签和计算负担越大；K 越大，重规划更少，但反馈更迟。

5.5 训练与部署伪代码

```
训练:
  读取当前图像、关节状态、专家未来动作块
  后验编码器生成 μ, log方差
  重参数化采样 z
  动作解码器(图像, 关节状态, z) → 动作块
  有效步 L1 + β × KL → 更新参数

部署:
  读取最新图像与关节状态
  z = 先验的固定中心值（原始 ACT 常为零）
  解码得到未来动作块
  反归一化；按部署协议执行或融合
  重新观测
```

读懂检查：你能否解释图中的“专家动作作为训练输入”为什么不等于作弊，以及部署如何移除对它的依赖？若只记住“一次输出一段动作”，还没有真正读懂 ACT。

来源：ACT 主页与论文、原始策略损失代码、后验与动作解码器。本章解释原始结构，XPolicyLab 适配器与后来变体可能有额外差异。

6. Diffusion Policy：去噪的是动作，不是机器人世界

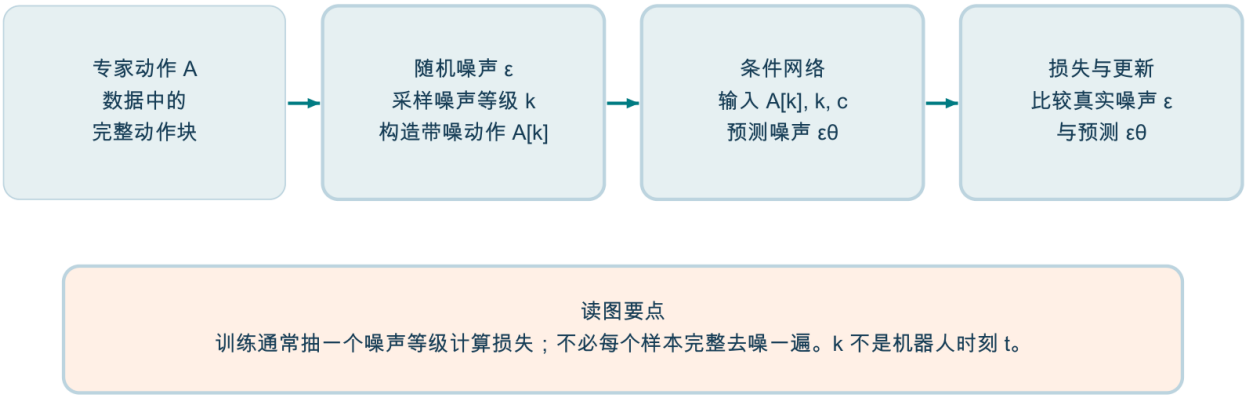
6.1 三种“时间”要先分开

机器人交互时刻 t、动作块中未来位置 h、扩散噪声等级 k 是不同索引。一张图若写 “step”，先问它是哪一种步数。训练时间标签 k 不是“机器人执行第 k 个动作”。

Diffusion Policy（扩散策略）学习条件动作分布，条件 c 包括观测及任务信息，生成对象是未来动作块 A。它可以使用卷积时序网络或 Transformer 去噪器，网络类型与扩散监督不是同一层。

6.2 训练：为何预测噪声也能学会动作分布

图 6 | 扩散训练学的是去噪映射



教学示意：按功能解释，不代表所有方法具有相同网络结构。

一种常见噪声预测形式为 A_k = sqrt(α_bar_k) A + sqrt(1 - α_bar_k) ε。A 是专家动作，ε 是标准正态噪声；α_bar_k 由噪声日程决定，控制保留多少数据。网络 εθ(A_k,k,c) 预测加进去的噪声。

教学损失：L_diffusion = E[||ε - εθ(A_k,k,c)||²]。平方差监督的目标是噪声，不是直接把不同专家动作取平均。网络在不同噪声等级学习条件去噪关系，配合相应反向采样过程恢复动作分布。

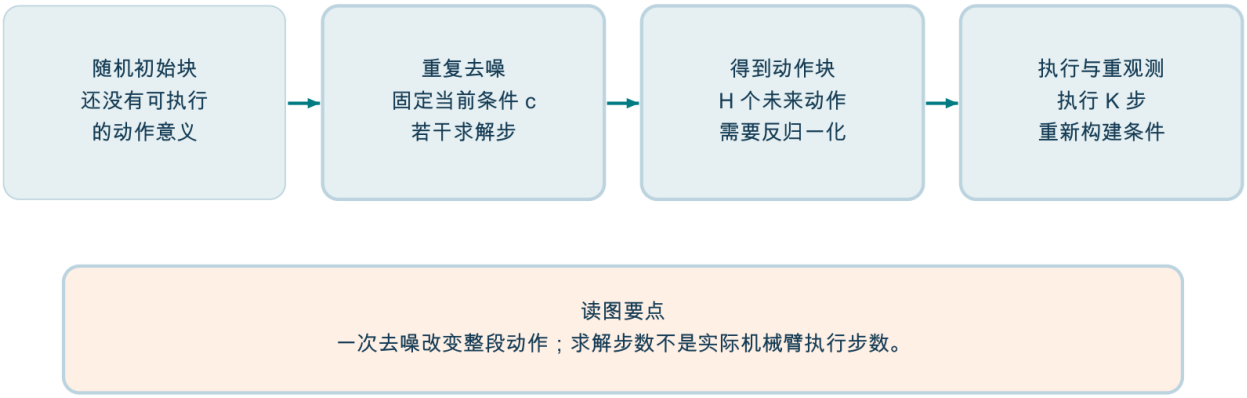
原理直觉：轻噪声时修细节，重噪声时依条件组织整体动作。这个描述帮助理解，不代表每个模型都有可解释的“粗规划层”和“精修层”。一些方法预测干净样本或速度而非噪声，推理更新式必须与训练参数化匹配。

```
采样专家动作块 A 与条件 c
采样噪声等级 k 和随机噪声 ε
按日程构造 A_k
网络预测 ε_hat
比较 ε_hat 与 ε，更新参数
```

训练通常随机选一个 k 计算损失，不必对每个训练样本完成一次全程去噪。这就是为什么训练图与推理图不同。

6.3 推理：一次求解改变整段动作

图 7 | 扩散部署从随机动作噪声开始



教学示意：按功能解释，不代表所有方法具有相同网络结构。

部署从随机动作噪声开始，固定当前条件 c，经若干去噪步得到动作块。随后反归一化，执行前 K 步，再根据新观测重新生成。一次去噪更新整段张量，不对应夹爪的一次物理动作。

```
c = 编码当前观测与必要历史
A = 标准正态随机动作块
for k in 规定的反向噪声日程:
    ε_hat = 去噪网络(A, k, c)
    A = 对应采样器的一步更新(A, ε_hat, k)
反归一化 A
执行前 K 步；获取新观测
```

DDPM（Denoising Diffusion Probabilistic Model）与 DDIM（Denoising Diffusion Implicit Model）代表不同采样建模 / 求解路线。减少采样步可能降低延迟，也可能损伤质量；蒸馏或一致性方法尝试减少迭代成本，但需要额外训练与验证。不要只改循环次数而忽略采样器配置。

6.4 它有什么优点，又没有解决什么

扩散较适合表达多个可行动作模式，并联合生成连续动作序列。但观测或数据不正确时，去噪也会生成错误动作；碰撞与动作限制也不会自动满足。采样随机性、迭代延迟和反馈频率需要与任务配合。

DP3（3D Diffusion Policy，三维扩散策略）主要改变视觉 / 空间条件表示，引入点云等信息。是否更好，取决于几何需求、点云质量、相机设置和计算预算，不是“3D”三个字自动提高所有任务成绩。

读懂检查：扩散策略与视频扩散世界模型的区别是什么？前者生成动作，后者生成观测或未来表示；共享扩散机制不意味着共享用途。

来源：Diffusion Policy 原论文与项目、代码、DP3。

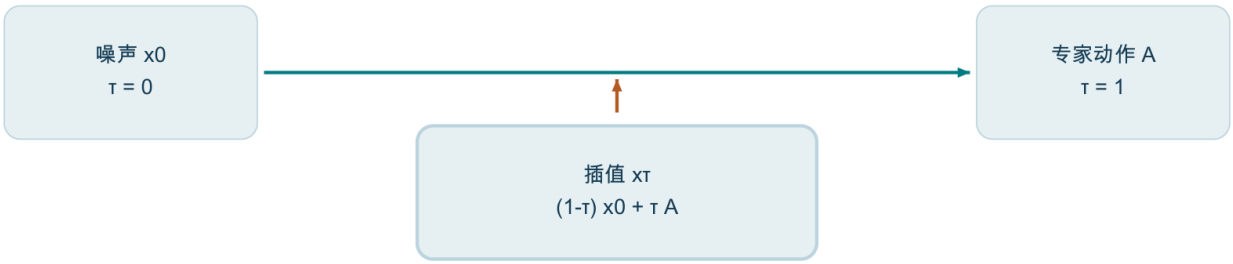
7. 流匹配：从噪声到动作学习一条连续路径

7.1 训练的标签是速度场，不是实际关节速度

Flow Matching（流匹配）学习一个连续变化的向量场，让随机噪声逐渐变成符合条件的动作样本。这个向量场定义在动作块的生成空间中；它的“速度”不等于机械臂在真实时间里转动的速度。

图 8 | 流匹配：学习从噪声到专家动作的方向

采用教学约定：τ=0 是噪声，τ=1 是数据；具体实现可能采用相反方向。



监督速度：u = A - x0

训练拟合速度场；推理通过数值积分生成动作块。

教学示意：按功能解释，不代表所有方法具有相同网络结构。

采用一种便于理解的约定：τ=0 是噪声 x0，τ=1 是专家动作 A，定义 $x_\tau = (1-\tau)x_0 + \tau A$。τ 是生成过程的插值时间，不是机器人交互时刻 t。直线路径的目标速度为 $u = A - x_0$。

网络 $v_\theta(x_\tau,\tau,c)$ 根据带噪动作、生成时间和条件，预测这个变化方向。教学损失为 $L_{flow} = E[\ ||v_\theta(x_\tau,\tau,c) - (A-x_0)||^2\ ]$。它没有要求模型在部署时获得专家 A；A 只用于训练构造样本和监督。

“直线路径”指训练时两个样本之间的插值构造，不意味着推理轨迹一定是直线，更不意味着机器人应该沿空间直线抓杯子。学习到的条件向量场与数值求解共同决定生成结果。

7.2 推理的数值积分到底在更新什么

推理从噪声出发，通过 ODE（Ordinary Differential Equation，常微分方程）求解器积分 $dx/d\tau = v_\theta(x,\tau,c)$，得到动作块。最简单的欧拉步可示意为 $x_{next} = x + \Delta\tau \times v_\theta(x,\tau,c)$。具体模型可能使用相反的时间方向、其他路径或更好的求解器，应与训练定义一致。

```
训练:
  采样专家动作块 A、噪声 x0、插值时间 τ
  xτ = (1-τ)x0 + τA
  监督网络预测 A-x0

部署:
  x = 随机噪声动作块
  for τ in 求解网格:
    x = 数值积分的一步(x, 网络预测速度, 步长)
  反归一化；执行前 K 步
```

整个 H×d 动作块在每个求解步一起更新。这与扩散策略同样需要区分“生成内部迭代”和“实际动作执行”。减少积分步数可降时延，但效果要通过动作质量与闭环成功检验。

7.3 扩散、流匹配与动作回归怎样比较

确定性回归直接预测一个动作或动作块；扩散与流匹配从简单随机分布生成条件样本。后两者有相关理论联系，但训练参数化、路径、日程和求解器并不完全相同。不要仅凭“都从噪声开始”将代码混用。

对偏算法的学习者，比较时先固定条件编码器与数据，再看动作分布表达、生成成本、优化稳定性和反馈频率。复杂生成器在小而单一的任务上未必优于简单回归；多种可行动作、丰富数据和复杂条件可能增加它的价值。

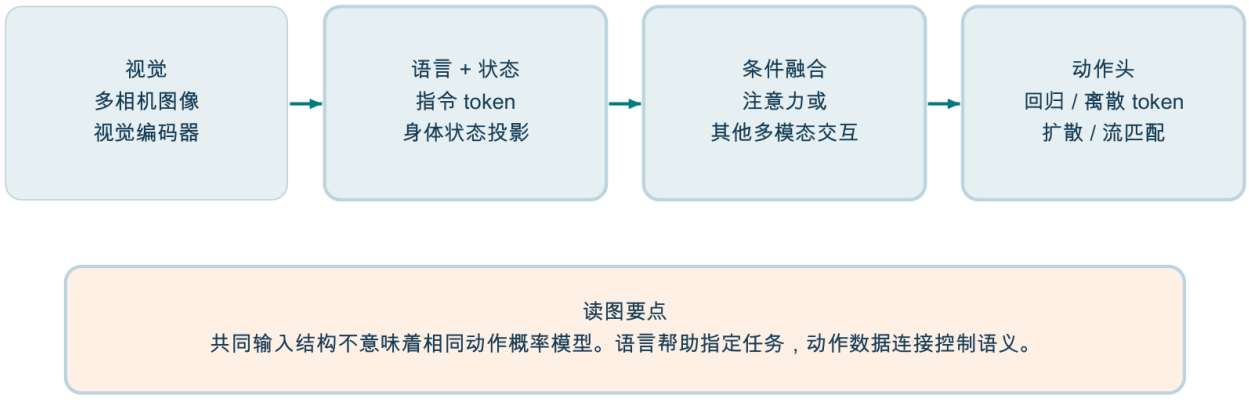
读懂检查：图中的 τ、机器人时刻 t、动作块长度 H 与执行间隔 K，你能否分别指出？不能分开时，读动作生成论文会反复混淆。

8. VLA：共同的输入骨架，不同的动作概率模型

8.1 视觉语言能力如何延伸到动作

VLM（Vision-Language Model，视觉语言模型）处理图像与语言；VLA（Vision-Language-Action，视觉语言动作模型）进一步与动作生成关联。视觉语言预训练提供语义与表示，机器人数据把这些条件与具体动作接口连接起来。识别“杯子”不等于已经知道该机械臂如何控制夹爪。

图 9 | VLA 的共同骨架与可替换动作头



教学示意：按功能解释，不代表所有方法具有相同网络结构。

一种常见路线是视觉编码器提取图像 token，语言 tokenizer（词元化器）产生指令 token，身体状态经投影变成条件；网络融合后交给动作头。实际可以是统一 Transformer、双专家、独立动作解码器或其他结构。

输入里没有语言的视觉动作策略有时称 VA（Vision-Action）。语言通常是任务条件之一：同一桌面可以要求“拿红杯子”或“把碗向右推”。如果测试所有指令都对应同一动作，模型忽略语言也可能得高分；应设计目标冲突、颜色变化等检验。

8.2 离散动作 token：把控制问题改写成序列预测

一种方法将连续动作的每个维度划到离散区间，模型预测对应 token，再转换回连续值。若范围为 [-1,1]、256 个区间，教学例子中一个区间宽度约为 2/256。真实 tokenizer 可能使用分位数、压缩编码或联合表示，不能把这个例子当成所有模型的配置。

自回归预测写为 p(A | c) = product_j p(token_j | c, token_<j)。训练使用 Cross-Entropy（交叉熵）监督，并常用 Teacher Forcing（教师强制）：前文来自真实 token；推理前文来自自己生成的 token。预测误差可以在 token 序列中累积。

离散动作有利于接入现有语言模型训练框架，但量化误差、token 数量与生成延迟影响控制。更细的离散区间提升表示精度，也可能增加学习负担。动作 tokenizer 是把机器人动作组织成模型单位，不是简单将数值打印成字符串。

原始 OpenVLA 是理解这条路线的重要入口，其后续动作分块、并行解码或优化变体应分别看实现。不能把某一版本的推理行为外推到所有带同名词的模型。

8.3 连续动作头：视觉语言主干与生成器怎样分工

π0 系列提供流匹配动作头的代表例子；openpi 中 π0-FAST 使用自回归方式与 FAST（Frequency-space Action Sequence Tokenization，频域动作序列词元化）表示。FAST 是动作表示工具，不是一个机械臂控制器，也不等于流匹配求解器。

一个模型家族可以同时存在不同动作头。比较“π 系列”和“自回归”时不能把家族名称当成互斥分类。更稳妥的标签是：条件含哪些模态，动作如何表示，使用何种生成机制，预测与执行长度是多少。

连续动作生成器可以接受视觉语言主干提供的条件表示。冻结主干、训练动作头，可以节省成本；一起微调可以让表示适配动作，但会增加训练开销和遗忘风险。不同设计对梯度传播、缓存和动作延迟都有不同影响。

8.4 大规模预训练、微调与部署为何不能只看参数量

预训练学习多任务、多场景行为；SFT（Supervised Fine-Tuning，监督微调）用目标数据更新模型；LoRA（Low-Rank Adaptation，低秩适配）等 PEFT（Parameter-Efficient Fine-Tuning，参数高效微调）只训练部分增量。它们降低部分更新成本，却不能消除基础权重、激活、渲染和数据加载开销。

多本体训练还要处理动作空间、维数、单位和相机差异。可以通过本体条件、独立输出头、统一动作表示、填充掩码等方法组织，但没有一种简单格式就能让所有本体动作等价。一个机器人能抬起的杯子，另一个机器人可能因为抓爪宽度不可达。

“零样本”需要说明没有针对哪种目标训练：新场景、新对象、新任务还是新本体。模型在公开数据里见过相似任务，不等于严格未见；不同数据来源还可能共享轨迹。

8.5 模型清单如何变成理解清单

方法入口	优先理解的机制	先问的一个问题
ACT	动作分块、CVAE、时间集成	训练与部署的潜变量来源一样吗？
Diffusion Policy / DP3	条件动作去噪、空间条件	生成对象和噪声等级是什么？
OpenVLA	视觉语言表示、动作 token	连续动作如何被编码与还原？
π0 / openpi	流匹配动作头、条件与微调	内部积分步数与反馈周期如何设置？
Octo	通用条件策略与扩散式动作生成	缺失模态、目标条件如何组织？
RDT-1B	Robotics Diffusion Transformer，大规模机器人扩散 Transformer	跨本体动作信息怎样表示？
GR00T 系列	跨本体条件、动作生成与系统分工	具体版本实际输出什么控制量？

这里列方法作为机制锚点，不构成最新能力排序。GR00T 等品牌名称保留官方名称，不为每个字符编造全称。

读懂检查：一个新 VLA 有更高成功率，你能否区分收益来自表示、动作头、更多数据、执行频率还是后训练？没有对照实验不能把所有收益归给主干。

来源：OpenVLA、openpi、π0 论文、FAST 论文、Octo、RDT。

9. RL：奖励、价值、优势与策略更新

9.1 强化学习与行为克隆的根本区别

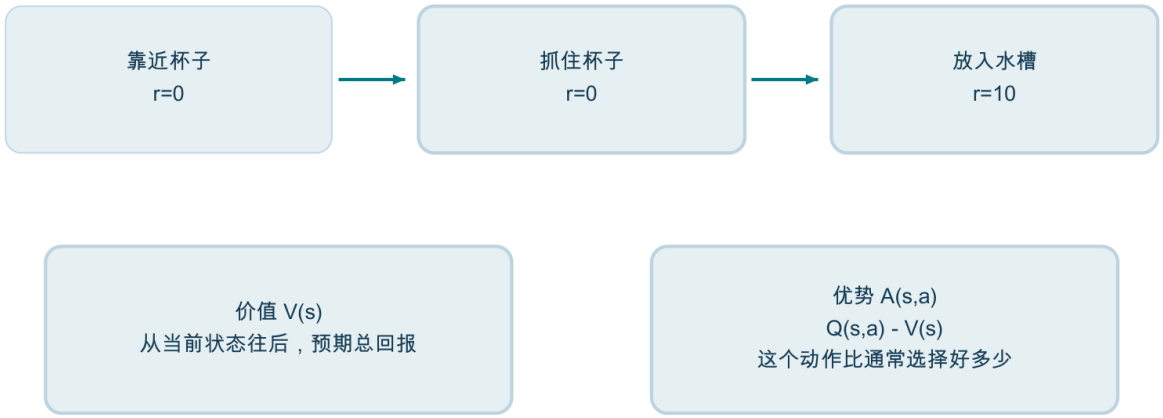
RL（Reinforcement Learning，强化学习）优化交互产生的长期回报，而不是要求每个状态复制专家标签。示意目标 $J(\pi) = E[\sum_t \gamma^t r_t]$，$\gamma$ 是折扣因子，r_t 是奖励。奖励来自任务设计或其他可信评价信号，不一定是人的实时打分。

MDP（Markov Decision Process，马尔可夫决策过程）用状态、动作、转移、奖励和折扣描述问题；POMDP（Partially Observable Markov Decision Process，部分可观测马尔可夫决策过程）强调机器人只看到部分观测，需要历史或状态估计。把单帧图像当作充分状态是建模假设，不总成立。

9.2 Reward、Return、Value、Q 与 Advantage

图 10 | 奖励、价值与优势：在不同时间尺度上打分

数字是教学例子，假设折扣 γ = 1，且价值估计恰好给定。



教学示意：按功能解释，不代表所有方法具有相同网络结构。

Reward（奖励）是当前反馈；Return（回报）是此后累计的奖励；Vπ(s) 是从状态 s 开始按策略 π 行动的预期回报；Qπ(s,a) 是先采取动作 a、之后按 π 行动的预期回报。Advantage（优势）Aπ(s,a)=Qπ(s,a)-Vπ(s) 衡量这个动作相对于该状态通常表现好多少。

例子：从抓杯子的状态开始，常规策略预计能得到 6 分，某个稳健动作的预期 Q 值是 8，优势为 +2。它不是“动作准确率 2%”，而是在当前奖励定义下的相对收益。V 与 Q 都是估计值，可能偏差很大。

Critic（价值评价器）学习预测回报，Actor（策略网络）产生动作。这里 Critic 不是语言模型写一句评价，而通常是可学习的数值函数。Actor-Critic（策略与价值联合学习）利用评价信号更新策略。

9.3 Bellman 关系把长期问题拆成一步

一个基本关系是 Vπ(s)=E[r + γVπ(s_next)]。它说长期价值等于当前奖励加后续折扣价值。用网络估计价值时，可以构造一步目标 y=r+γ(1-d)V_target(s_next)，其中 d 表示真正终止。

如果是时间预算截断，而不是任务真实结束，是否允许 bootstrap（用估计后续价值接续）取决于问题定义。把所有超时都当作真正终止，可能系统性压低价值；相反，已经成功结束却继续接续也会错。

TD（Temporal Difference，时间差分）误差可写成 δ=y-V(s)。这个误差用于学习价值，并与某些优势估计有关。它不是物理时间差，而是当前估计与一步更新目标的差异。

9.4 为什么策略梯度会提高较好动作的概率

一个示意梯度为 E[gradθ log πθ(a|s) × A(s,a)]。优势为正时，提高该动作的概率；优势为负时，降低其概率。减去基线可以减少估计方差，但基线与优势估计本身也可能不准确。

PPO（Proximal Policy Optimization，近端策略优化）常用概率比值 ρ=πθ(a|s)/π_old(a|s) 和裁剪目标限制一次更新幅度。它不是严格保证全局最优，也不是把机器人动作幅度直接裁小。概率更新裁剪与动作物理限幅是不同层。

GAE（Generalized Advantage Estimation，广义优势估计）组合多步时间差分信号，在偏差与方差之间取舍。初学阶段先理解它为“利用轨迹估计相对回报”，后续再推导公式。

9.5 奖励塑形与探索的实际问题

只在成功时给奖励，训练可能很少见到有效信号；增加距离、姿态、稳定性奖励，可以帮助学习，但策略也可能利用漏洞。奖励夹爪高度，机器人可能空手抬起；奖励杯子移动，机器人可能把杯子撞飞。

Sparse Reward（稀疏奖励）与 Dense Reward（稠密奖励）描述信号分布；Reward Shaping（奖励塑形）设计额外反馈。任何塑形都要检查是否鼓励真正目标，以及在独立成功判据下有没有收益。

探索需要有机会发现更好动作。现实机器人每次重置都可能耗费人力；大量失败轨迹也可能有风险和磨损。并行仿真可降低采样成本，但仿真动力学、渲染和动作接口必须足够匹配任务。

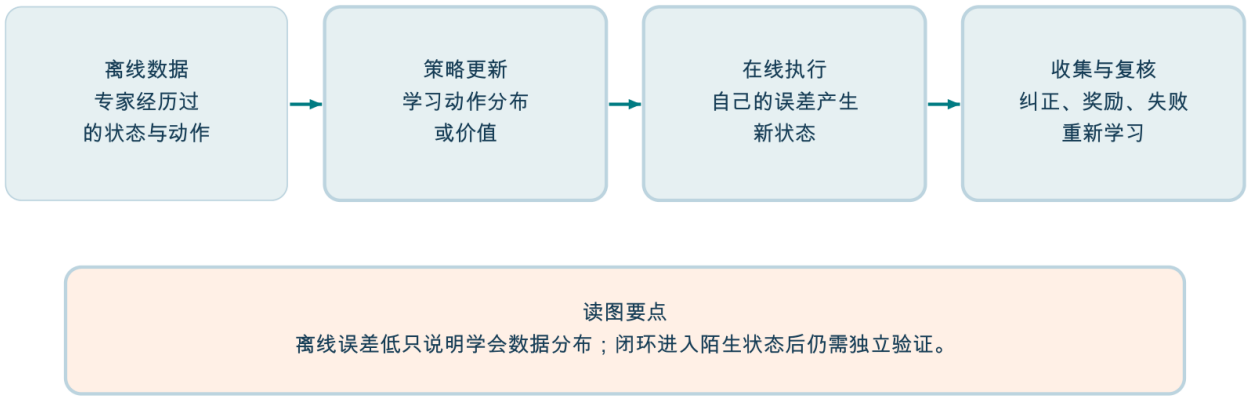
读懂检查：高奖励却低成功率可能说明什么？可能是奖励错位、终止处理错误、价值估计偏差或评测协议不同，不能简单判定“模型需要更大”。

10. 离线 RL 与后训练：为什么不能直接给生成策略套 PPO

10.1 On-Policy、Off-Policy、Offline、Online 是两组轴

On-Policy（同策略）与 Off-Policy（异策略）讨论更新所用数据与当前策略的关系；Offline RL（离线强化学习）只用固定数据训练；Online RL（在线强化学习）持续交互收集新经验。在线算法也可以使用经验回放，因此在线不等于同策略。

图 11 | 离线评估与在线闭环的状态分布不同



教学示意：按功能解释，不代表所有方法具有相同网络结构。

Replay Buffer（经验回放池）存储交互供训练采样。离线数据可以含专家、随机策略和失败轨迹。BC 直接拟合动作，离线 RL 还试图借奖励与价值改进动作选择。

10.2 离线价值为什么容易高估未见动作

数据只记录采取过的动作，价值网络可能对未见动作胡乱给高分；策略优化又会主动选择这些高分区域。于是价值误差被策略利用，产生 Distribution Shift（分布偏移）。保守估计、行为约束或数据支持内优化等方法试图减轻这类问题。

不要理解成“有失败数据，RL 就能自动学会恢复”。失败轨迹能提供反馈，但如果缺少可成功的替代行为、奖励不能区分恢复、价值估计不可靠，仍然难以学会。

10.3 生成动作策略的概率接口与后训练方法

标准 PPO 需要动作概率或可用的对数概率比值。流匹配与扩散策略通过多步生成过程输出动作，不能直接把网络输出速度或预测噪声当作 log π(a|s)。这不表示生成模型在数学上绝对没有密度，而是现成训练接口未必能提供适合策略梯度的精确、可负担概率计算。

后训练可采用不同路径：用优势加权或优势条件化学习；在基座之外学习动作残差；选择或优化初始噪声；用改进策略采集数据再蒸馏；为生成过程建立合适概率目标。它们更新的对象不同，不能统一称为“套 PPO”。

Residual Policy（残差策略）在已有动作上加调整，便于限制改动，但基座差时残差不一定能救回来。Distillation（蒸馏）把教师行为或改进轨迹学到部署策略中，便于运行，但教师的偏差与数据覆盖也会传给学生。

10.4 一套可解释的后训练实验

先用同一个预训练权重做 BC / SFT 基线，再固定任务和计算预算比较后训练方法。分开报告新交互量、人类干预、奖励、独立成功率和延迟。若后训练用了更多任务数据，不能把全部收益都说成算法更优。

读懂检查：你研究的后训练到底更新主干、动作头、残差、初始噪声分布还是数据配方？要能指出图中的具体对象。

11. 世界模型：学动态，再决定怎样利用动态

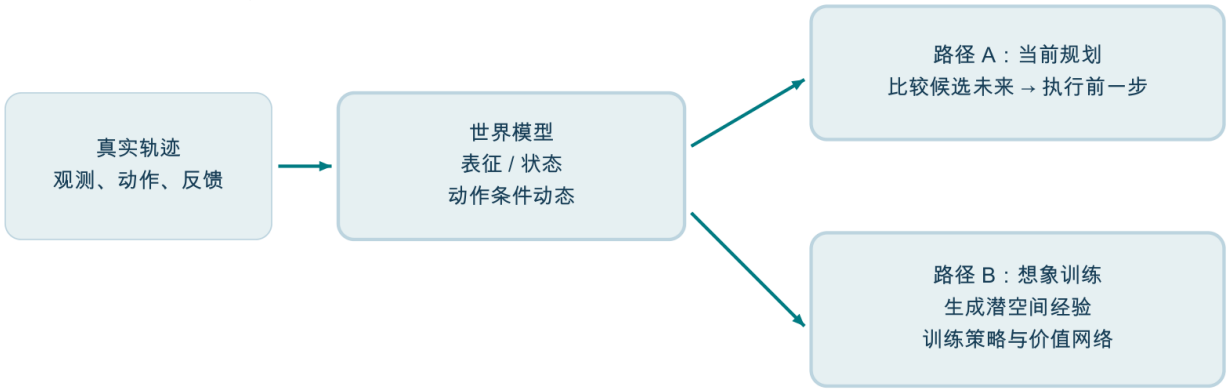
11.1 最小定义与动作条件

WM（World Model，世界模型）预测环境在时间与动作作用下的变化。最简单形式是 z_next = fθ(z,a)，其中 z 是观测编码后的状态表示，a 是候选动作。随机模型预测的是分布，历史模型还包含记忆。

只预测“常见视频接下来怎样”，与预测“这个机器人执行某个动作后怎样”，不是同一问题。前者可学外观与一般动态，后者需要可靠的动作条件、时间对齐和本体关联。潜在动作可以连接两种数据，但必须验证怎样映射到可执行指令。

图 12 | 世界模型：两条使用路径

学习动态与利用动态是两件事；图中模块按用途添加。



A 的部署成本来自搜索；B 的成本主要在训练，部署可直接用策略。

教学示意：按功能解释，不代表所有方法具有相同网络结构。

图中的动态模型不自动决定动作。路径 A 是当前使用模型规划；路径 B 是用想象轨迹训练策略。世界模型还可以只作为辅助学习目标，训练更好的表示而在部署时不运行预测分支。

11.2 预测对象：像素、特征、对象、网格与几何

预测像素提供丰富视觉信息，也消耗很多资源；预测特征压缩成本，但依赖编码器保留任务所需量；对象状态让位置、接触等易检查，但对象识别和结构先验更强；网格保留空间邻接，分辨率与范围影响内存；几何场提供可渲染空间表示，但动态与接触还需另建机制。

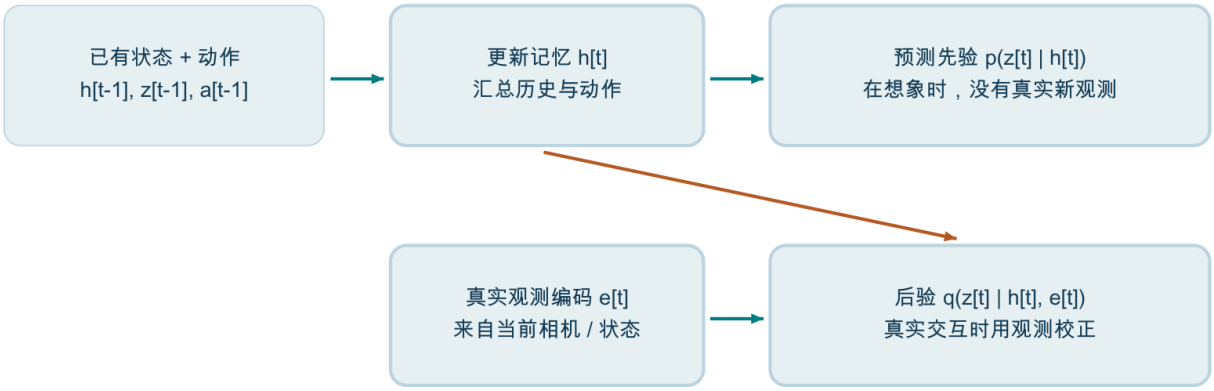
假设杯柄是关键，编码器却只保留“这是一只杯子”的语义，特征预测再准确，也可能不够精确地控制夹爪。于是学习目标不能只问“预测误差多少”，还要问“预测表示包含什么，对任务是否充分”。

11.3 RSSM：先预测，再用观测校正

RSSM（Recurrent State-Space Model，循环状态空间模型）结合确定性记忆 h 与随机状态 z。h 汇总历史和动作，z 表达模型对当前状态的随机变化或不确定估计。它不是简单地把所有原图存进缓存。

图 13 | RSSM：记忆、先验与观测校正

RSSM = Recurrent State-Space Model；h 为确定性记忆，z 为随机状态。



训练比较预测与实际，并约束先验 / 后验；世界模型潜变量 z 与 ACT 的 z 不同。

教学示意：按功能解释，不代表所有方法具有相同网络结构。

一个教学形式是：h_t = F(h_(t-1),z_(t-1),a_(t-1))；先验 pθ(z_t|h_t) 在没有新观测时预测状态；后验 qθ(z_t|h_t,e_t) 加入真实观测编码 e_t，校正估计。

真实训练或环境交互时有 e_t，可用后验；想象未来时没有真实未来观测，只能依赖预测先验。训练需要使先验逐步学会跟上由观测校正的状态，并保留可预测任务信息。先验与后验的差异是世界模型训练中的关键问题之一。

这里 z 与 ACT 的潜变量 z 不同。ACT 的 z 主要解释演示动作变化；RSSM 的 z 属于时序状态建模。同一个字母不意味着模型共享同一功能。

11.4 损失由用途决定，不是把所有损失都加上

常见目标包括观测重建、特征或状态预测、奖励预测、终止 / 继续概率预测、先验后验 KL、多步一致性。像素重建关注外观，奖励头关注任务信号，动态一致性关注展开稳定。

教学形式可以写作 L_WM = L_prediction + λ_r L_reward + λ_d L_continue + λ_kl L_KL。这只是功能示意，不是 DreamerV3 的完整官方损失；实际实现可能使用梯度分离、分布参数化、不同尺度处理和额外正则。

JEPA（Joint Embedding Predictive Architecture，联合嵌入预测架构）强调预测表示而非完整像素。V-JEPA（Video Joint Embedding Predictive Architecture）是视频表示路线。DINO-WM 利用预训练视觉特征学习动态与规划；DINO 本身是视觉表征模型，不能直接等同于动作条件世界模型。

Collapse（表示坍缩）意味着所有不同观测都被编码成近乎相同特征。预测这种特征很容易，但没有任务信息。停止梯度、教师编码器、表示约束或预训练结构等方法可缓解，具体要看方法。低损失本身不能排除坍缩。

11.5 Dreamer：在想象经验里训练动作策略

Dreamer 系列在真实经验上学习潜空间世界模型，再从真实历史估计的状态出发，使用模型预测先验展开想象轨迹。奖励预测与价值估计支持策略更新；部署时通常依据观测更新模型状态，并由策略选择动作。

“想象训练”不是凭空编造知识，而是借已学动态生成额外训练信号。如果动态对某些动作错误，策略可能在想象中高分、真实环境失败。限制展开长度、增加真实覆盖、改进估计与独立验证都可能重要。

```
真实环境收集经验 → 更新世界模型
从真实经验中抽取起始状态
在模型中用当前策略产生动作与未来状态
预测奖励与继续概率，估计回报
更新 Actor / Critic
重新到真实环境检查效果，补充经验
```

它与 MPC 不同：不是部署每一步都必须搜索很多候选；主要在训练时利用模型优化策略。实际算法可以组合两种思想。

11.6 分层指标：预测像、动态准、控制好

PSNR（Peak Signal-to-Noise Ratio，峰值信噪比）、SSIM（Structural Similarity Index Measure，结构相似性指标）反映部分图像差异；FVD（Fréchet Video Distance，弗雷歇视频距离）比较视频特征分布。它们有用，但不能证明接触和动作因果正确。

还应看位置 / 姿态误差、多步误差、动作敏感性、对象持续存在、碰撞预测、任务成功、延迟与校准。对比两个不同动作时，预测是否合理改变，特别能帮助检查模型是否忽略了动作条件。

读懂检查：你的世界模型在哪个表示空间预测、怎样获得动作条件、部署是否需要运行、最终提升哪个任务指标？若只能回答“生成视频很逼真”，还没有完整解释用途。

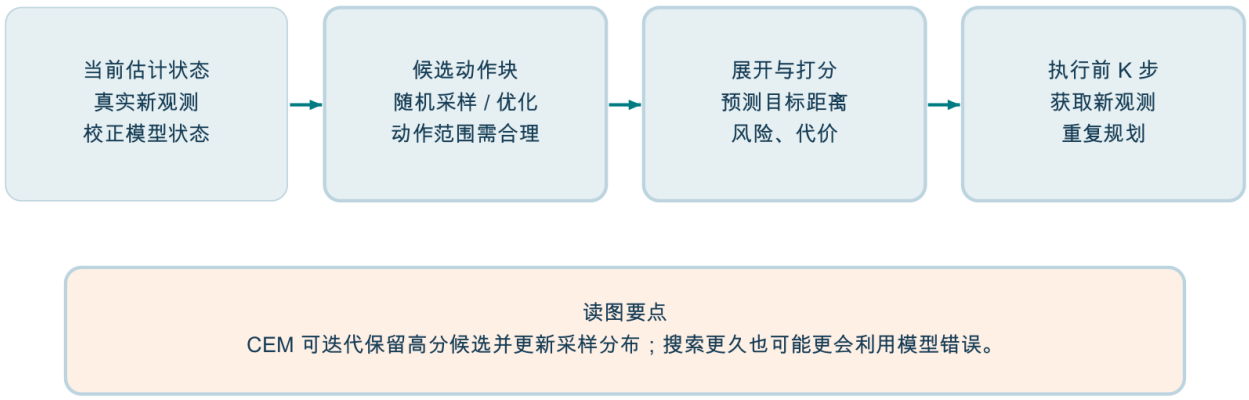
来源：DreamerV3、DINO-WM、V-JEPA 2，以及随包 P4 世界模型综述。

12. MPC 与搜索：预测怎样变成下一次动作

12.1 用一个小数字例子走一遍规划

MPC（Model Predictive Control，模型预测控制）从当前估计状态出发，优化未来一段动作，只执行一部分，再根据新观测重规划。动态模型可以是已知方程或学习世界模型；因此 MPC 不等于神经世界模型。

图 14 | MPC 搜索：执行计划的一小段再重新规划



教学示意：按功能解释，不代表所有方法具有相同网络结构。

教学打分：score = -目标距离 - 2×碰撞风险 - 0.1×动作代价。候选 A 预测距离 0.2、碰撞风险 0.3、代价 1，得分 -0.9；候选 B 距离 0.4、风险 0、代价 1，得分 -0.5。此时 B 更好，因为模型认为绕路更稳妥。数字与权重只是说明评分如何影响选择，不是通用配置。

若碰撞风险预测错，评分再精确也没用。目标函数还要有合理量纲、终止价值与动作限制。模型偏好某条路线，未必代表真实世界也偏好它。

12.2 CEM 为什么能比一次乱采样更有效

CEM（Cross-Entropy Method，交叉熵方法）是一种采样优化思路。先从分布采样动作序列，模型展开并评分，保留高分候选，再用它们更新采样分布，重复若干轮。其名称与分类训练的交叉熵损失相关，但这里承担搜索优化功能。

```
初始化动作序列采样分布
重复若干搜索轮:
  采样 N 条候选动作序列
  用模型展开未来并打分
  保留高分的少量精英候选
  更新采样分布，适当保留探索
执行最优序列前 K 步
用真实新观测重新开始规划
```

采样更多、预测更长，可以增加搜索成本，也可能让优化器更善于发现模型漏洞。必须同时比较搜索预算、延迟、任务成功和真实预测误差。

12.3 梯度规划、特征目标与风险

如果动态模型和目标可微，可以直接对动作序列求梯度。可微不代表好优化：非凸目标、错误梯度、动作约束和接触突变仍可能造成失败。采样与梯度方法也可以组合。

DINO-WM 这类特征规划路线可比较预测特征与目标图像特征距离，不必每一步生成像素。目标图像应与任务相关，特征距离也需能表达“完成”而不是只匹配背景。

Uncertainty（不确定性）估计可用于风险评分，但必须检查 Calibration（校准）：预测很确定时是否真的准确。多个模型意见一致不保证它们没有共享训练偏差。

读懂检查：你把预测时域翻倍后成功率提高，能否排除只是计算预算翻倍？应比较相同预算下的预测长度、候选数量和反馈间隔。

13. 长时程、记忆与分层：算法要知道任务走到哪了

13.1 一个短策略为何完成不了整条任务链

任务“开柜门 → 拿杯子 → 倒水 → 清理”含依赖关系。拿杯子要求门真的打开；倒水要求杯子真的被抓住。动作块可以覆盖几秒连续行为，但不必然记录几分钟前的事实和任务进度。

在理想化的独立步骤假设下，每步成功概率为 0.9，10 步全部成功约为 0.9^10≈0.35。真实步骤往往相关，也可恢复，因此这不是普适成功率公式；它只说明很多小误差会使长任务更难。

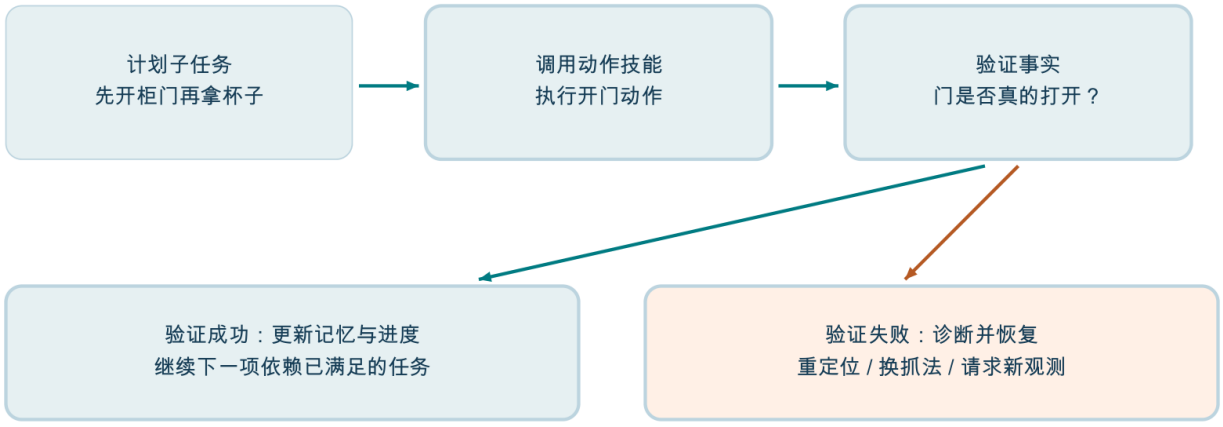
13.2 记忆存什么、更新什么、取什么

短期历史窗口保留最近帧；循环状态压缩过去；显式记忆保存任务事实、对象位置或技能结果；检索机制从历史中取相关记录。这些设计在容量、更新规则、可解释性和时延上不同。

“杯子刚放到左柜子”比整段重复视频更直接，但如果记录来自错误识别，会形成错误事实。记忆应附时间、来源和可信度，在环境变化后能够校正。只增加历史帧数并不能证明记忆模块真的更好。

13.3 计划、执行、验证、恢复

图 17 | 长时程 Agent：记录证据才能正确恢复



教学示意：按功能解释，不代表所有方法具有相同网络结构。

LLM（Large Language Model，大语言模型）可提出子任务或调用工具，动作策略执行，验证器根据环境证据确认结果。Harness（运行支撑框架）组织上下文、记忆、工具接口、进度和异常处理。

如果控制接口返回“动作已发送”，只能证明发送成功，不能证明柜门打开。验证应检查环境事实，失败后选择重定位、换策略或重新观察。无限重试可能增加表面成功率却牺牲时间和可靠性，协议应报告重试与干预。

Slow / Fast System（慢 / 快系统）按职责与频率分工：慢系统组织语义和子目标，快策略与控制器跟踪运动。它可以是一个模型不同模块，也可以是多个模型；“双系统”不必然意味着固定两个网络。

13.4 五篇学长推荐论文放回算法主线

P1 Agentic Robots 帮你把策略放回 Model、Data、Environment、Harness 系统；P3 长时程综述讨论依赖、记忆、验证和持续执行；P4 世界模型综述讨论未来预测的表示、时间建模与用途。

P5 Path to RSI 与 P2 Last AI 讨论 RSI（Recursive Self-Improvement，递归自我改进）。策略更新、世界模型更新、改进机制更新是不同层。只把失败加进训练不自动构成递归改进；还要看负责寻找、选择或验证改进的机制是否被修改、继承并在后续更有效。

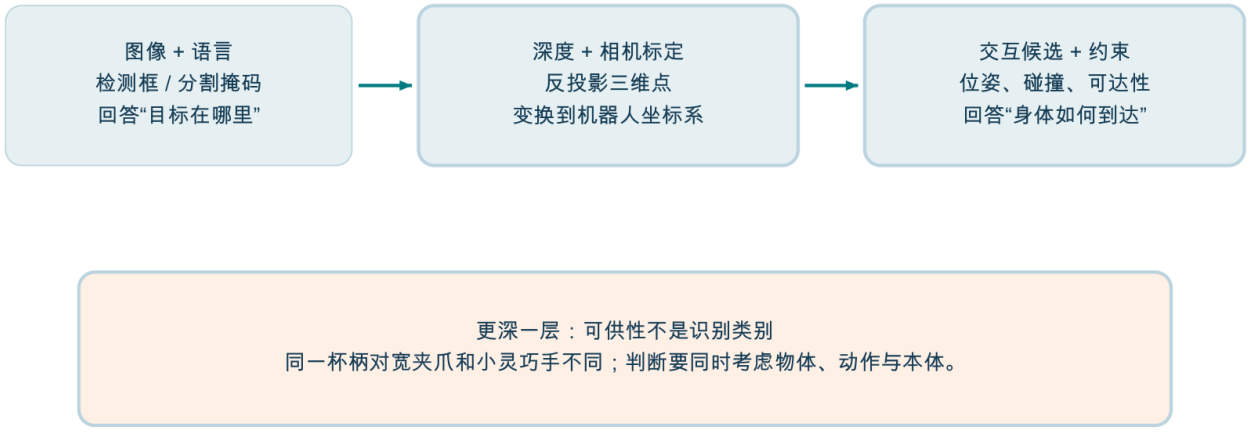
因此偏算法的第一遍建议先 ACT / DP、VLA、世界模型，再读长任务与系统，最后读两篇 RSI。保留广度，但不要在还不清楚动作和训练目标时直接钻进递归框架。

读懂检查：如果记忆方法更好，如何证明收益来自记忆而非更多图像和算力？设计相同预算、相同历史信息的对照，并用确实依赖历史的任务评测。

14. 几何、视觉与图形：偏算法也需要的最低接口知识

14.1 从像素到机器人坐标

图 15 | 从二维语义到三维动作，中间还缺哪些量？



教学示意：按功能解释，不代表所有方法具有相同网络结构。

检测框说目标在哪片图像，分割掩码区分目标像素，深度提供距离，相机内参连接像素与射线，外参连接坐标系。一个简化针孔相机反投影为 X=(u-cx)Z/fx、Y=(v-cy)Z/fy；这里 Z、焦距和主点定义需与相机约定一致。

变换到机械臂基座需要旋转和平移，示意为 p_base = R p_camera + t。相机内参、机器人时刻和外参一旦错配，模型输出可以很稳定却持续抓偏。深度是相对尺度时还不能直接当作米。

FK（Forward Kinematics，正运动学）由关节求末端位姿；IK（Inverse Kinematics，逆运动学）由末端目标求关节。IK 有解不保证整条轨迹无碰撞。Pose（位姿）包含位置与朝向，DoF（Degrees of Freedom，自由度）描述独立变量数量。

14.2 点云处理、配准和表示稳定性

点云太密会增加开销，也含噪声与背景。体素下采样把空间划格并选代表点；FPS（Farthest Point Sampling，最远点采样）逐步选择距离已有集合较远的点，帮助覆盖空间。这里 FPS 不代表视频 Frames Per Second（每秒帧数）。

ICP（Iterative Closest Point，迭代最近点）通过匹配与变换对齐点云，依赖初值与有效对应。几何数据增强应同步处理坐标、动作和本体状态，不能把对象旋转了却保持标签不变。

几何对应需要局部细节，语言检索需要语义关联，动作策略需要任务相关表示。同一个视觉编码器对这三种目标不必同样合适。

14.3 Affordance、2D / 3D / 4D 分别是什么

Affordance（可供性）描述在某个本体与动作条件下可能的交互。杯柄是一个可抓区域，但宽夹爪可能进不去；门把手可抓，不代表往任意方向拉都能开门。可供性可以输出热图、交互点、方向或动作参数。

2D（Two-Dimensional）视觉处理图像；3D（Three-Dimensional）视觉处理空间；4D（Four-Dimensional）通常指三维加时间的变化建模。它不是“维数更高就更智能”，而是是否保留任务需要的空间与时间结构。

Grounding（落地关联）把文字或抽象表示对应到环境对象、区域和动作。SAM（Segment Anything Model）系列做提示分割，Grounding DINO 以文本找对象；组合能提供可检查中间输出，但仍需动作规划与控制。

14.4 重建、渲染、动态预测不能互相替代

NeRF（Neural Radiance Fields，神经辐射场）学习场景的密度与视角相关外观，支持新视角渲染；3DGS（3D Gaussian Splatting，三维高斯泼溅）用三维高斯表示场景并快速渲染。漂亮渲染不自动提供质量、摩擦、碰撞体或物体未来动作。

Real2Sim（Real-to-Simulation，现实到仿真）可用重建形成场景资产，但通常还需物理属性、关节和碰撞表示。Sim2Real（Simulation-to-Reality，仿真到现实）考虑视觉、动力学、延迟与噪声差异。Differentiable Rendering（可微渲染）可以将图像误差传回场景参数，不等于所有接触物理都容易求导。

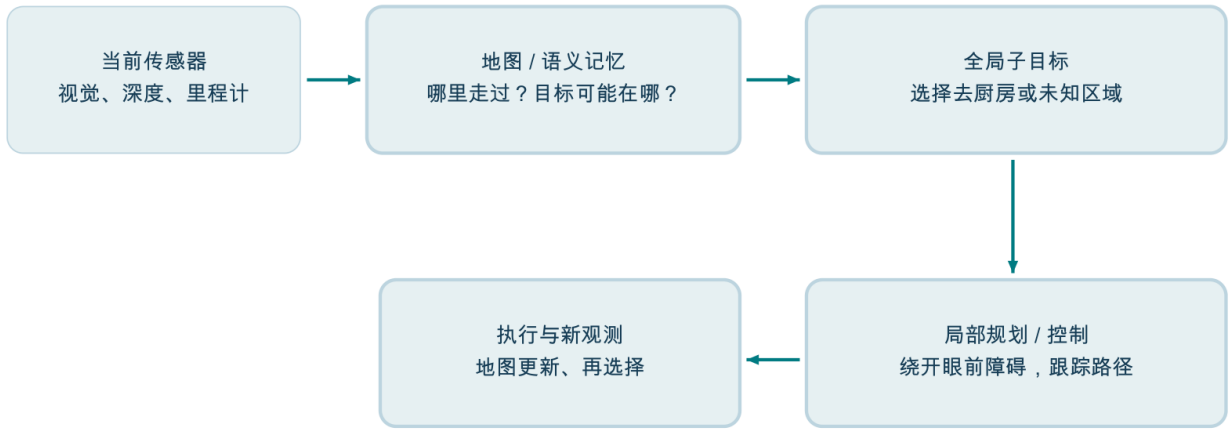
读懂检查：看到论文加了 3D 表示，应问它改进了几何精度、跨视角泛化、动作条件还是数据生成？这些是不同贡献。

15. 导航、全身控制与其他分支：广度怎样保留

15.1 导航的任务、系统结构与训练设置是不同轴

ObjectNav（Object-Goal Navigation）寻找物体类别；ImageNav（Image-Goal Navigation）去到目标图像位置；VLN（Vision-and-Language Navigation）按语言导航；PointNav（Point-Goal Navigation）到指定点。这些目标形式决定感知与探索的难点。

图 16 | 导航：探索决策与局部避障承担不同职责



教学示意：按功能解释，不代表所有方法具有相同网络结构。

模块化系统可包含地图、探索 / 全局子目标、局部规划和控制；端到端系统可直接从观测与目标生成动作。Zero-Shot（零样本）是训练 / 迁移设置，不能严格与“模块化”“端到端”作为互斥结构分类：一个模块化或端到端模型都可能在特定目标上零样本测试。

地图告诉机器人哪里走过、哪些位置可通行；探索决策告诉它优先去哪里找冰箱；局部避障让它不撞眼前椅子。语义常识认为冰箱可能在厨房，不代表厨房可达，也不能替代实时碰撞检查。

导航可研究视觉定位、地图表示、记忆、探索、目标落地与动作生成，不是只有路径搜索。SLAM（Simultaneous Localization and Mapping，同时定位与建图）同时估计位置和地图，并不限于已经有地图的场景。仓库中的简化对比需要以这些实际边界理解。

15.2 运动学习与全身控制

WBC（Whole-Body Control，全身控制）协调躯干、腿、手臂等部位满足运动与约束；PID（Proportional-Integral-Derivative，比例积分微分控制）跟踪误差；学习策略可能给关节目标，低层控制执行。稳定性、接触、平衡、控制延迟尤其重要。

仿真训练常使用机器人状态、速度目标和奖励；部署还涉及状态估计、动作限幅与摩擦、质量、执行器差异。模仿运动与动作重定向 Retargeting 将一种身体的运动映射到另一种，但需要解决形态与动力学不一致。

若你更偏视觉与深度学习，可以先从操作策略、VLA、潜空间世界模型进入；若喜欢优化和动力学，可以考虑基于模型 RL、控制与规划。两条路线都要识别动作与评测接口，但不要求一开始成为完整控制工程师。

15.3 无人机、驾驶和医疗有何不同

UAV（Unmanned Aerial Vehicle，无人机）强调高速闭环、飞行稳定与探索；自动驾驶强调动态参与者、轨迹预测和场景泛化；医疗操作可能涉及柔性组织、接触感知、专家示范和严格任务条件。相同“策略 / 世界模型”框架可以迁移，但动作频率、观测、风险和验证证据不同。

本章保留这些分支的机制地图，具体方法清单与行业案例请回仓库算法篇第 (10) 节。这里没有逐篇深读所有应用论文；覆盖位置与深度在 11 覆盖核对文档中明确列出。

读懂检查：你能否用“任务目标、观测、动作、监督、部署约束、评测”六项描述一个新分支，而不先背模型名单？

16. 代码与实验：从理解跨到可验证的小问题

16.1 第一个实验建议只检验一件事

如果尚未决定方向，先选择一个任务、小量公开演示和 ACT / Diffusion Policy 基线。目标是让一条数据经过加载、归一化、预测、反归一化、执行与评测；不是先跑一个最大模型。

不必现在安装全部环境。纯理解阶段可以先画样本窗口、手算一个动作误差、查看参考代码 forward 的输入输出和训练 / 推理分支。实际配置依仓库版本与设备支持，不承诺某个固定显存能跑所有设置。

16.2 阅读代码时的顺序

先找 Dataset / DataLoader（数据集与加载器），检查字段与单位；再看 Model.forward（前向函数），追张量形状；然后看 loss（损失）和哪些参数更新；接着看 inference / sample（推理 / 采样）；最后看环境执行与 evaluator（评测器）。

在 ACT 原始代码中，policy.py 组织 L1 与 KL 损失，detr/models/detr_vae.py 展示后验潜变量与动作解码；部署调用再决定如何取动作和集成。理解这条链比逐行阅读所有工具函数更直接。

同理，扩散项目先追条件编码、噪声构造、训练目标、采样器与执行切片；世界模型先追真实后验状态、想象先验展开、奖励 / 价值信号和环境验证。代码里名字相似的变量不一定同义。

16.3 实验矩阵与消融

图 18 | 有用实验：控制变量，再增加压力测试



教学示意：按功能解释，不代表所有方法具有相同网络结构。

Ablation（消融）去掉或替换关键模块，检查收益来源；Baseline（基线）提供参照；压力测试在固定权重下变化遮挡、视角、对象、扰动与长期依赖。训练数据、观测权限、重试预算、控制频率和计算预算应尽量对齐。

除了 SR（Success Rate，成功率），报告失败类型、试验数、多个随机种子、均值与波动、推理延迟、训练成本和人类干预。几个百分点变化在少量试验下可能只是噪声。

16.4 三个算法方向的小问题卡片

候选方向	可验证的问题	必要对照与边界
动作分块与反馈	H 固定时，改变执行间隔 K 是否改善受扰动任务？	固定模型与测试扰动；同时报告延迟与动作平滑
特征世界模型	相同编码器下，多步动态训练是否改善动作选择？	不用模型、一步模型、多步模型；对齐搜索预算
历史 / 记忆	相同输入信息与预算下，压缩记忆是否提升遮挡后恢复？	确实依赖历史的任务；与简单窗口、随机记忆比较

这些是学习实验，不承诺天然构成论文贡献。形成研究需要查已有工作、定位缺口、重复验证和解释条件。小但可独立验证的问题，通常比同时换编码器、数据、动作头和规划器更容易判断。

读懂检查：你能否写出一个“只改变一个核心因素”的实验，并明确什么结果会否定你的假设？

17. 前沿进展怎样读：用问题线索代替追模型名字

17.1 四条值得优先跟踪的算法线索

动作生成：回归、离散 token、扩散、流匹配如何平衡多模态与延迟？后训练：演示、自主交互、纠正与奖励如何提高覆盖和可靠性？预测与记忆：未来模型、历史状态怎样进入训练或部署？可信评测：如何区分任务拟合、数据重叠与真实泛化？

仓库 2026 工作清单提供发现论文的入口。这里按机制讲解，没有将每条仓库描述都当作已独立复核的实验结论，也没有把商业发布等同于公开可复现算法。数据引擎与评测重要，不意味着网络架构已经没有研究价值。

17.2 偏算法的推荐阅读顺序

第一轮：本章 1 至 7，配合仓库 Robot Learning 与经典 ACT / Diffusion Policy，建立数据与动作生成基础。第二轮：本章 8 至 12，配合 S2 VLA 与 P4 世界模型综述，从动作表示与动态用途比较方法。第三轮：本章 13 至 16，配合 P1 / P3，把算法放回记忆、验证、执行与评测。最后读 P5 / P2，分清持久更新和递归改进。

如果更喜欢算法理论，优先补概率分布、变分推断、策略梯度和模型预测控制；如果更喜欢深度学习实现，优先追动作窗口、条件融合、生成器与评测入口。广度阶段能描述各方向问题就够了，深度阶段只选一条主线精读代表方法与代码。

17.3 数学预备知识：学到能解释用途

期望：对随机样本平均；条件概率：已知观测后动作分布；负对数似然：让真实样本更可能；KL：比较分布并约束偏离；梯度：参数小变化对目标的影响；数值积分：沿速度场一步步更新；Bellman：把长期价值拆成当前与未来。

这些概念应与本文实例对应。不会推完整推导并不妨碍先理解系统，但想研究方法改进时，需要回到原论文的精确定义和推导条件。

18. 常见疑问与答案：读完后应能自己解释

问题一：ACT 与 Diffusion Policy 都输出动作块，为什么还算不同方法？因为动作块只是输出组织；ACT 使用条件解码与潜变量训练，扩散使用带噪动作监督和迭代生成。共同输出形状不代表共同概率模型。

问题二：流匹配速度就是机器人关节速度吗？不是，它是生成空间里动作块随 τ 变化的向量场；最终动作块才按其定义进入实际控制接口。

问题三：世界模型与策略能用同一个 Transformer 吗？可以共享或联合建模，但仍要分别说明预测对象、动作选择与训练信号。功能合并不意味着无需区分作用。

问题四：语言模型说“门已开”能当奖励或任务完成吗？只有经过适当环境证据验证才可靠。模型陈述、控制指令发送与真实完成不是同一件事。

问题五：特征预测不用像素，就一定省算力又更好？可能省部分生成成本，但编码、预测长度与特征数量仍占资源，且可能漏掉关键物理量；最终要测任务收益。

问题六：预训练 VLA 微调少量样本后表现好，是不是证明我的架构好？还可能来自预训练数据、任务相似性或执行协议。应与相同基座、相同数据预算的基线比较。

问题七：加长动作块和加长记忆是一回事吗？前者预测未来，后者使用过去；一个机器人可以预测很长却不记得几分钟前放下的物体。

问题八：模拟成功能代表真机成功吗？只能支持相应模拟条件下的结果。视觉、接触、延迟、标定和重置差异需要进一步验证；当前没有真机也可以做清楚的仿真研究。

问题九：两篇 RSI 的等级编号能直接对照吗？不能，它们的分类依据不同。先写论文名、定义和具体机制，再讨论递归层次。

问题十：我什么时候该开始读代码？当你能讲清任务、条件、动作、损失和推理流程时，就从一条样本的路径开始；不必等背完整个领域，也不必一次啃完仓库。

19. 来源、覆盖深度与本章边界

仓库来源为 Embodied-AI-Guide 算法篇 与控制 / 基础设施篇。2026-10-23 重新读取公开分支的五份 Markdown，内容与此前快照一致；本章图解成稿于 2026-10-24。具体覆盖见 11 仓库覆盖核对与算法阅读地图。

ACT、Diffusion Policy、OpenVLA、openpi、DreamerV3、DINO-WM 的官方代码 / 项目说明用于核对机制；涉及算法的公式为便于理解的简化表达，不替代完整论文推导。18 张图为原创教学图，并非论文原图或实验结果。

本章深入解释数据、表征、BC、ACT、扩散、流匹配、VLA、RL、世界模型与规划；几何、导航、控制与应用分支提供机制和接口层说明；没有复制仓库的全部链接清单，也没有逐篇复核其所有前沿与行业条目。文档是否足够，应由是否能解释这些机制和接口判断，不能只按页数判断。

仓库覆盖核对与算法阅读地图

更新于 2026-10-24。本文件回答“仓库比学习文档详细，文档是否漏了内容”，并说明哪些内容已经展开、哪些只保留方向地图。以覆盖的问题与机制判断充分性，不承诺把链接索引中的每一篇论文都改写成教材。

1. 之前的导读为什么显得薄

仓库 README、algorithm、control、infrastructure、hardware 五份 Markdown 分别约为 2.29 万、5.21 万、1.05 万、0.99 万、1.26 万字符，包含链接、代码、表格和资源名称，不能将这些字符直接等同于教材正文。算法篇自称“索引而非教材”，它给广泛入口；学习文档应该补上入口背后的机制解释。

此前 01 仓库导读将四篇内容压成一个速览，覆盖了主链，但对算法方向不够充分：潜变量、生成目标、动作 token、价值学习、规划与表示选择都过于简略；计算机视觉、图形、导航、应用等分支也没有明确展开。五篇论文的短导读属于框架理解，不是所有方法的详细教材。

本次保留 01 作为速览，新增 10 算法图解详解：按样本、条件表示、训练目标、推理、动作执行和独立评测组织，并补充公式说明、图、伪代码、失败原因与自测。新增文件可单独作为主教材，也已经合并进完整文档。

2. 算法篇十个顶层板块的对应位置

仓库板块	本包对应位置	覆盖深度与保留项
(1) Common Tools	10 第 2、14、16 节；09 第 5 节	数据接口、标定、点云、运动学、代码路径；不复制所有工具安装命令
(2) Vision Foundation Models	10 第 3、14 节；01 第 3 节	特征与检测 / 分割 / 位姿的区别、条件融合、冻结与微调；型号列表以仓库为入口
(3) Robot Learning	10 第 4 至 7、9 至 10、16 节	BC、ACT、扩散、流匹配、RL 价值 / 更新、离线与后训练；训练与部署分别解释
(4) LLM for Robotics	10 第 13 节；02、04 论文导读	分层、技能接口、事实验证、记忆与恢复；不默认语言输出可执行
(5) VLA	10 第 8、10、17 节；07 的 S2	动作表示、离散 / 连续头、预训练 / 微调、后训练与前沿问题轴；不逐篇重写全部型号论文
(6) Computer Vision	10 第 3、14 节	2D / 3D / 4D、空间与时序、可供性与落地；基础 CV 课程仍需按需补
(7) Computer Graphics	10 第 14 节；09 世界模型模块	NeRF / 3DGS、渲染 / 重建 / 动态区别；未推导完整渲染或资产重建流程
(8) Multimodal Models	10 第 3、8 节	token、注意力、跨模态交互、条件融合与动作语义；不逐层复现所有 VLM
(9) Robot Navigation	10 第 15 节；09 第 3、6 节；07 的 S4	目标、系统结构、探索 / 局部控制、数据与评测；具体导航方法保留原仓库检索入口
(10) Embodied AI for X	10 第 15 节；仓库原节	医疗、无人机、驾驶的算法约束地图；应用论文逐篇精读未包含，按兴趣再选

表中“覆盖”不是“每个链接都已精读”。算法主线已展开到能说明机制与接口；导航与行业应用提供广度；专门工程操作与数学完整推导仍需在选方向后深入。

3. 控制、基础设施与硬件怎样读才适合算法背景

控制篇第 (1) 至 (3) 节，优先掌握坐标、运动学、状态估计和接口；第 (4) 全身控制，先区分策略目标与低层执行。数据与策略论文没有要求你先学完全部现代控制，但控制错误不能完全用模型大小解释。

基础设施篇与 09 工具地图一起读，优先区分数据集、任务环境、仿真器、评测、权重；然后看动作单位、显存、并行、配置与日志。硬件篇只需先知道传感器、自由度、控制接口和遥操作如何限制数据及动作，不要求逐款采购和搭建。

算法向主阅读顺序：01 速览 → 10 第 1 至 7 节 → 10 第 8 至 12 节 → P4 / S2 → P1 / P3 → 按兴趣读 P5 / P2。09 作为工具查询；07 提供补充综述和选方向线索。

4. 哪些部分还没有声称完成

没有逐篇解释仓库列出的全部前沿模型，没有对每个商业产品独立核验能力，没有重现全部安装和训练命令，没有给出可直接替代官方代码的完整实现，没有逐句重审此前九篇论文全文机器译稿。

学习文档里的公式与图用于教学；正式引用、完整损失、模型版本、硬件支持和发表状态，以论文及官方代码为准。下一阶段深入代码应选定一个代表方法，而不是同时展开所有索引。

5. 如何判断这次详解达到目的

你应能独立解释：一条轨迹如何截成样本；ACT 的后验训练与先验部署；扩散 / 流匹配的内部时间；VLA 的动作表示；RL 的奖励 / 价值 / 优势；世界模型的预测与使用；长期任务的记忆 / 验证；以及一个控制变量实验。

如果某节仍不能回答，就回该节的图与自测，而不是先换另一篇综述。若你能回答，再去代表代码追一条样本的完整路径。这是偏算法入门的完成标准，页数只是阅读成本，不是质量指标。

6. 核对来源

2026-10-23 重新下载公开分支的五份 Markdown，与之前提交 3e3abf3e687737c84113f0fe8a78587582c54eb6 的本地副本逐字对照，内容一致；图解版成稿于 2026-10-24。

README、**算法篇**、**控制篇**、**基础设施篇**、**硬件篇**。仓库正文与链接会持续更新，未来使用时核对版本。